MINE4101-Ciencia de Datos Aplicada

Universidad de los Andes Colombia
Departamento de Ingeniería de Sistemas y Computación

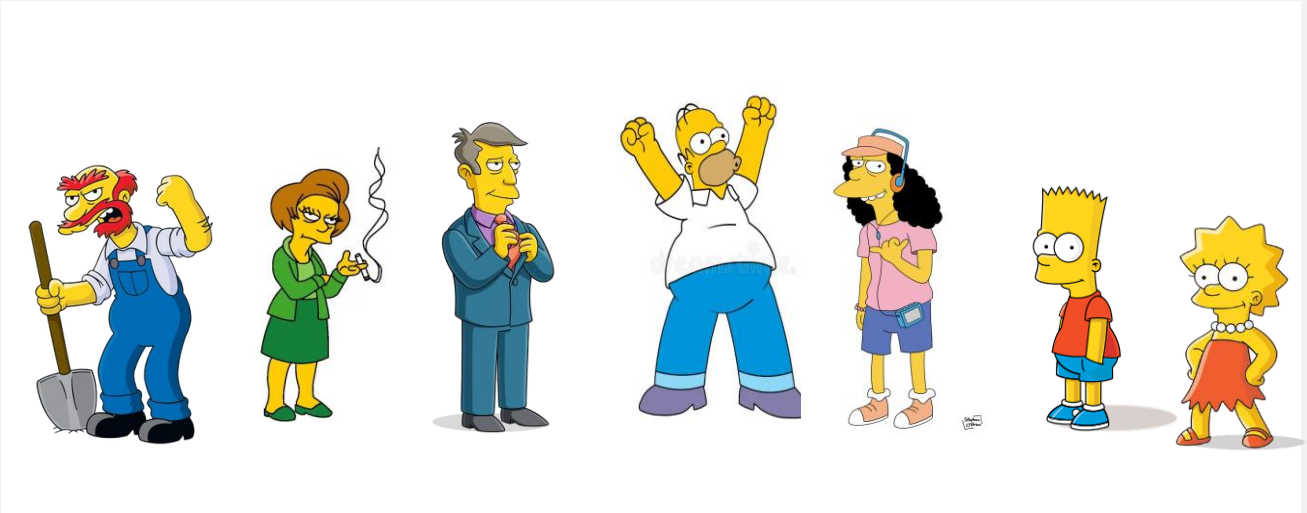
Fundamentos de modelos comunes de aprendizaje no supervisado

Reconocimiento como Universidad: Decreto 1297 del 30 de mayo de 1964.
Reconocimiento personería jurídica: Resolución 28 del 23 de febrero de 1949 Minjusticia

Aprendizaje NO supervisado

Dado un conjunto de **instancias** con **atributos** y una **medida de similitud**, encontrar un conjunto de grupos en el cual:

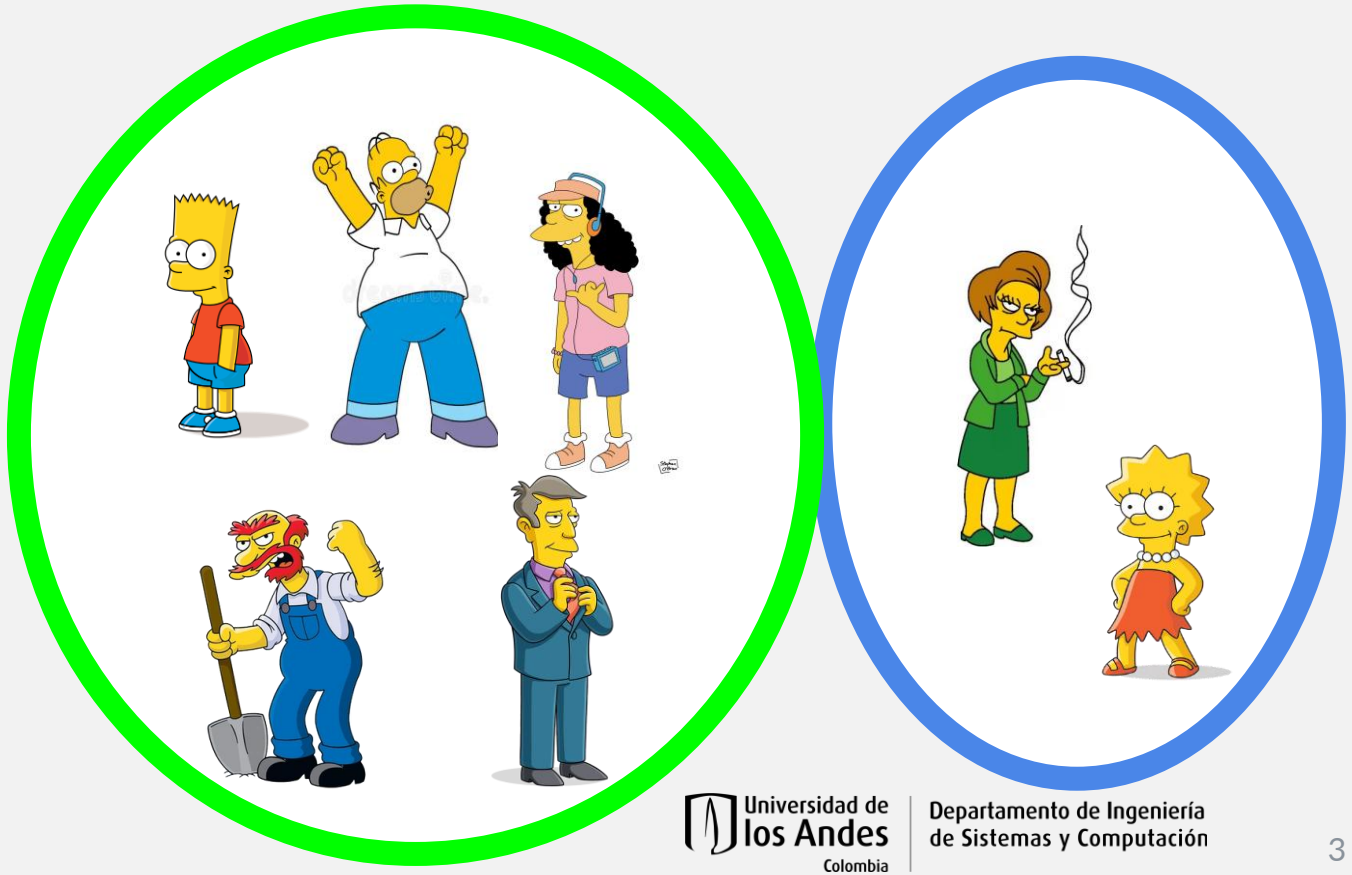
- Las instancias en un grupo sean similares entre sí.
- Las instancias en distintos grupos sean diferentes.



Aprendizaje NO supervisado

Dado un conjunto de **instancias** con **atributos** y una **medida de similitud**, encontrar un conjunto de grupos en el cual:

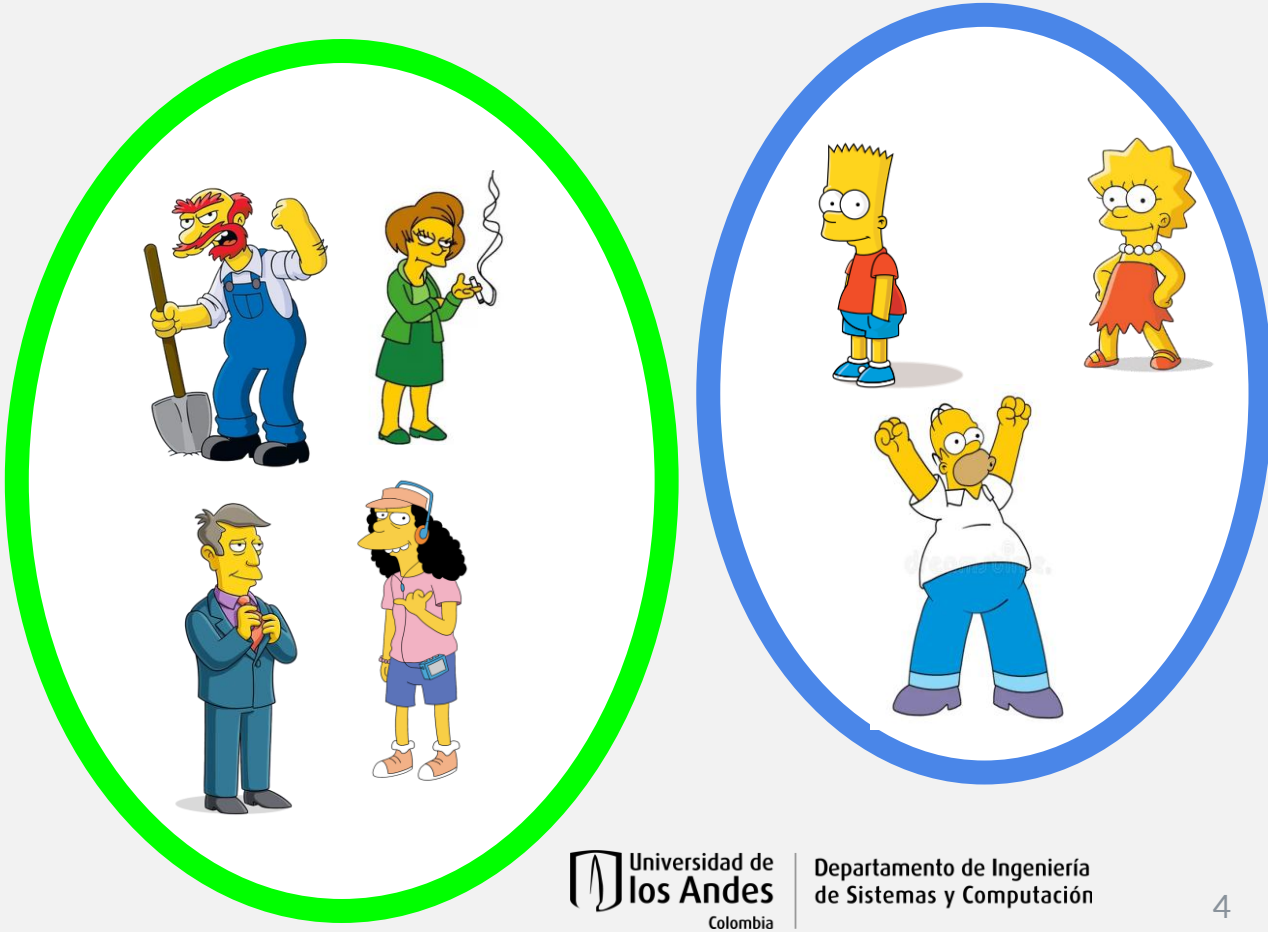
- Las instancias en un grupo sean similares entre sí.
- Las instancias en distintos grupos sean diferentes.



Aprendizaje NO supervisado

Dado un conjunto de **instancias** con **atributos** y una **medida de similitud**, encontrar un conjunto de grupos en el cual:

- Las instancias en un grupo sean similares entre sí.
- Las instancias en distintos grupos sean diferentes.

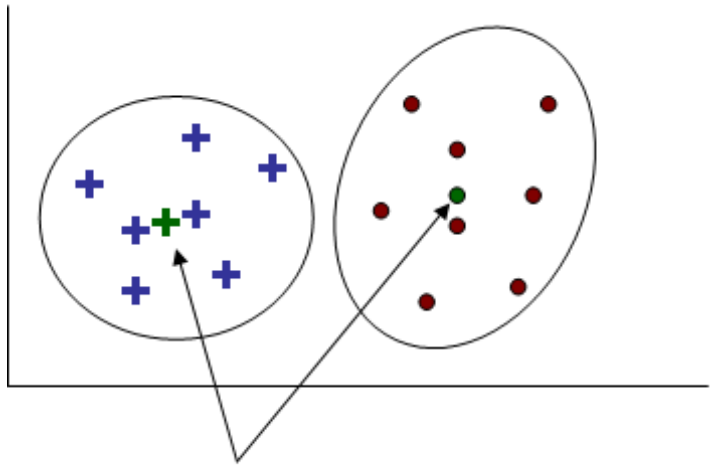


Algunos ejemplos

- **Segmentación de mercado**
  - **Meta:** identificar y agrupar a los consumidores en subconjuntos homogéneos que comparten características, necesidades o comportamientos similares.
- **Segmentación de documentos**
  - **Meta**: Encontrar grupos de documentos similares basándose en términos relevantes que aparezcan en los mismos.

Algoritmos basados en centroides

- El criterio de división son al mismo nivel.
- En general encuentra grupos exclusivos.
- La similitud se determina con medidas de distancia (p.ej Euclideana, Manhattan).
- El número de grupos (K) es especificado por el usuario.
- Se usa un prototipo o centro para representar a los grupos.



prototipos
(Centroides)

Cada dato está más cercano al centro de su grupo que al centro de cualquier otro grupo

↓

Objetivo = encontrar buenos prototipos

Algoritmos basados en centroides

Se utiliza una función objetivo (que se busca optimizar) que mide la variación dentro de los grupos.

$$E = \sum_{i=1}^{k} \sum_{\boldsymbol{x} \in G_i} dist(\boldsymbol{x}, \boldsymbol{c_i}) \qquad donde \begin{cases} x \in D = \{x_j\}_{j=1\ldots N} \\ G_i = grupo\ asociado\ al\ prototipo\ c_i, i = 1..k \end{cases}$$

Al minimizar esta función se intenta obtener grupos con una alta similitud intra-grupo (idea: obtener grupos tan compactos como sea posible)

Algoritmo de K-medias

- Sea $D = \{x_j\}_{j=1...N}$ el conjunto de datos, el algoritmo busca K particiones disjuntas; cada una asociada a un grupo $G_i, i = 1..k$
- Cada grupo G_i tiene un representante c_i el cual el es el centro del grupo = centroide o prototipo.
- El centroide puede especificarse como la media de los datos asociados al grupo.
- Un dato se asigna al grupo G_i si él está más cercano al prototipo c_i que a cualquier otro prototipo.
- Se utiliza la distancia Euclídea como medida de similitud.

Algoritmo K-medias

Entrada *= {D: conjunto de datos, K: número de grupos}*

Comienzo_procedimiento

Seleccionar K datos de D como prototipos iniciales $\mathbf{c}_i$, *i=1...K*

Repetir

Crear las particiones G_i *asignando cada dato de D a su prototipo más cercano*

Actualizar cada prototipo $\mathbf{c}_i$ *como la media de los datos de la partición* G_i

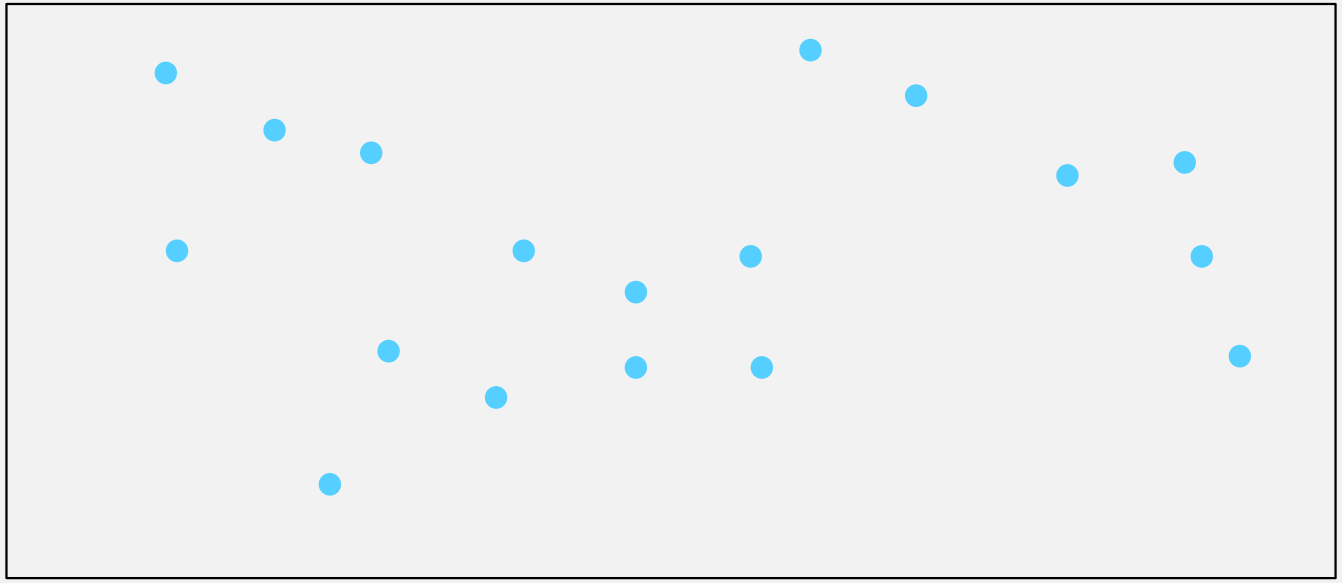
hasta *alcanzar la convergencia*

Fin-procedimiento

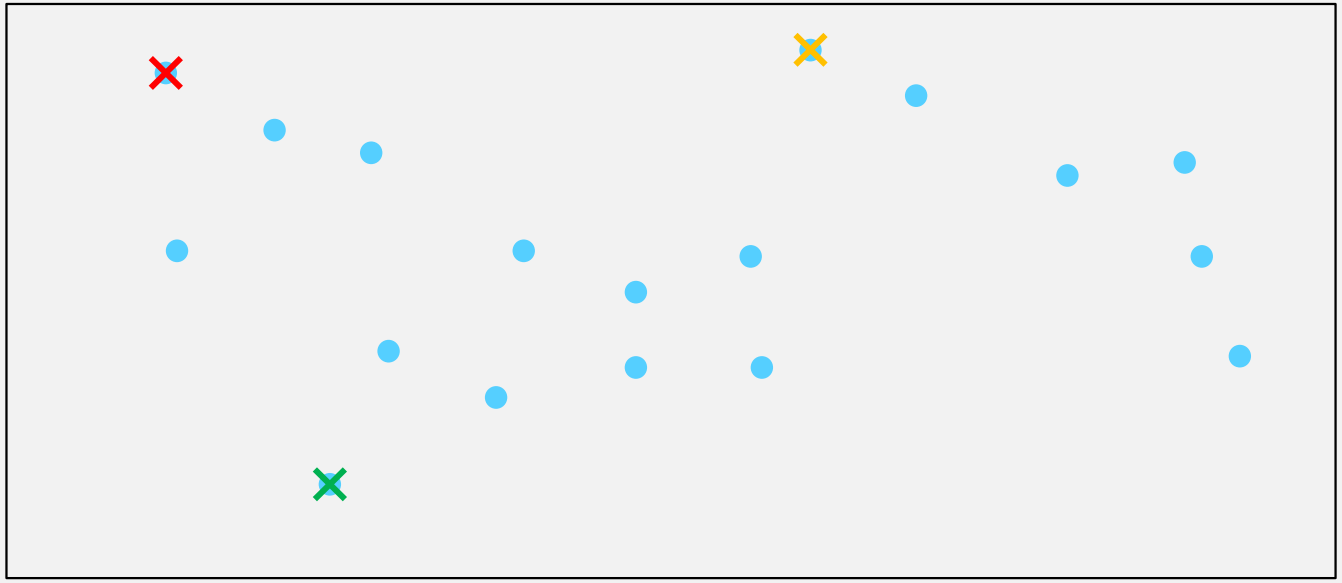
Salida *= Conjunto de prototipos* $\mathbf{c}_i$, *i=1..K*

$$E = \sum_{i=1}^{k} \sum_{\boldsymbol{x} \in G_i} \|\boldsymbol{x} - \boldsymbol{c_i}\|^2$$

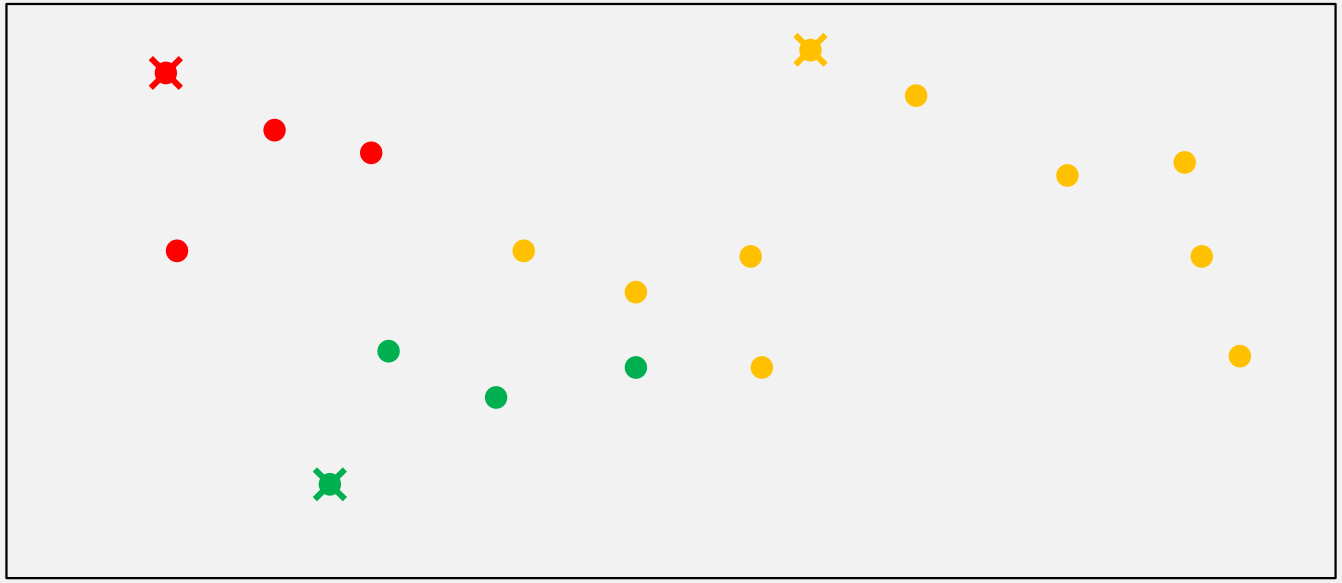
Algoritmo de K-medias



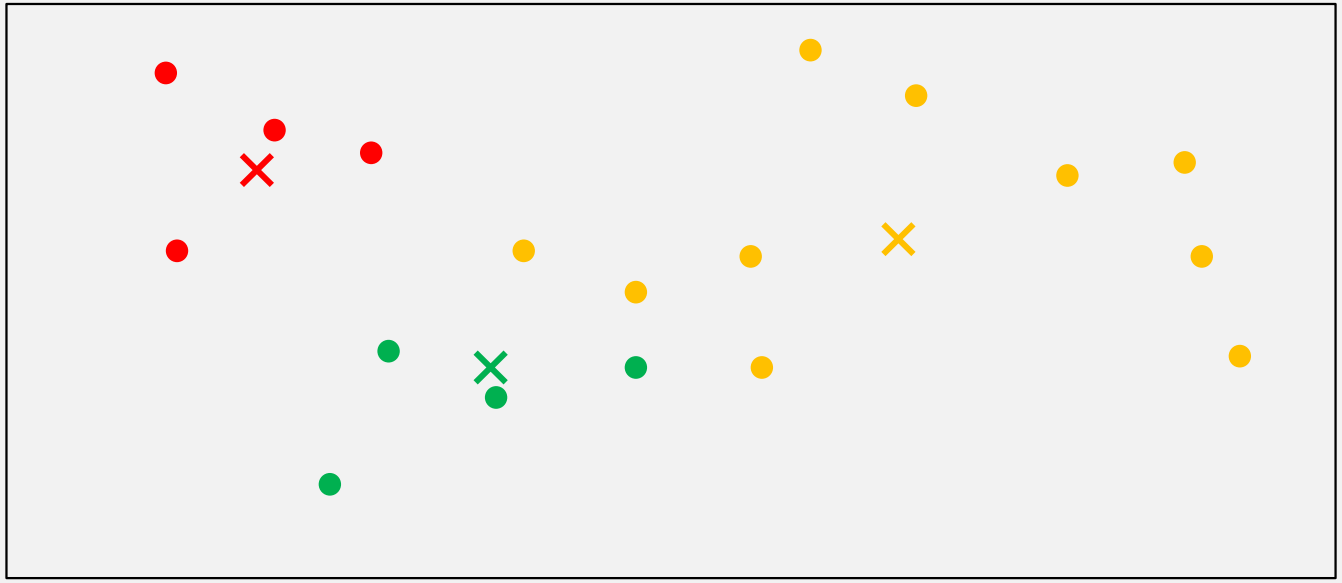
Algoritmo de K-medias



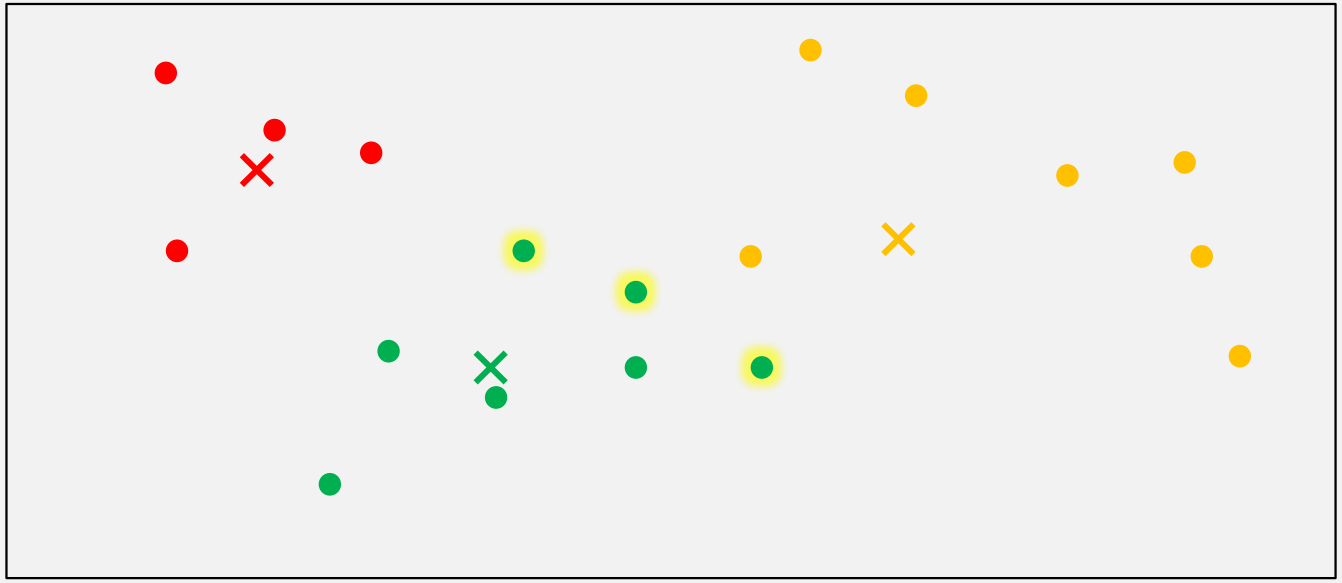
Algoritmo de K-medias



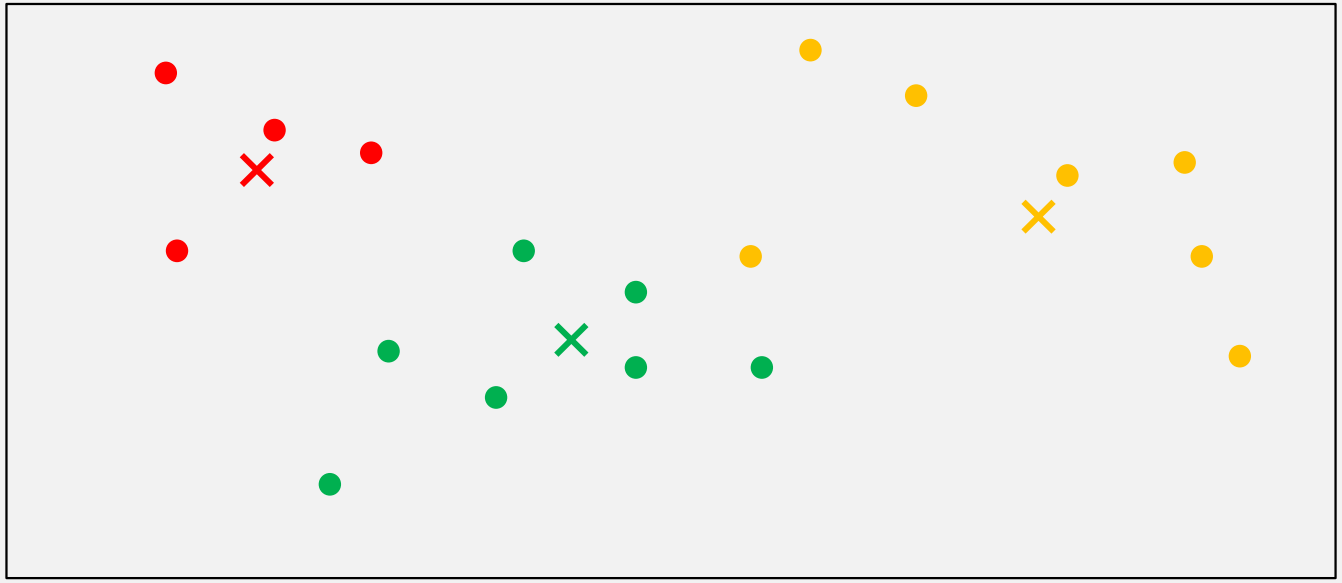
Algoritmo de K-medias



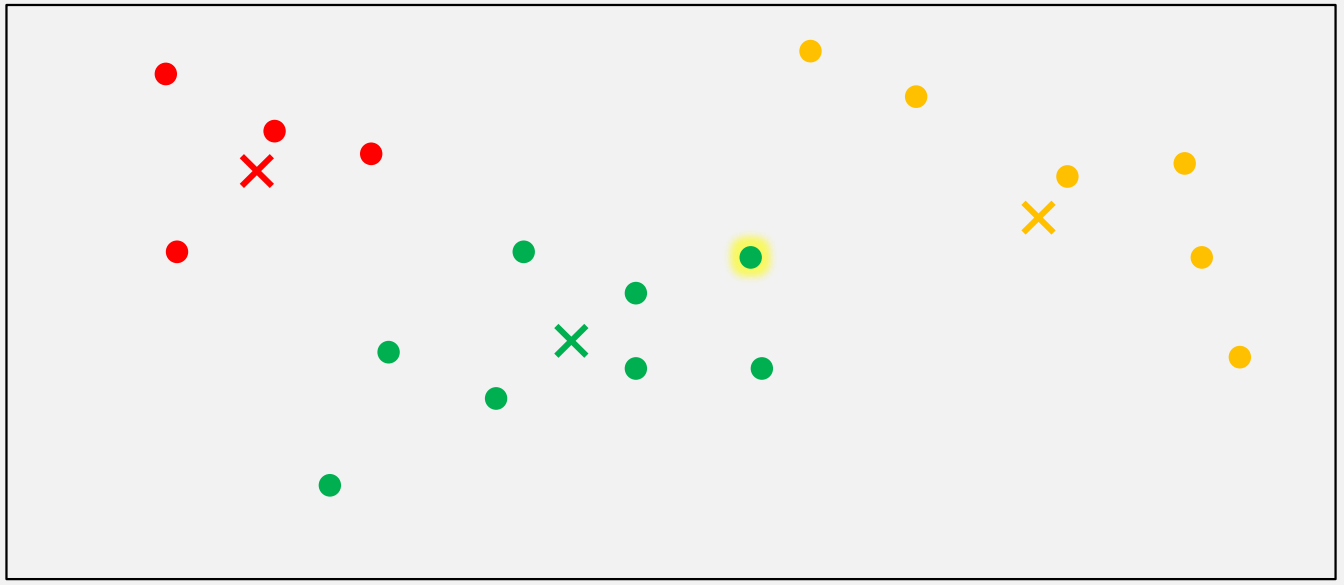
Algoritmo de K-medias



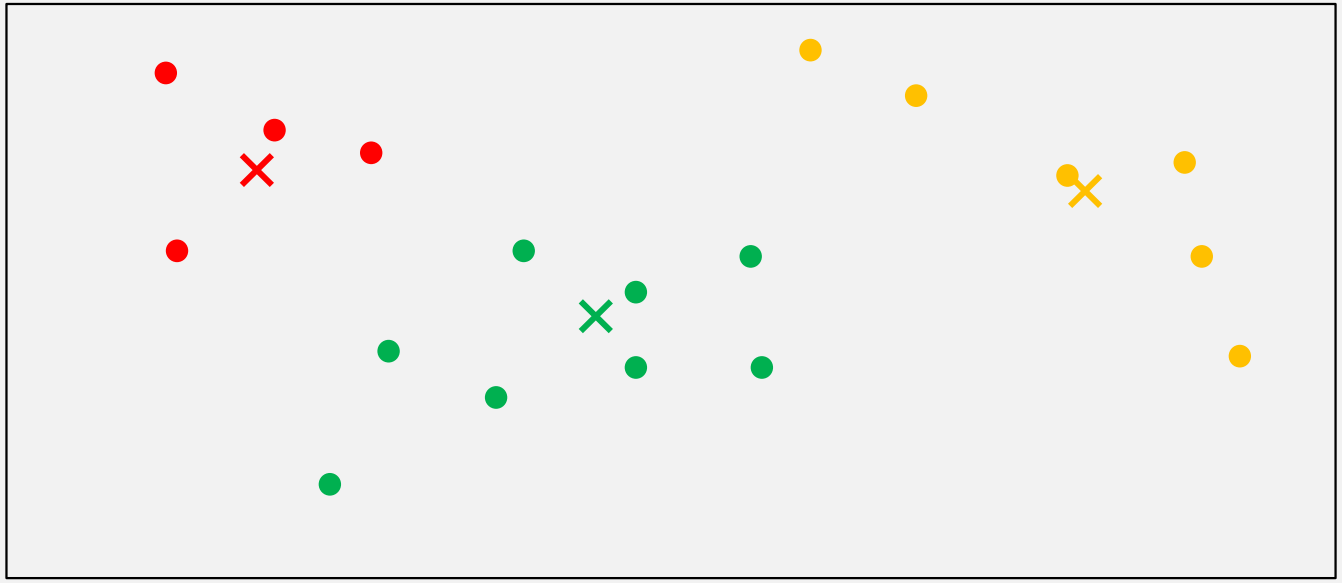
Algoritmo de K-medias



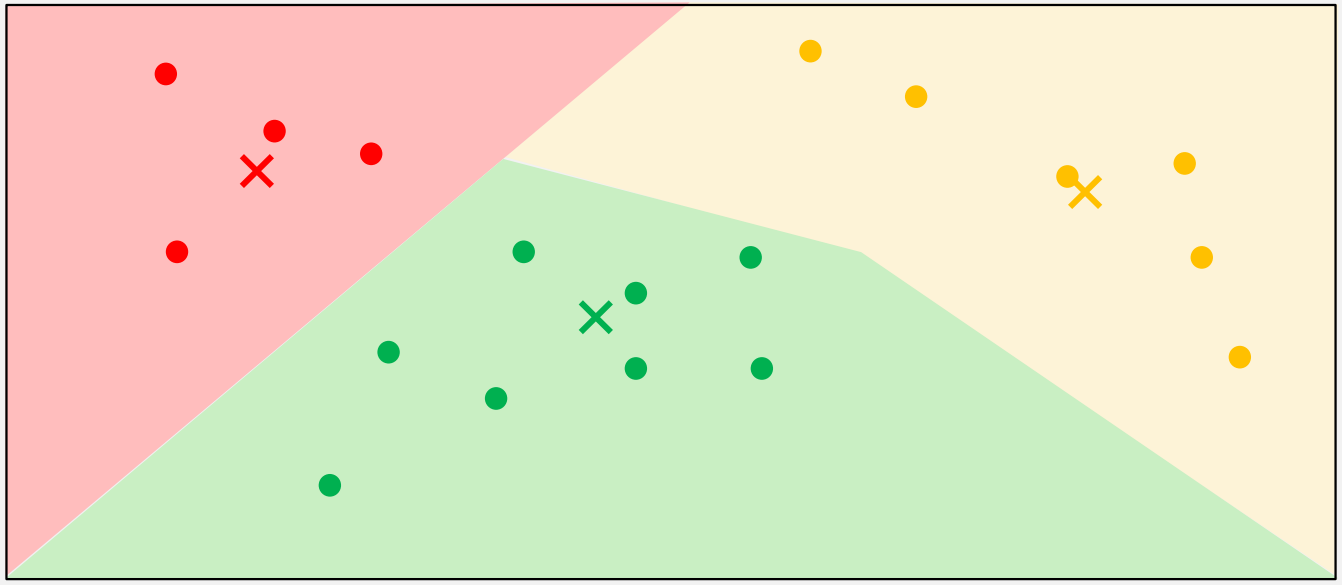
Algoritmo de K-medias



Algoritmo de K-medias



Algoritmo de K-medias

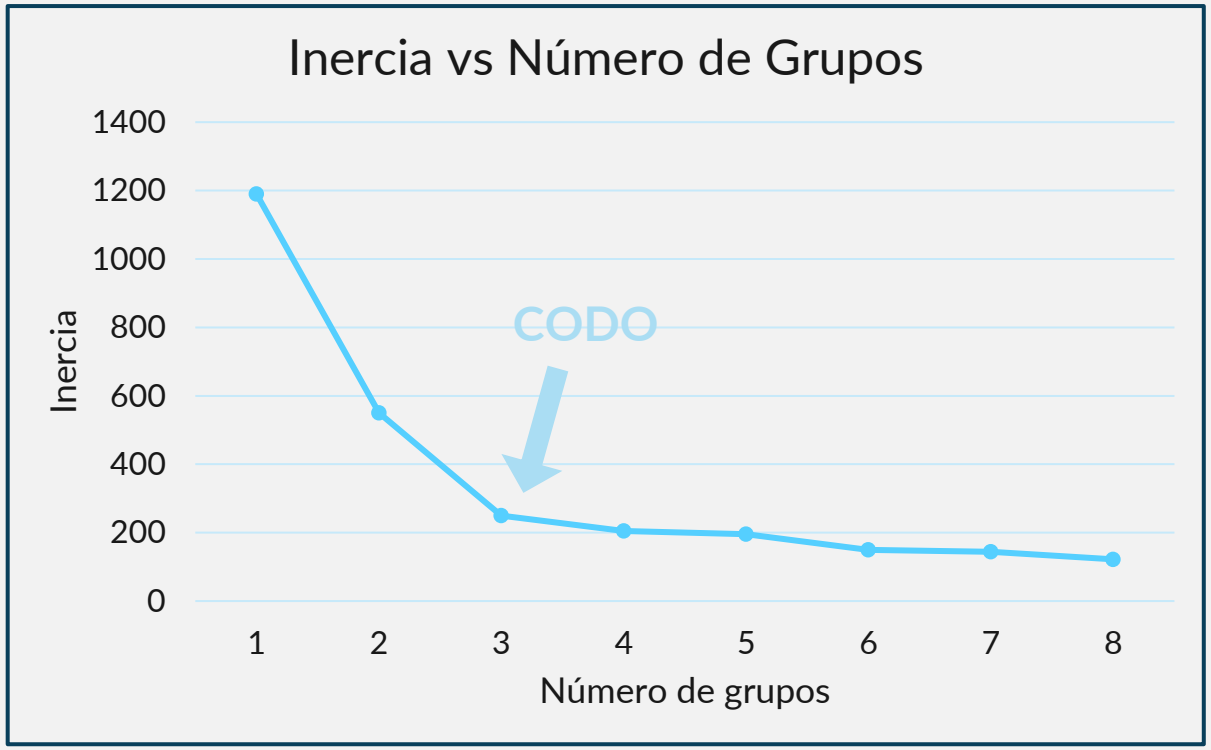


K-medias: Inercia y codo

La determinación de los grupos K debe realizarse como la búsqueda de cualquier hiperparámetro. Una opción es el método de la inercia

$$\sum_{i=1}^{N} (x_i - C_k)^2$$

En donde N es el número de muestras, x es el valor de cada muestra y C es el centroide del grupo.



El Codo es el punto de inflexión a partir del cual la inercia no se reduce significativamente.

Coeficiente de silueta

Permite cuantificar la cohesión interna y la separabilidad de los grupos. Para cada dato $\boldsymbol{x} \in D = \{\boldsymbol{x}_i\}_{i=1\ldots N}$ se calcula:

$$cs(\boldsymbol{x}) = \frac{d_{inter}(\boldsymbol{x}) - d_{intra}(\boldsymbol{x})}{max\{d_{inter}(\boldsymbol{x}), d_{intra}(\boldsymbol{x})\}}$$

Donde

$d_{inter} =$ *distancia promedio mínima de* $\boldsymbol{x}$ *a los puntos del grupo más cercano.*

$d_{intra} =$ *distancia promedio de* $\boldsymbol{x}$ *a los puntos dentro de su grupo.*

Coeficiente de silueta

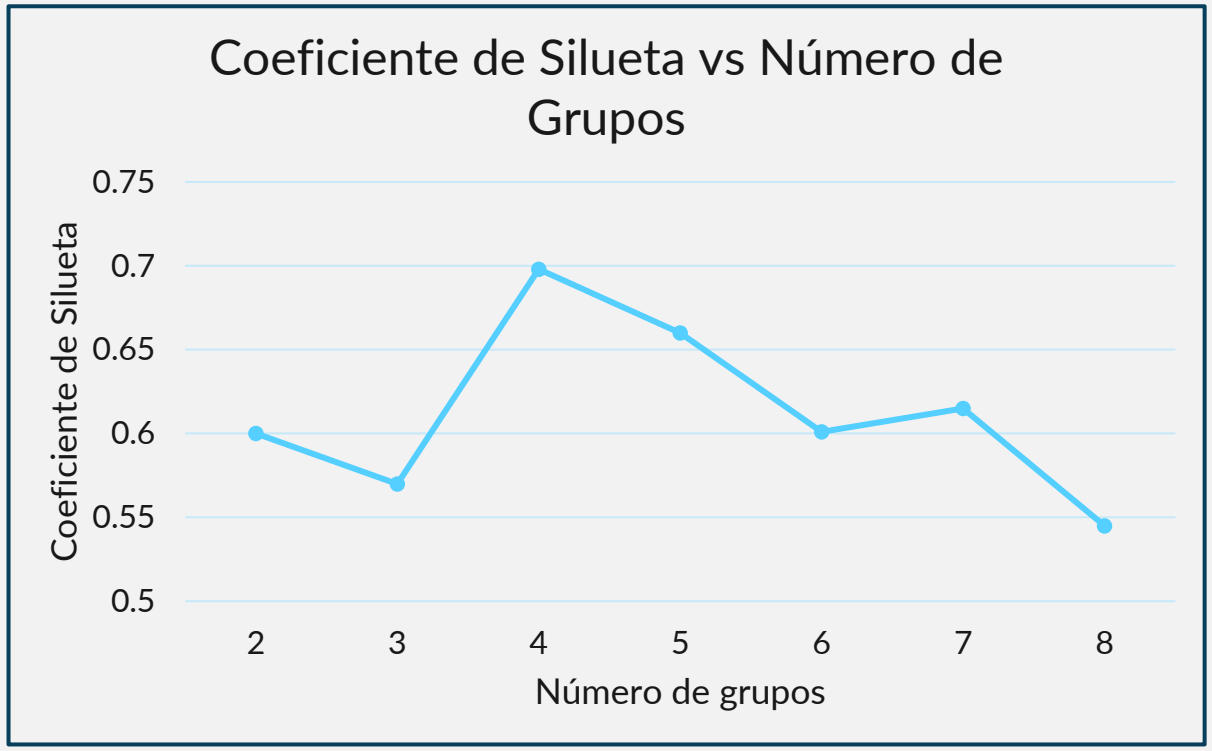
Para determinar la calidad de la agrupación se utiliza entonces el promedio de estos valores sobre el conjunto de datos:

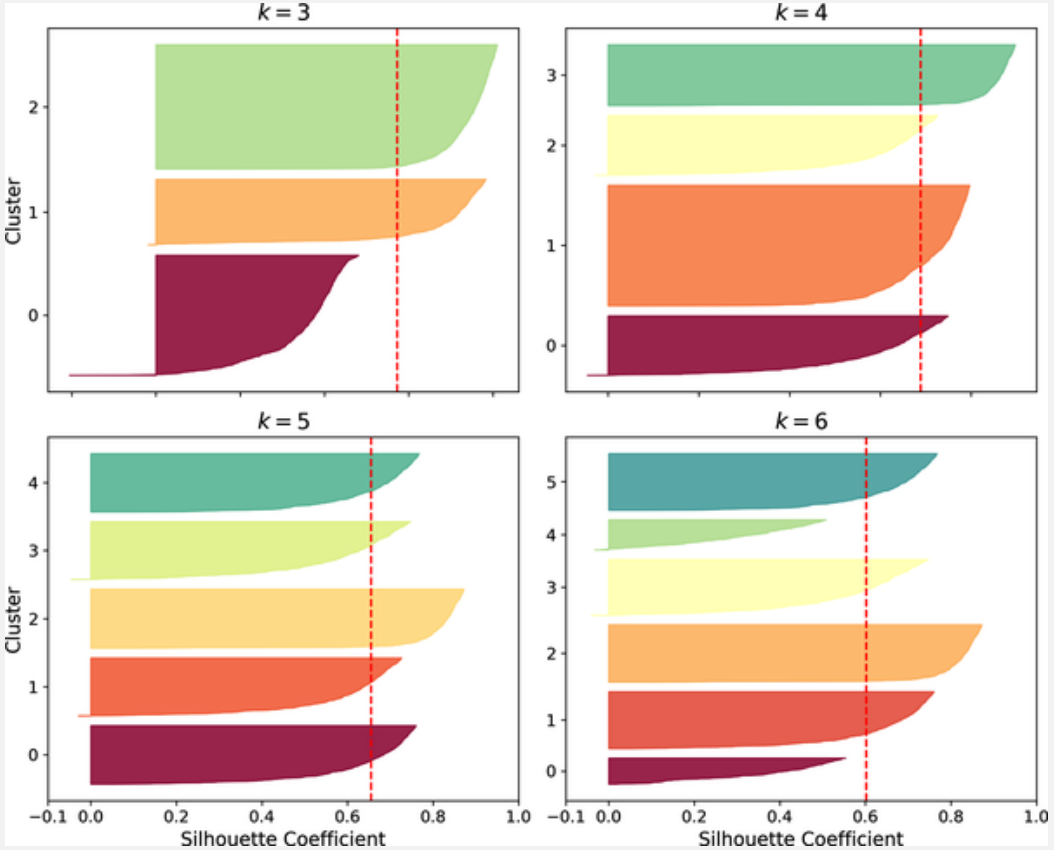
$$cs_{agrupación} = \frac{1}{N}\sum_{i=1}^{N} cs(\boldsymbol{x}_i)$$

Este promedio está limitado al rango [-1 y 1]:

- Cuando el valor está cercano a 1, sugiere grupos compactos y separados.
- Un valor cercano a -1 nos da idea de una agrupación incorrecta (mala asignación a un grupo), ya que es evidencia de que los datos están más cercanos a los puntos de otros grupos.
- Los valores cercanos a cero indican que los grupos se solapan (datos en el límite entre grupos).

Evaluación de modelos de agrupación





Análisis de coeficientes de silueta para varios valores de K

Índice de Davies-Bouldin

Mide el radio de similitud de cada cluster con su cluster más similar. Valores bajos indican mayor Calidad (<1).

$$db(\boldsymbol{x}) = \frac{1}{k}\sum_{i=1}^{k} \max\left\{\frac{d_{intra}(\boldsymbol{x_i}) + d_{intra}(\boldsymbol{x_j})}{d_{inter}(\boldsymbol{x_i}, \boldsymbol{x_j})}\right\}$$

Donde

$d_{intra}(x) = \ distancia\ promedio\ mínima\ de\ \boldsymbol{x}\ a\ los\ puntos\ del\ grupo\ más\ cercano.$

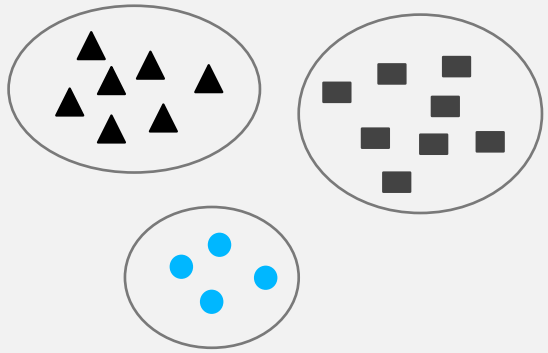
$d_{inter}(a, b) = \ distancia\ intercluster\ entre\ los\ grupos\ a\ y\ b.$

Evaluación de modelos de agrupación

Métodos extrínsecos: utiliza el conocimiento experto de manera implícita, a través de un conjunto datos etiquetados. Estas etiquetas representan la "verdad o realidad fundamental" (*ground truth)* del problema.

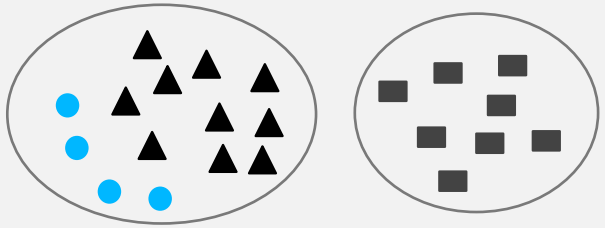
Las etiquetas indican las clases a la que pertenecen los objetos del conjunto de datos y son utilizadas de manera explícita en métricas que determinan el grado al cual datos que son de la misma clase están incluidos en el mismo grupo, es decir, el "acuerdo" en las asignaciones de los datos a los grupos y el *ground truth*.

$$V_{score} = 2 \times \frac{homogeneidad \times completitud}{homogeneidad + completitud}$$



La **homogeneidad** indica si los grupos solo contienen datos de una sola clase. Representa la "pureza" de la agrupación.

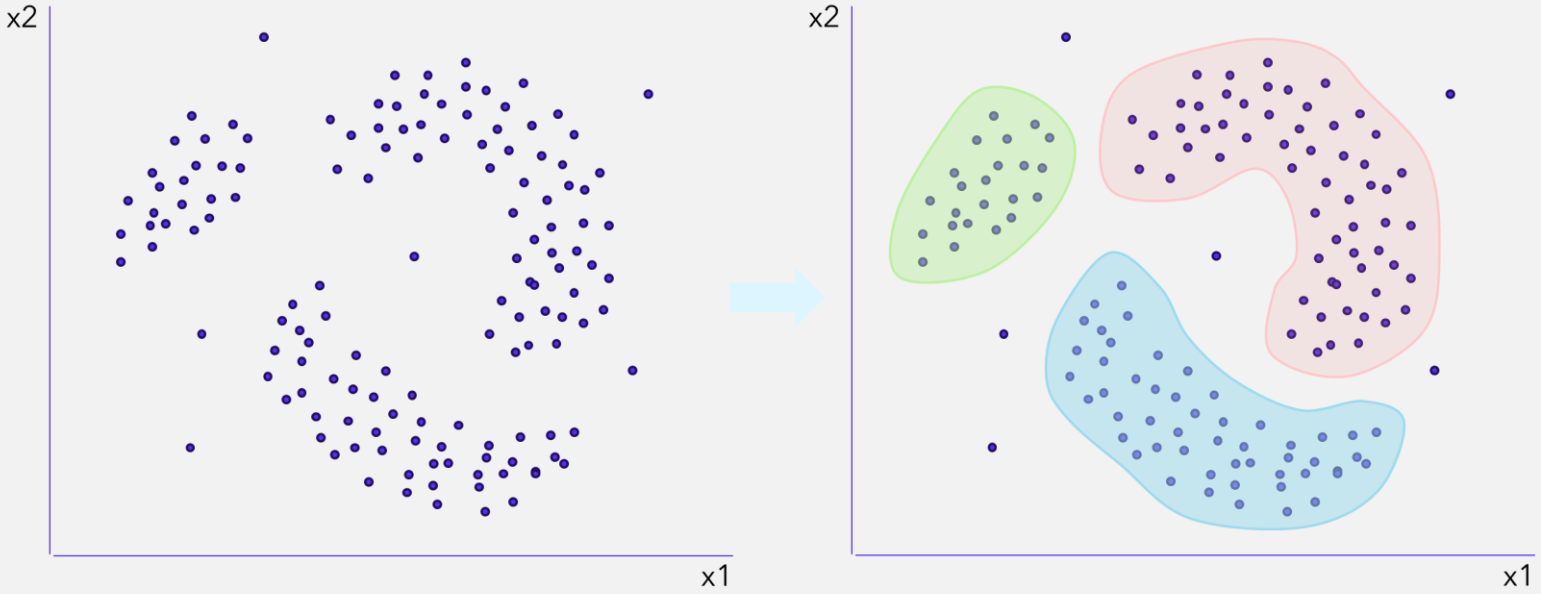
Esta medida toma valores en el intervalo [0, 1]. Valores cercanos a 1 indican que tanto la homogeneidad como la completitud están también próximos a 1, significando una buena agrupación.



La **completitud** nos dice si todos los datos de una clase fueron asignados al mismo grupo.

Algoritmos basados en densidad

- El Criterio de división son grupos al mismo nivel.
- Estos algoritmos encuentran grupos exclusivos, basados en la densidad de instancias.
- Las medidas de similitud están basados en la contigüidad.
- Los grupos pueden tener formas irregulares.



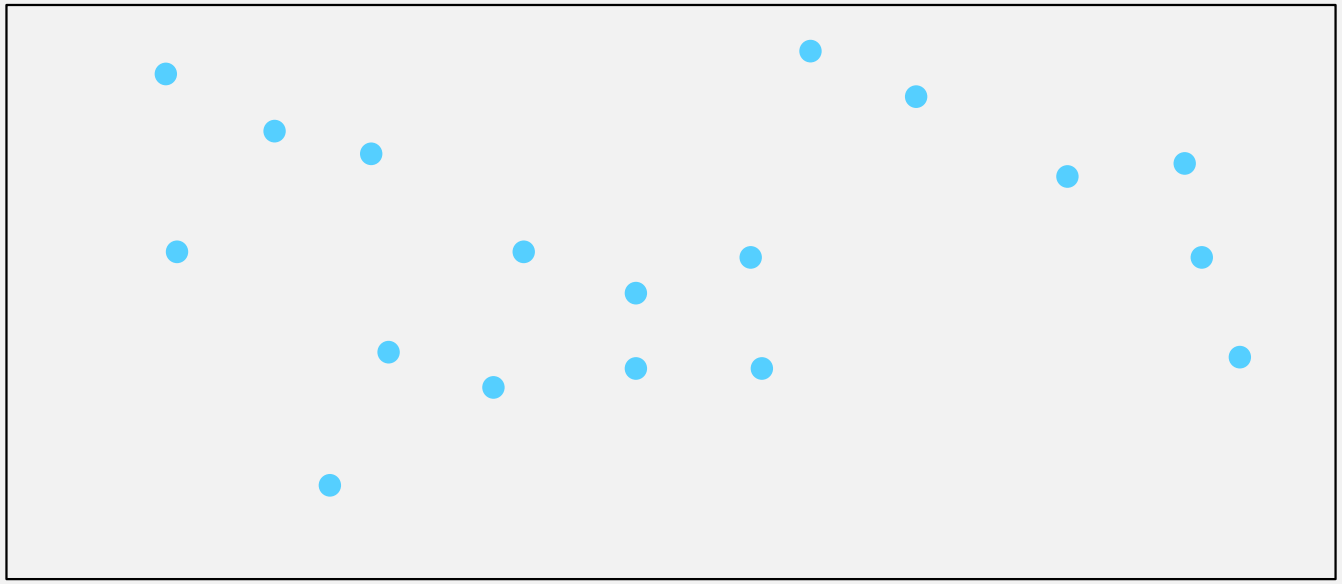
Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In Kdd, Vol. 96, Nº34, pp. 226–231.

DBScan

1. Para cada instancia, cuente cuantas otras instancias están localizadas a una distancia **ε** de la misma. (**ε-vecindario**)
2. Si la instancia tiene un mínimo de muestras en su ε-vecindario, se considera **núcleo**.
3. Todas las instancias en el vecindario de una **instancia núcleo** hacen parte del mismo grupo.
4. Toda instancia que no es núcleo y no está en un vecindario, es una **anomalía**.

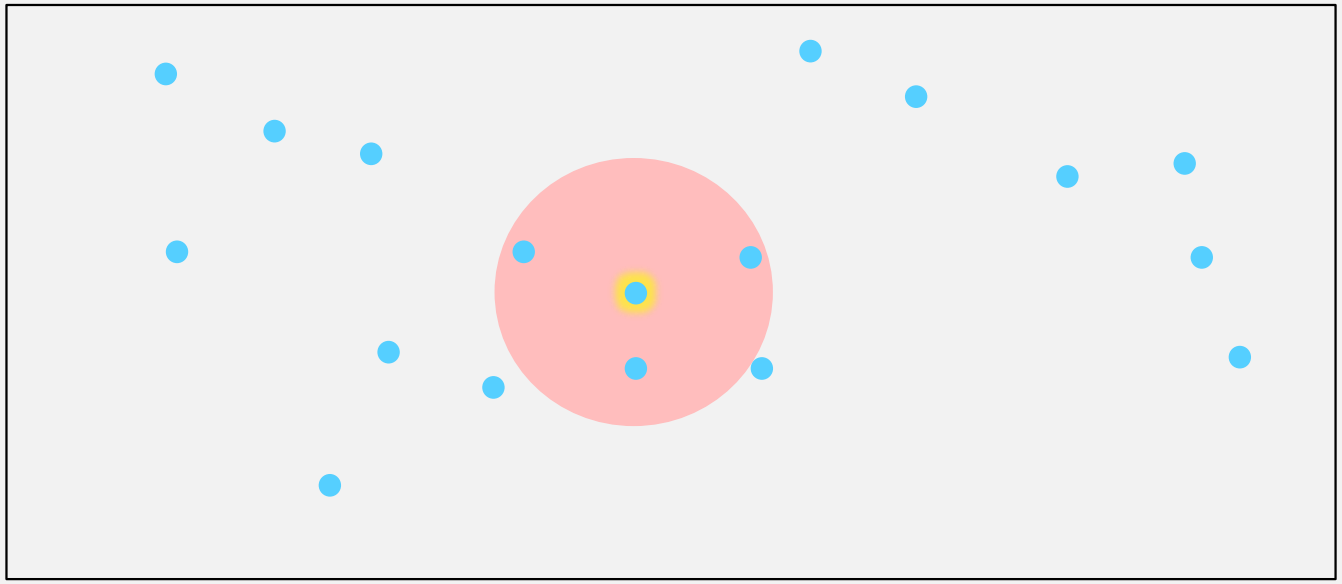
- **Objetos núcleo**: datos que en su vecindad tienen al menos minObj (min_points/min_samples))como vecinos (A).
- **Objetos borde**: datos que no tienen en su vecindad minObj (min_points/min_samples), pero están en la vecindad de un objeto núcleo (B).
- **Anomalías**: no cumplen con alguna de las condiciones anteriores (C).

DBScan



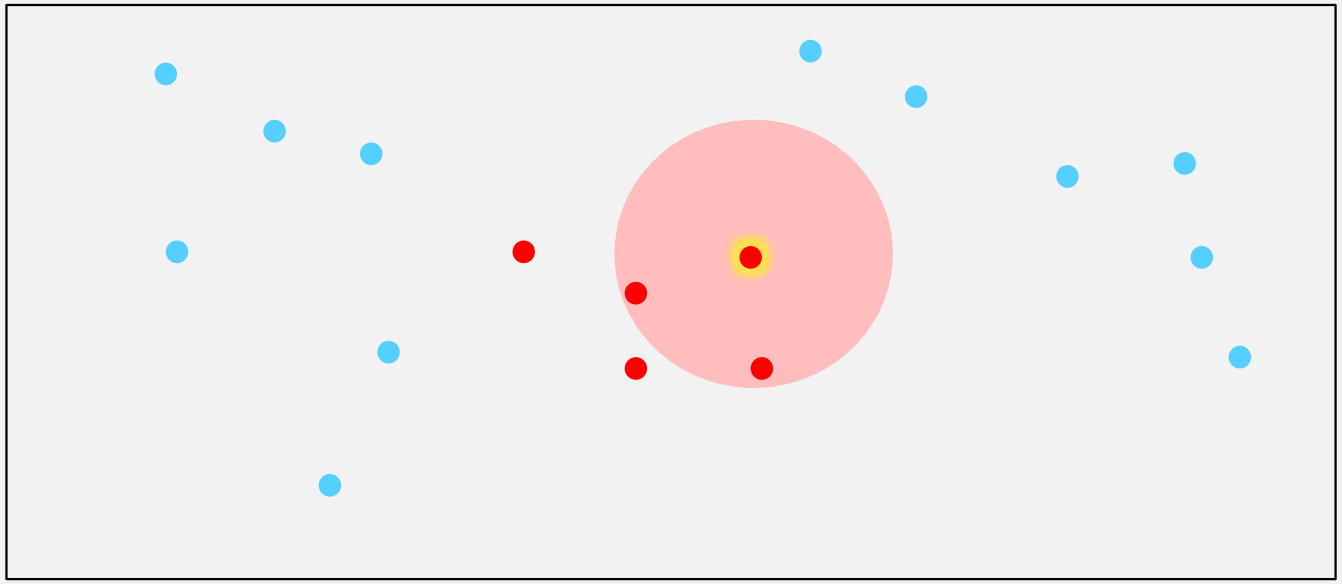
Mínimo de muestras: 2

DBScan



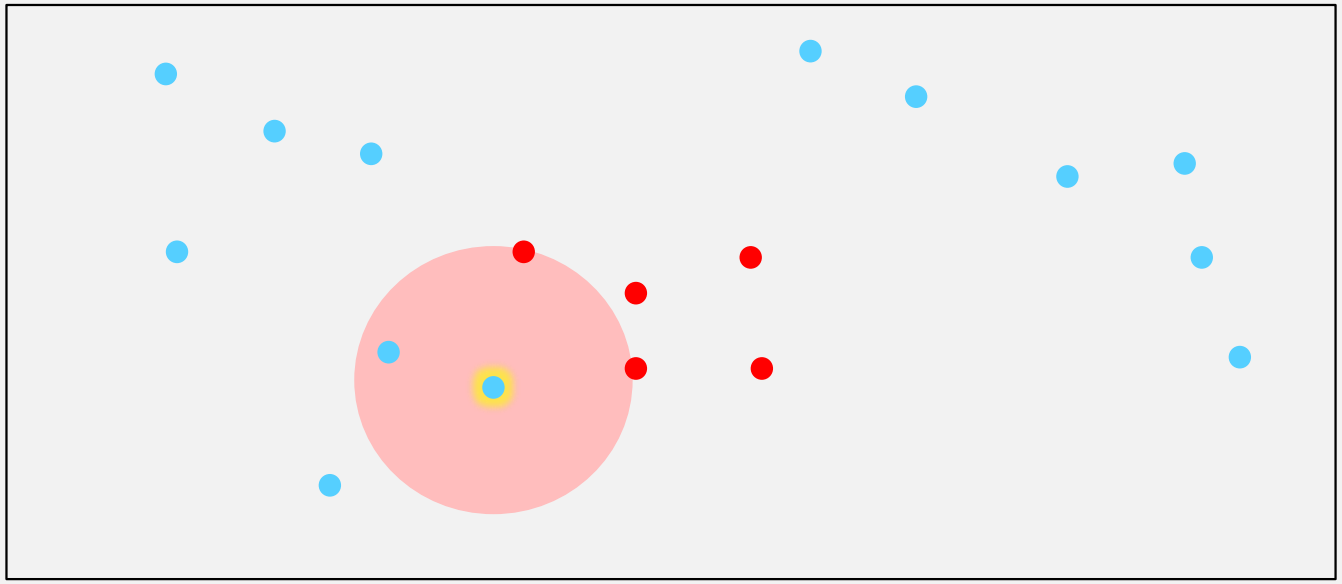
Mínimo de muestras: 2

DBScan



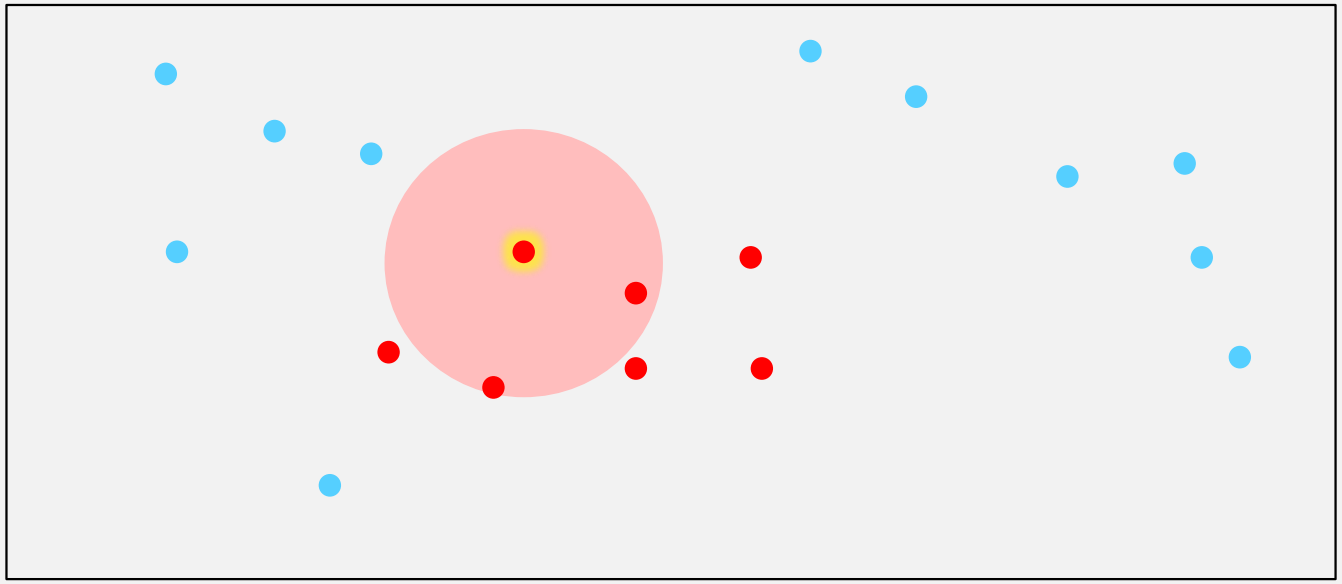
Mínimo de muestras: 2

DBScan



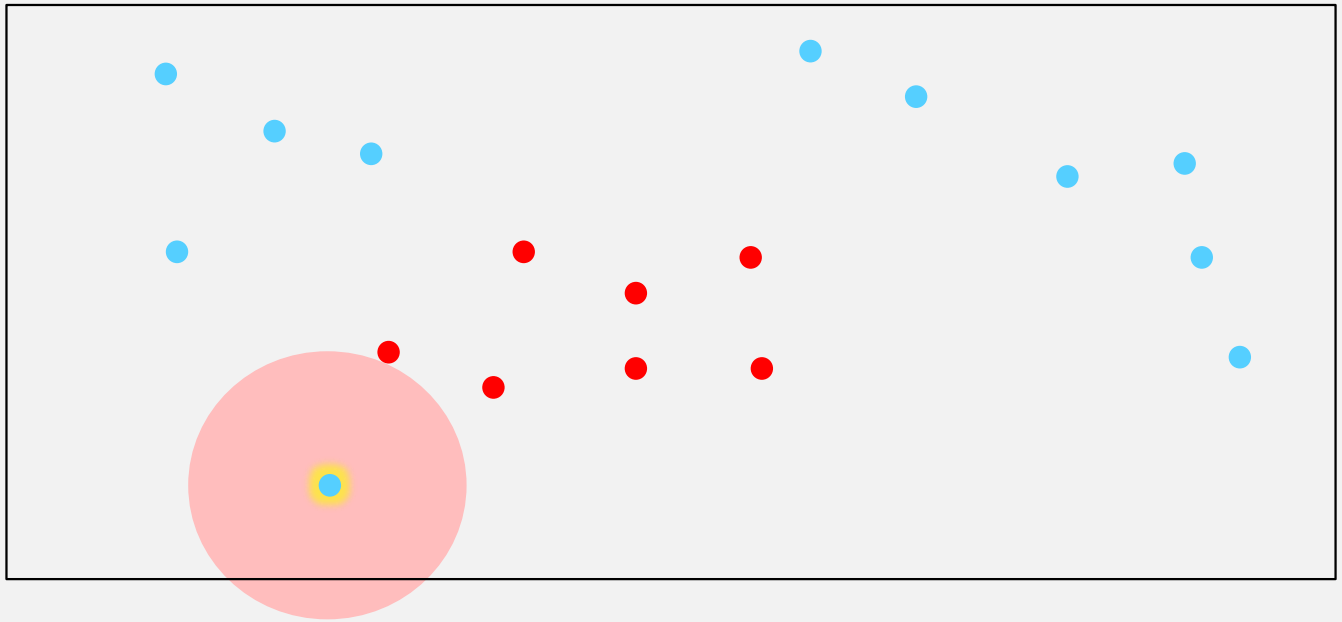
Mínimo de muestras: 2

DBScan



Mínimo de muestras: 2

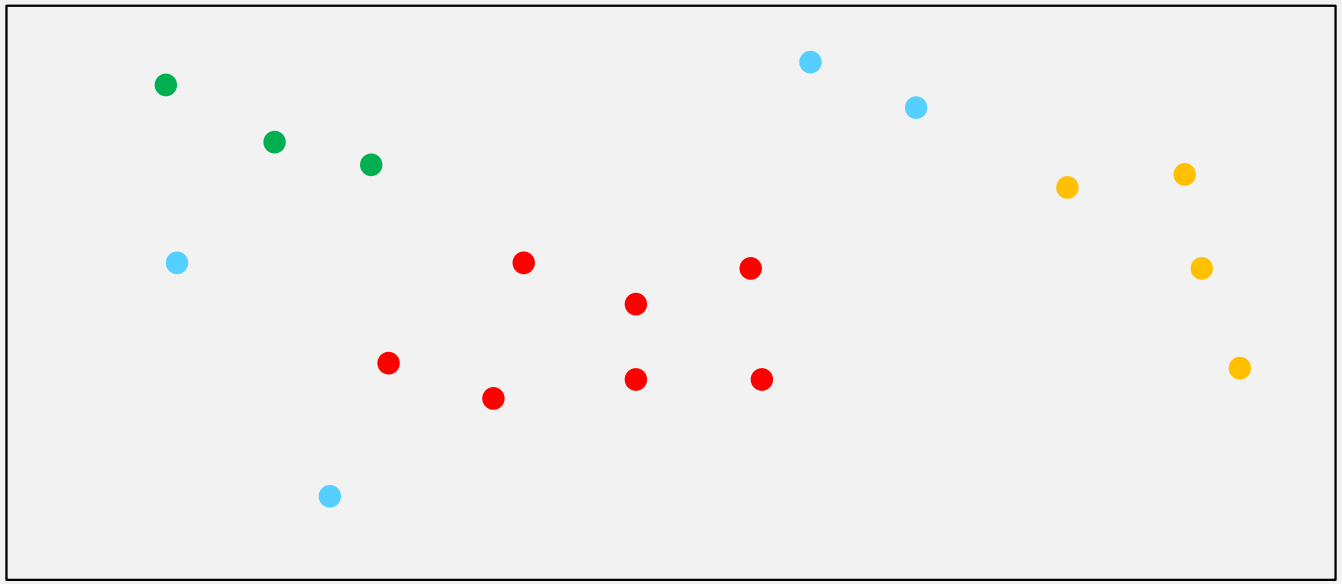
DBScan



Mínimo de muestras: 2


One
Eternity
Later

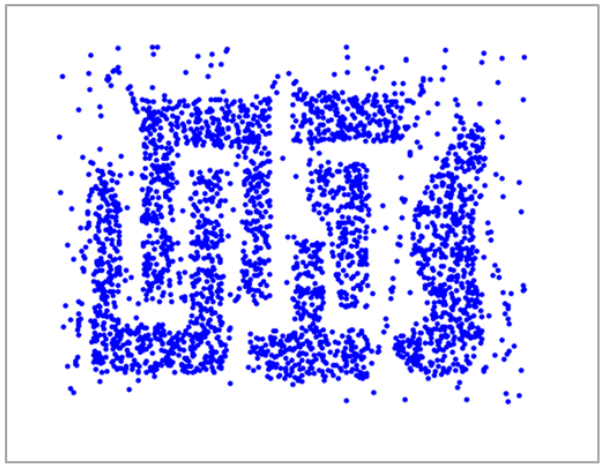
DBScan



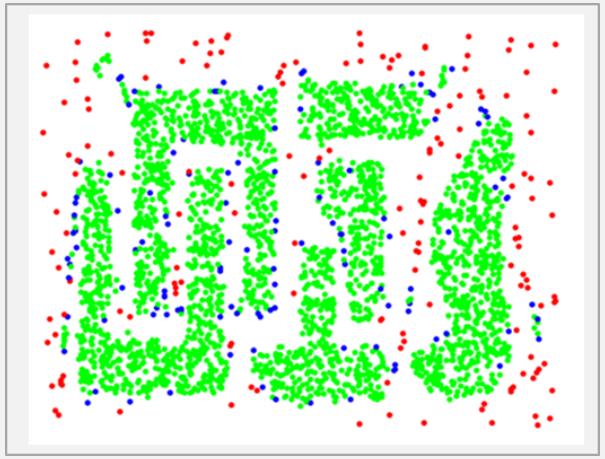
Mínimo de muestras: 2

DBScan

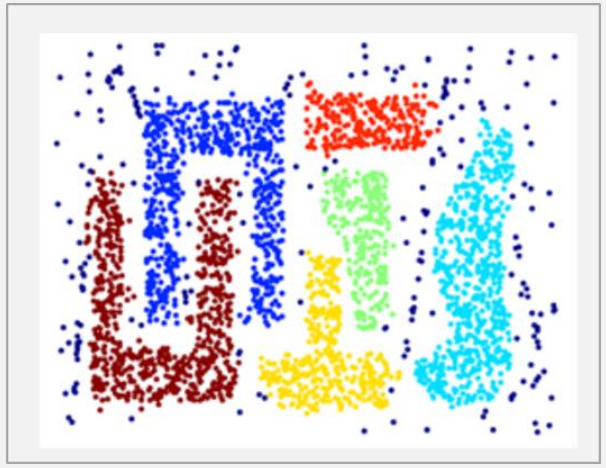
Conjunto de datos



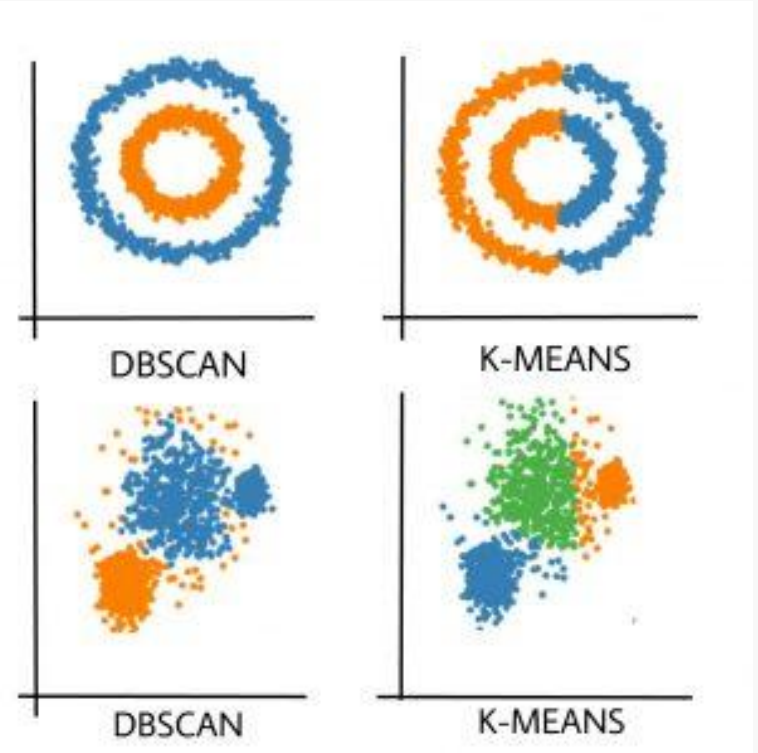
Tipos de datos: núcleo, borde y outlier



Grupos



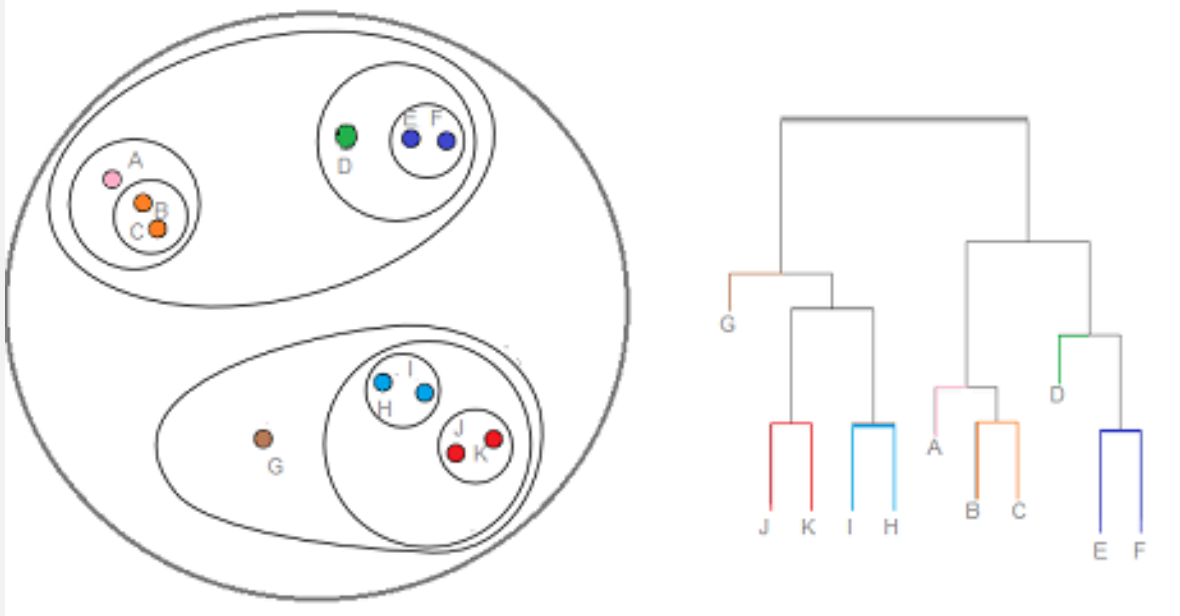
Comparación:



https://www.geeksforgeeks.org/dbscan-clustering-in-ml-density-based-clustering/

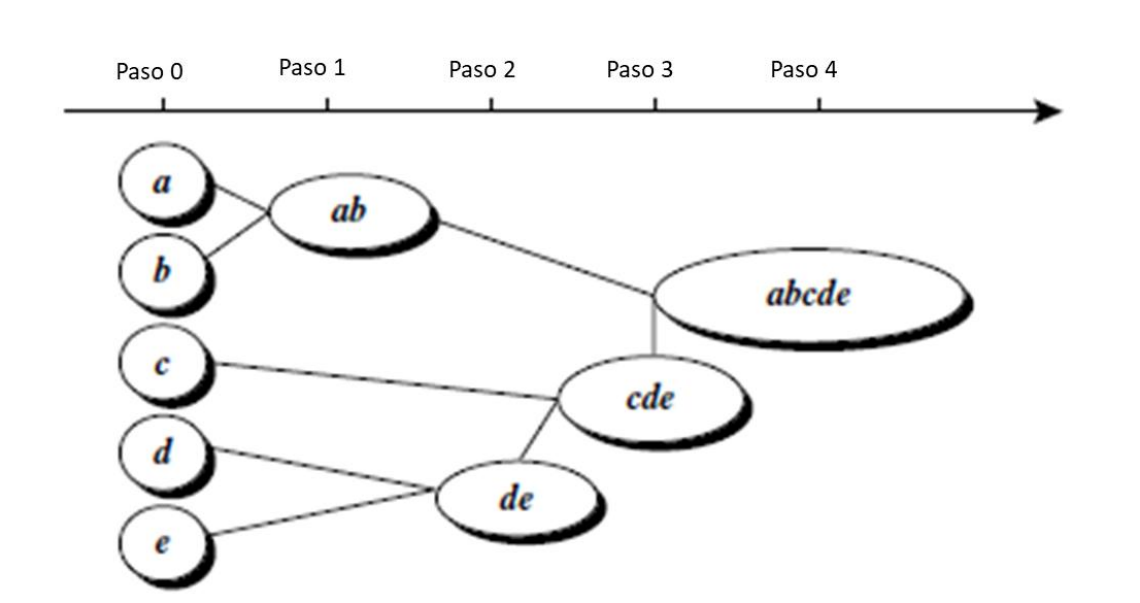
Algoritmos jerárquicos

- El criterio de división son grupos organizados en forma jerárquica.
- Se pueden obtener grupos solapados.
- La similitud se determina con medidas de distancia.
- Pueden ser visualizados a través de dendogramas.
- Hay dos variantes principales: aglomerativos y divisivos.



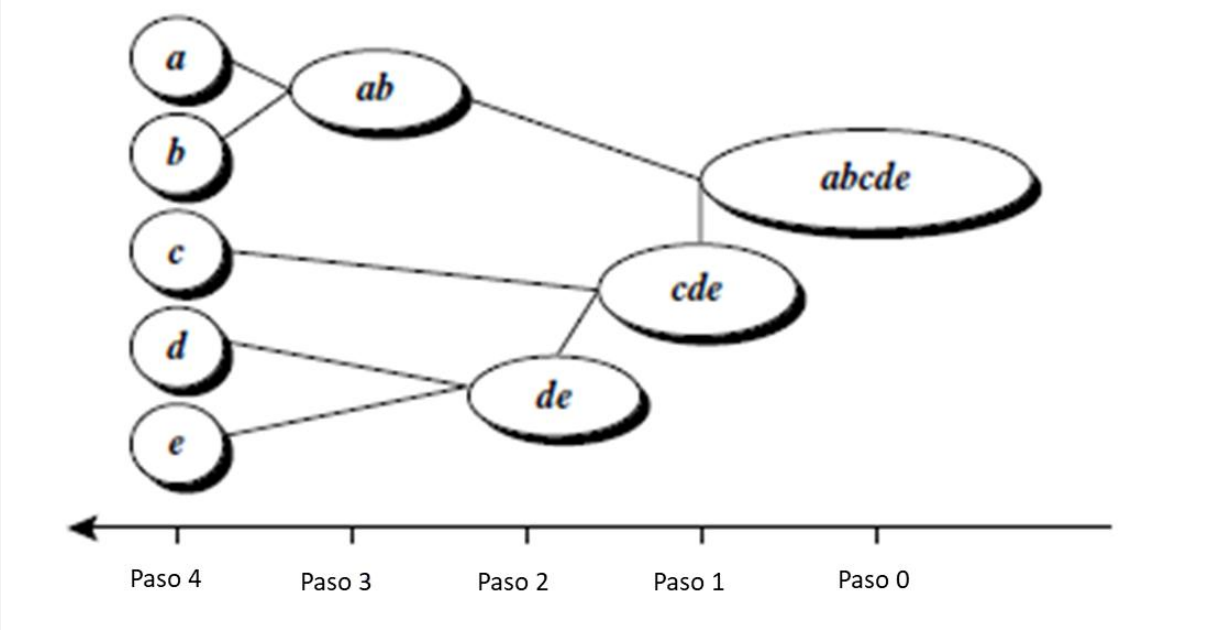
Algoritmos aglomerativos

- Esquema *bottom-up*.
- Inicialmente cada dato es considerado un grupo.
- En cada iteración, se une el par de grupos más cercanos.
- Finaliza cuando sólo queda un grupo (raíz, con todos los datos) o cuando se haya alcanzado alguna otra condición de parada, como el número de grupos a determinar (especificado por el usuario).

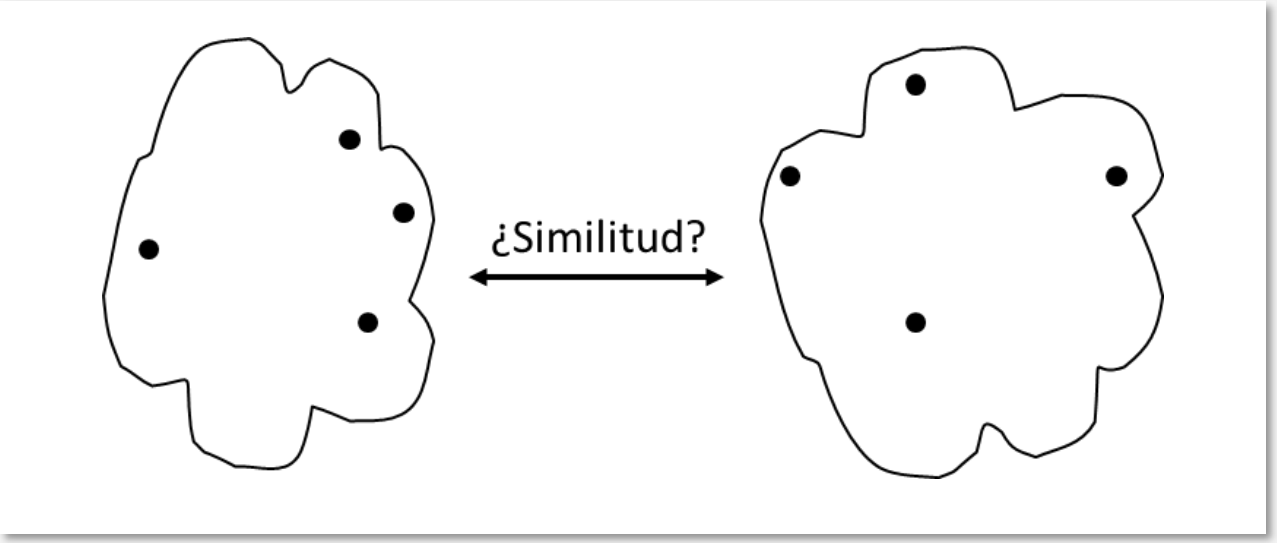


Algoritmos divisivos

- Esquema top-down.
- Inicialmente todo el conjunto de datos es un grupo (raíz).
- En cada iteración, se divide un grupo.
- Finaliza cuando cada grupo contiene un solo dato o se haya alcanzado alguna otra condición de parada, como el número de grupos a determinar (especificado por el usuario).



Similitud entre grupos



- $distancia\ mínima \rightarrow dist_{min}(G_i, G_j) = \min_{x \in G_i, x' \in G_j} dist(x, x')$
- $distancia\ máxima \rightarrow dist_{max}(G_i, G_j) = \max_{x \in G_i, x' \in G_j} dist(x, x')$
- $distancia\ media \rightarrow dist_{media}(G_i, G_j) = dist(c_i, c_j)$
- $distancia\ promedio \rightarrow dist_{promedio}(G_i, G_j) = \frac{1}{n_i n_j} \sum_{x \in G_i, x' \in G_j} dist(x, x')$

Estas medidas de similitud son conocidas también como **medidas de enlace**

¿Preguntas?