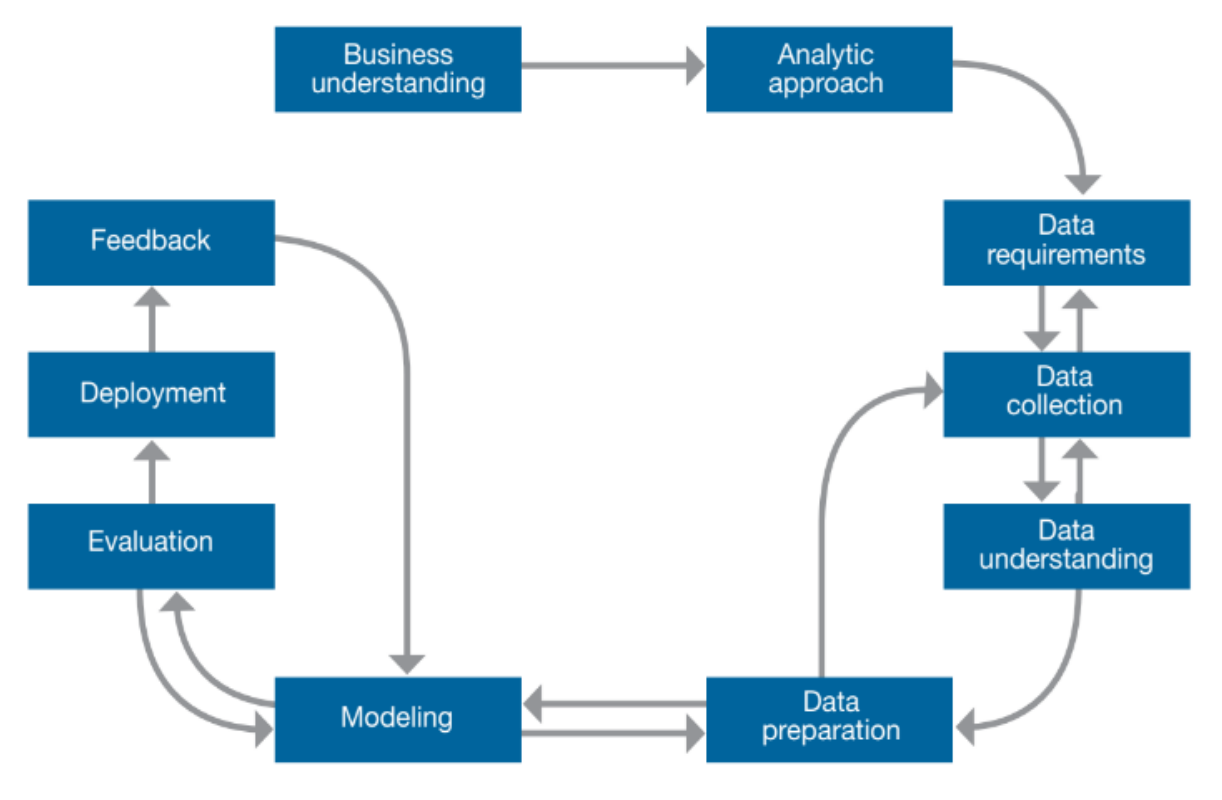
MINE4101-Ciencia de Datos Aplicada



Fundamentos de modelos comunes de aprendizaje supervisado

Reconocimiento como Universidad: Decreto 1297 del 30 de mayo de 1964.
Reconocimiento personería jurídica: Resolución 28 del 23 de febrero de 1949 Minjusticia

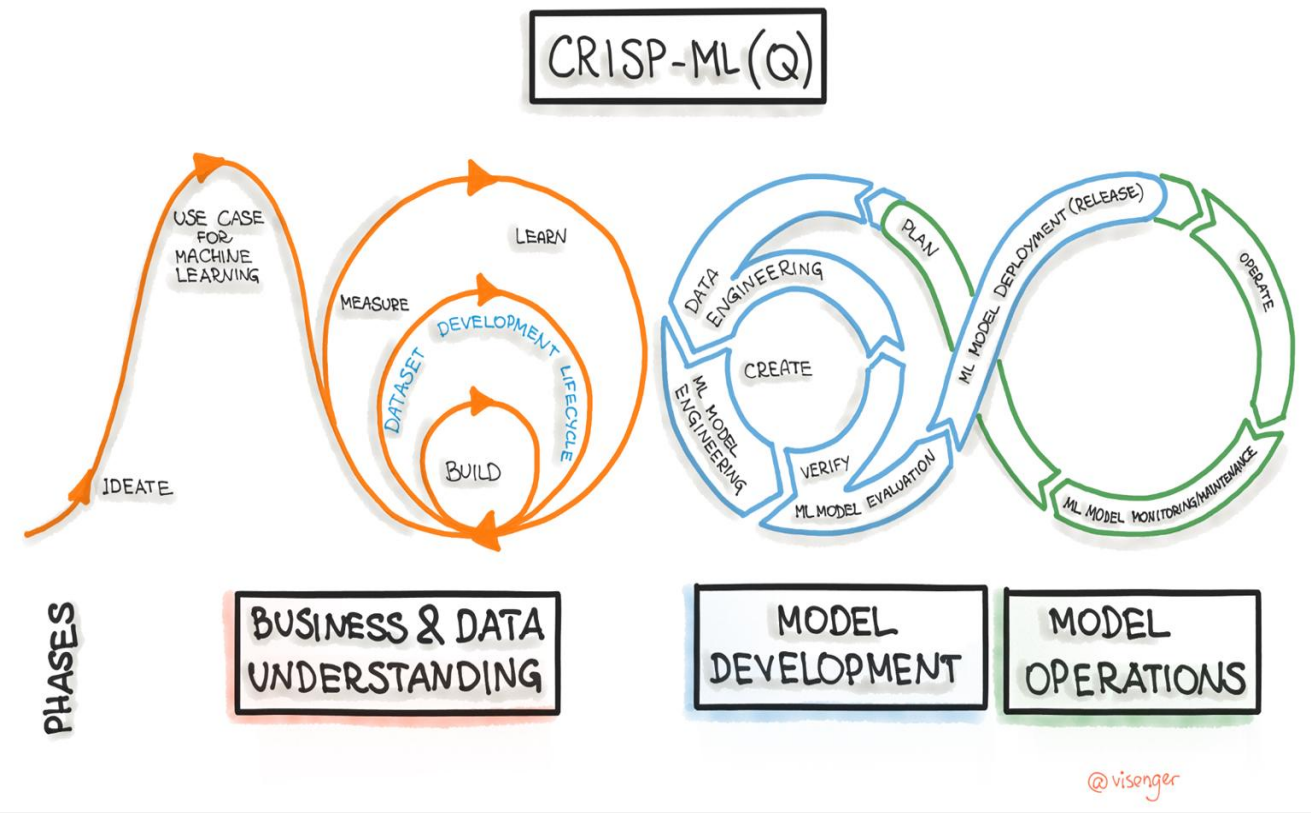
¿Cómo se lleva a cabo un proyecto de analítica?



Analytics Solution Unified Method for Data Mining / Predictive Analytics

ASUM-DM

¿Cómo se lleva a cabo un proyecto de analítica?



Cross-Industry Standard Process for the development of Machine Learning

CRISP-ML

Definiciones

*"The field of study that gives computers the ability to learn **without being explicitly programmed**."*

Arthur Samuel

*"A computer program is said to learn from **experience** E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E."*

Tom Mitchell

Ejemplo: Jugando al ajedrez

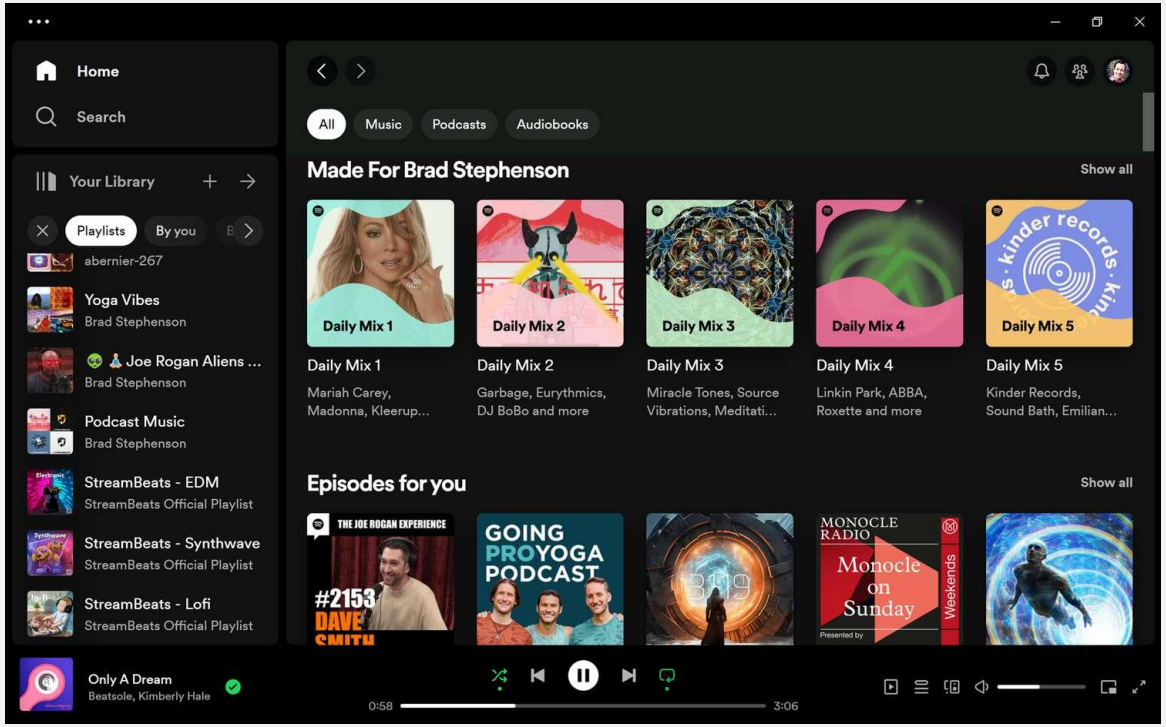


Task (T)
Jugar ajedrez, decidir el siguiente movimiento

Experience (E)
Muchos juegos de ajedrez pasados

Performance (P)
Cantidad de movimientos restantes para ganar

Ejemplo: Reconocimiento de gustos musicales



Task (T)

Experience (E)

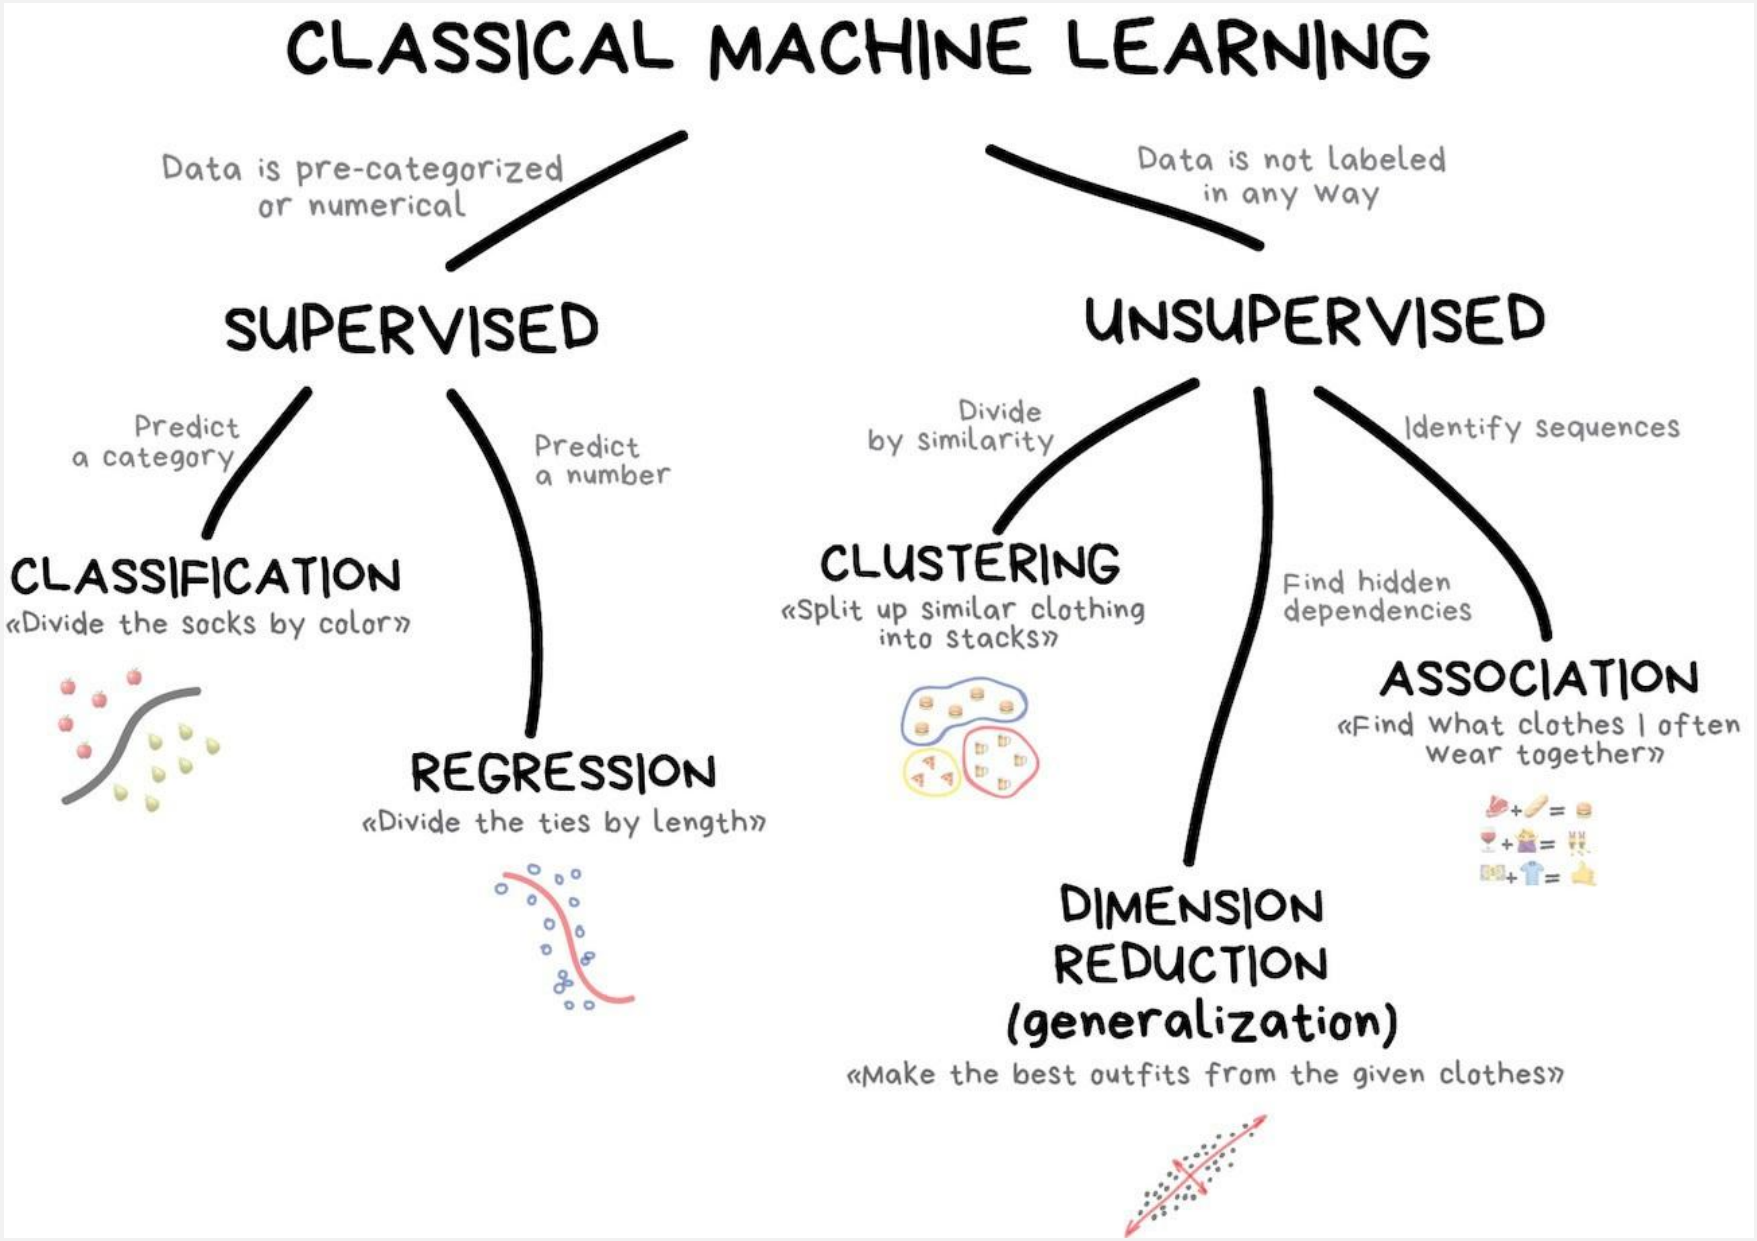
Performance (P)

¿Cuándo se usa?

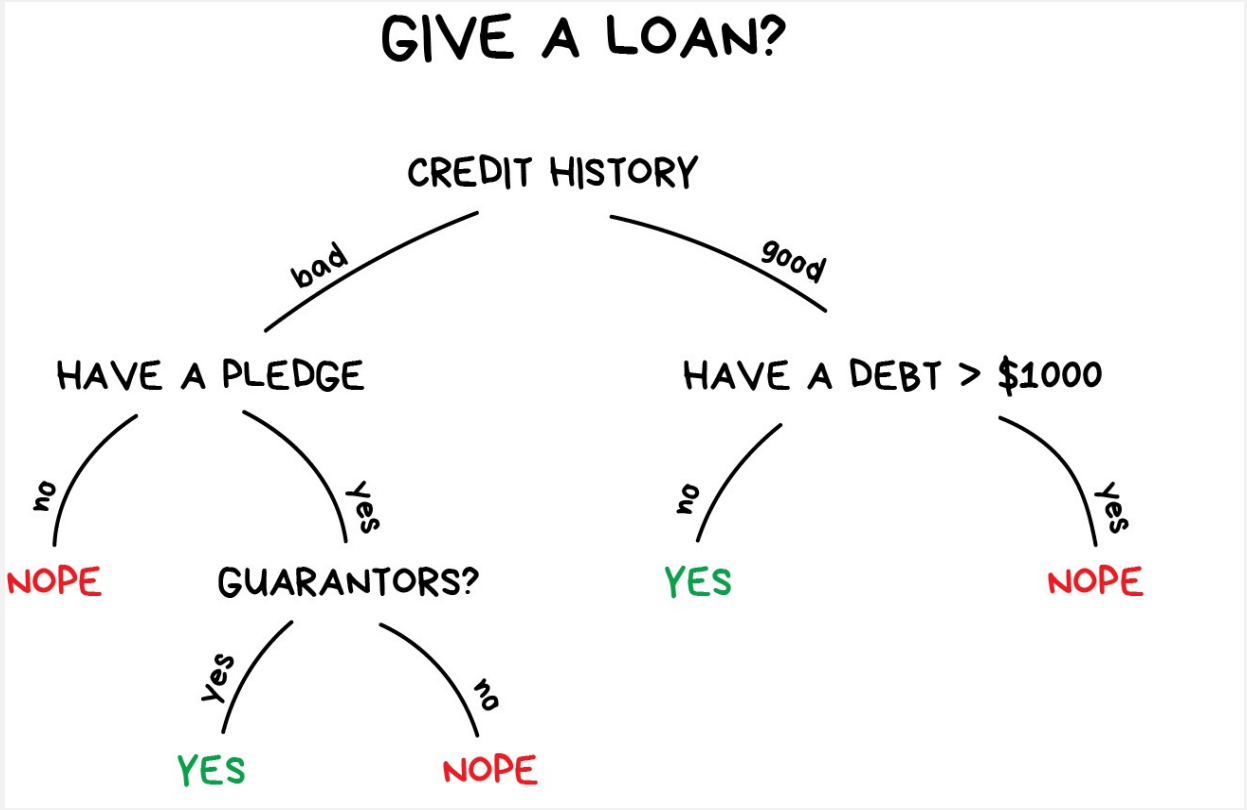


La **solución analítica** no es posible, por ende, no es **programable** directamente.

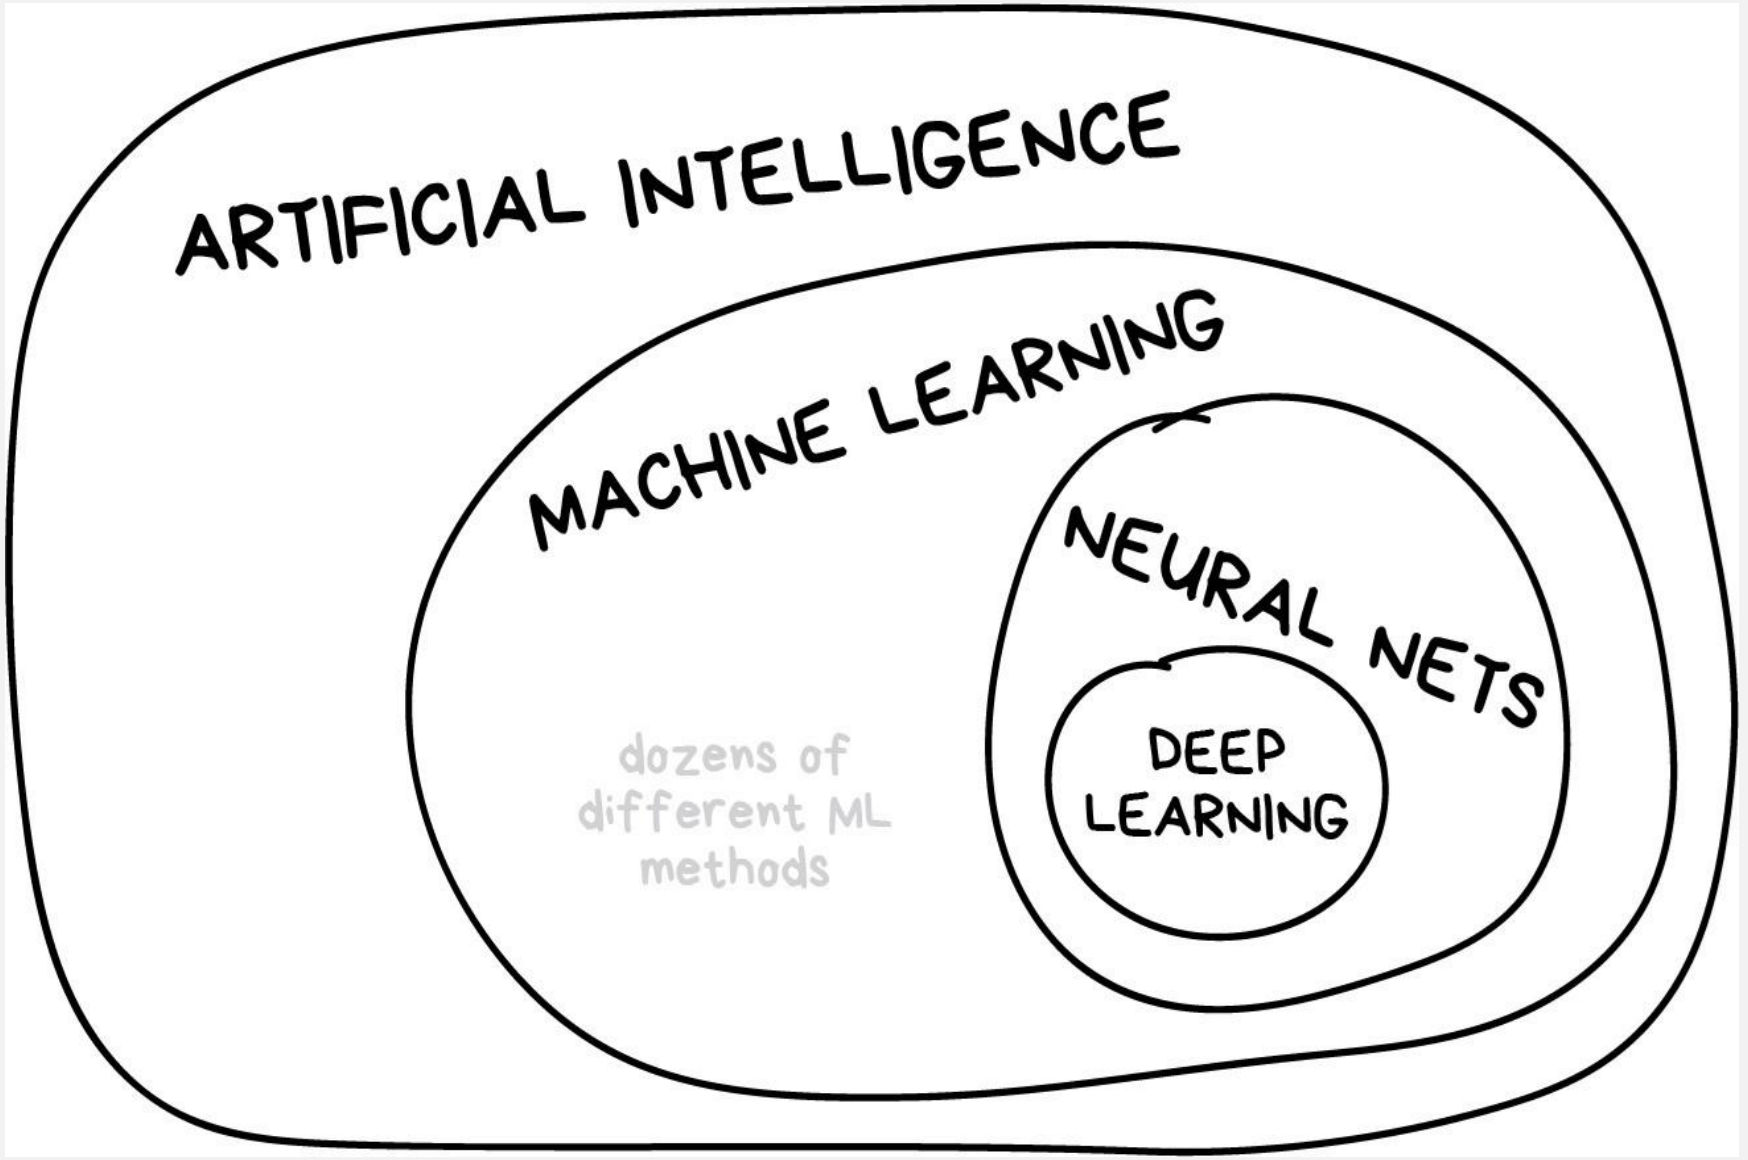
Es posible recolectar datos.

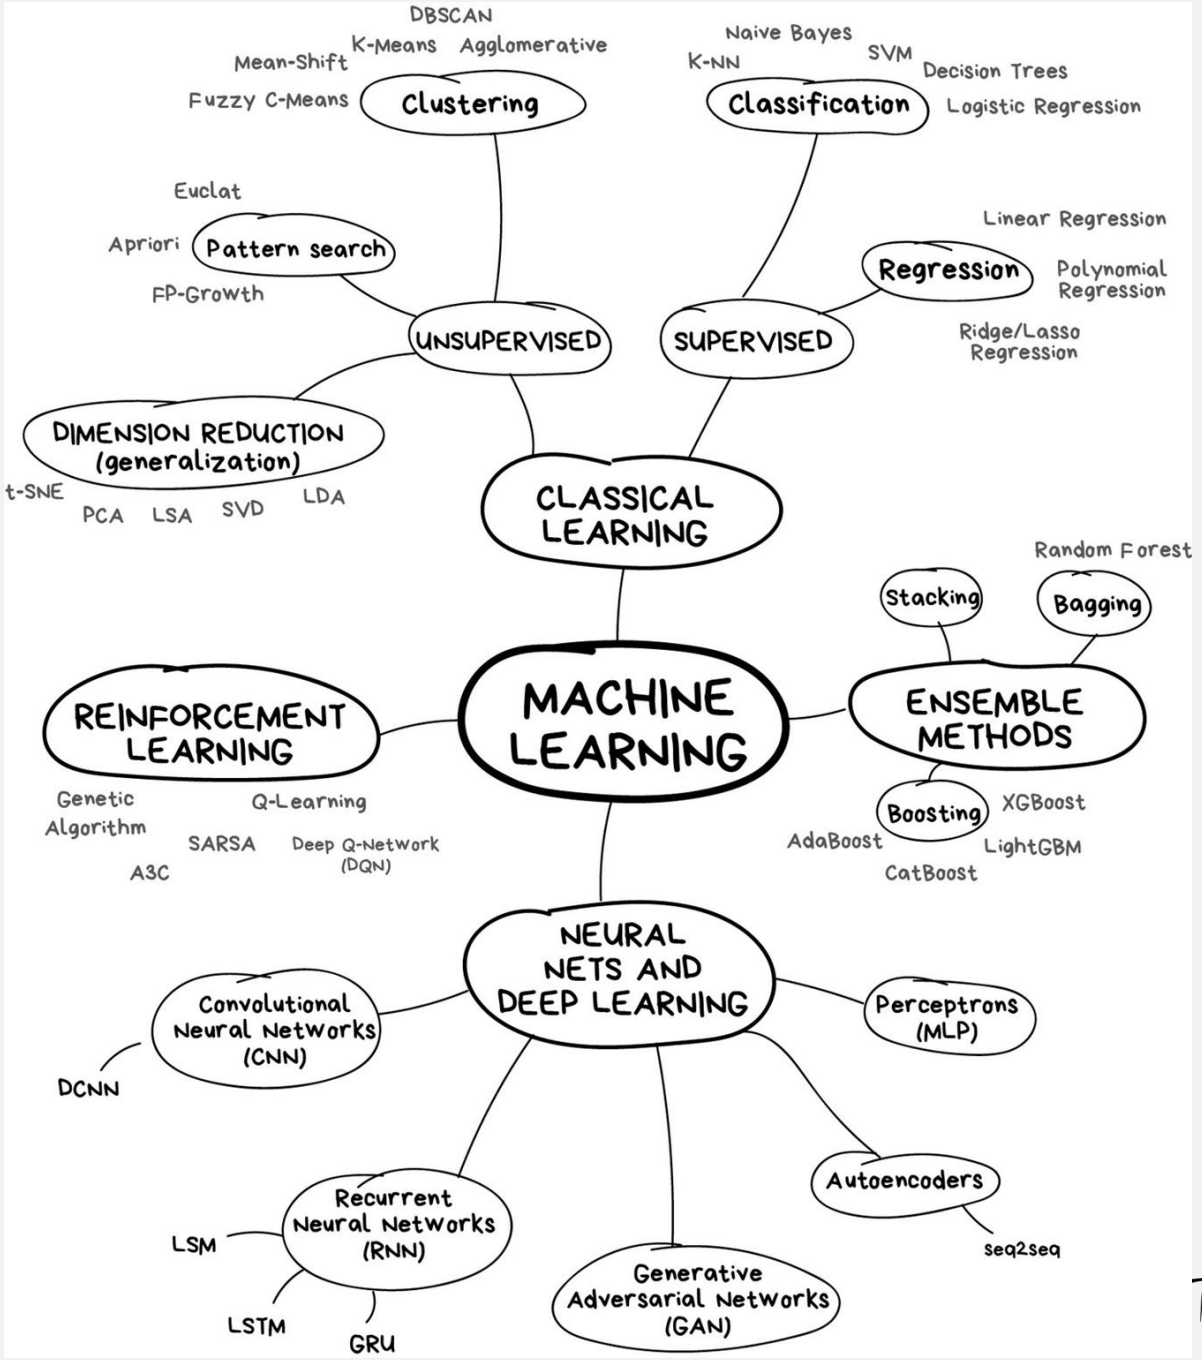

CLASSICAL MACHINE LEARNING
Data is pre-categorized or numerical
Data is not labeled in any way
SUPERVISED
UNSUPERVISED
Predict a category
Predict a number
Divide by similarity
Identify sequences
Find hidden dependencies
CLASSIFICATION
«Divide the socks by color»
REGRESSION
«Divide the ties by length»
CLUSTERING
«Split up similar clothing into stacks»
ASSOCIATION
«Find what clothes I often wear together»
DIMENSION REDUCTION (generalization)
«Make the best outfits from the given clothes»

Aprendizaje supervisado



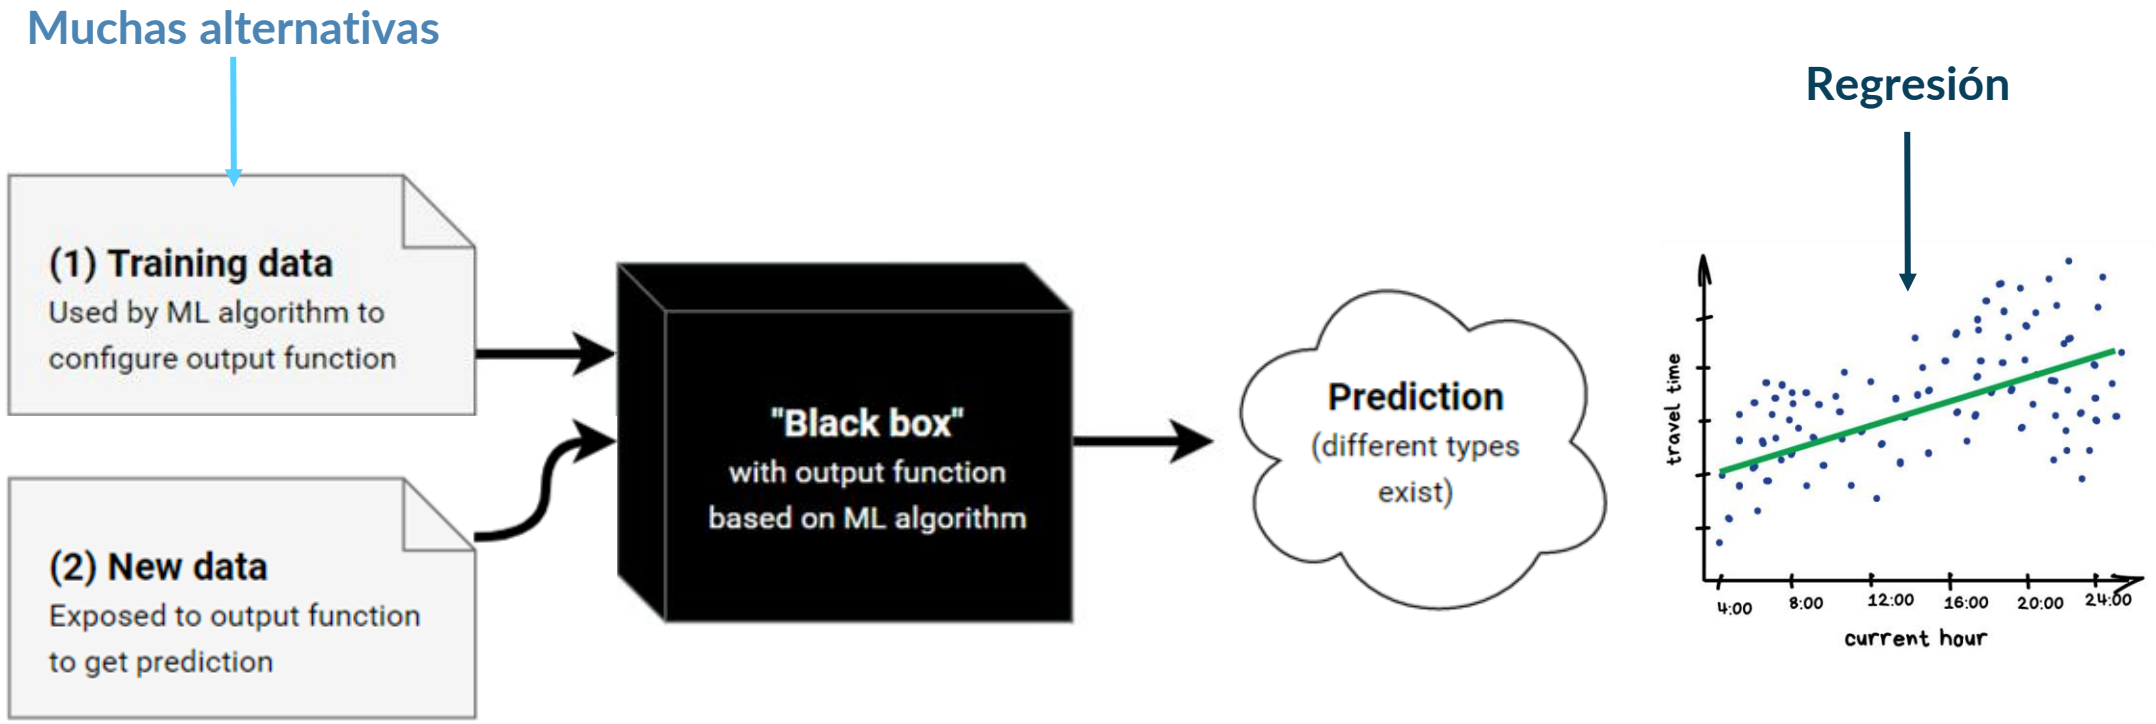
Dado un conjunto de **instancias** con **atributos** y una **etiqueta**, encontrar el conjunto de **patrones** que permiten discriminar una clase de la otra.


ARTIFICIAL INTELLIGENCE
MACHINE LEARNING
NEURAL NETS
DEEP LEARNING
dozens of different ML methods

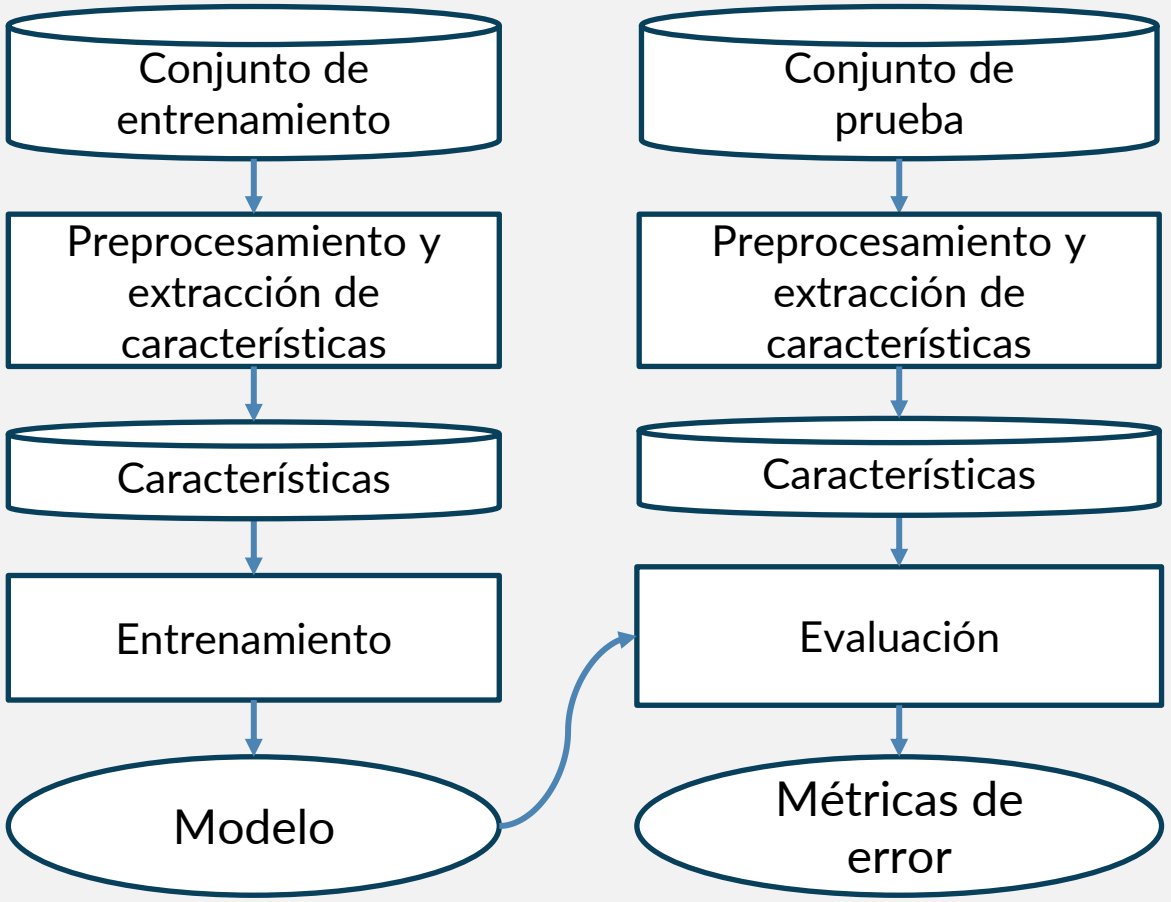

MACHINE LEARNING
CLASSICAL LEARNING
UNSUPERVISED
SUPERVISED
Clustering
DBSCAN
K-Means
Agglomerative
Mean-Shift
Fuzzy C-Means
Classification
Naive Bayes
K-NN
SVM
Decision Trees
Logistic Regression
Pattern search
Euclat
Apriori
FP-Growth
Regression
Linear Regression
Polynomial Regression
Ridge/Lasso Regression
DIMENSION REDUCTION (generalization)
t-SNE
PCA
LSA
SVD
LDA
REINFORCEMENT LEARNING
Genetic Algorithm
Q-Learning
SARSA
Deep Q-Network (DQN)
A3C
ENSEMBLE METHODS
Stacking
Bagging
Random Forest
Boosting
XGBoost
AdaBoost
LightGBM
CatBoost
NEURAL NETS AND DEEP LEARNING
Convolutional Neural Networks (CNN)
DCNN
Perceptrons (MLP)
Recurrent Neural Networks (RNN)
LSM
LSTM
GRU
Generative Adversarial Networks (GAN)
Autoencoders
seq2seq

Aprendizaje Supervisado: Regresión

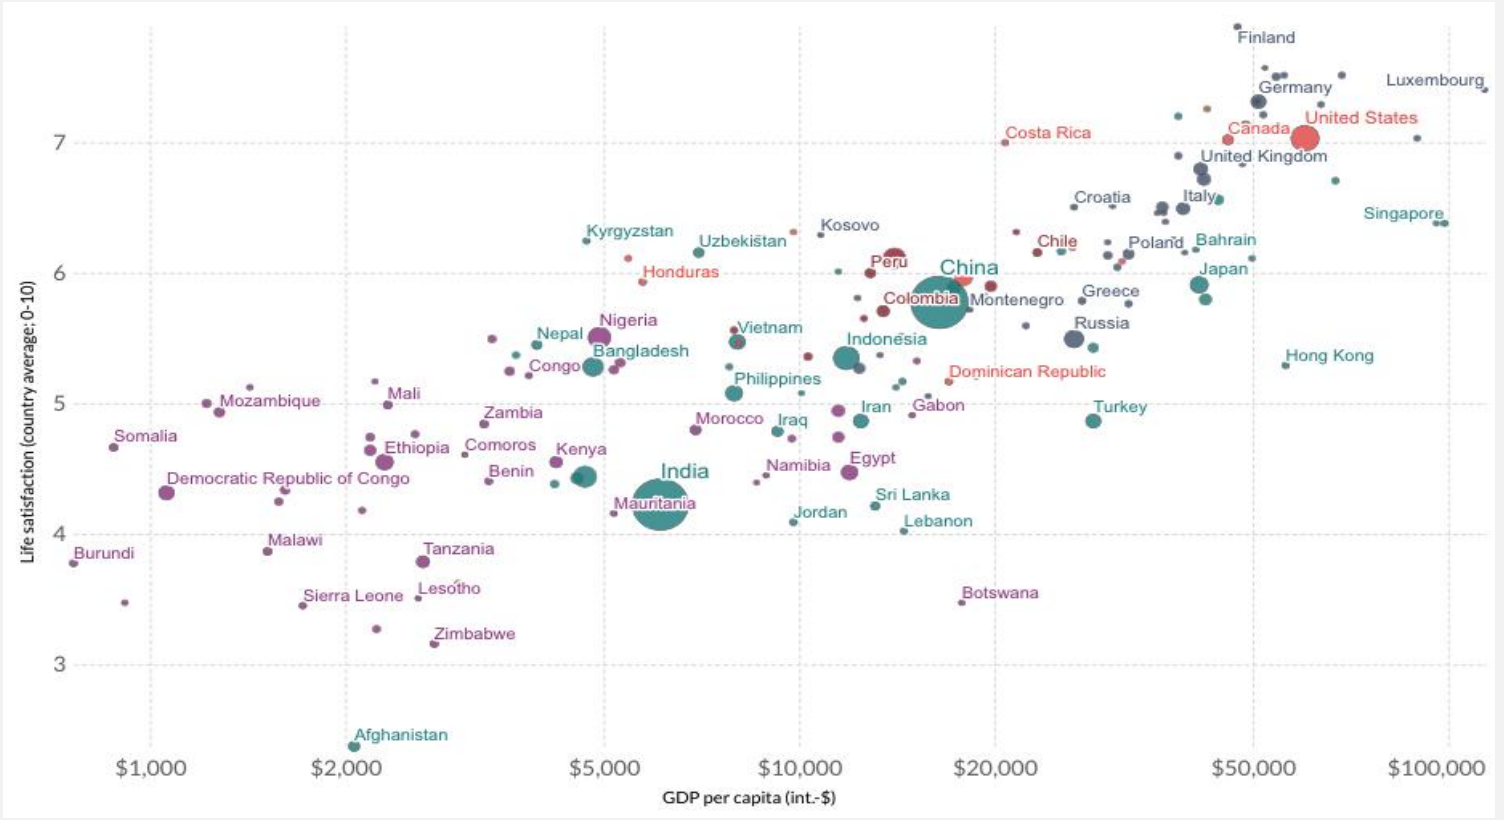
Esquema general de un modelo de Regresión



Esquema general de un modelo de Regresión



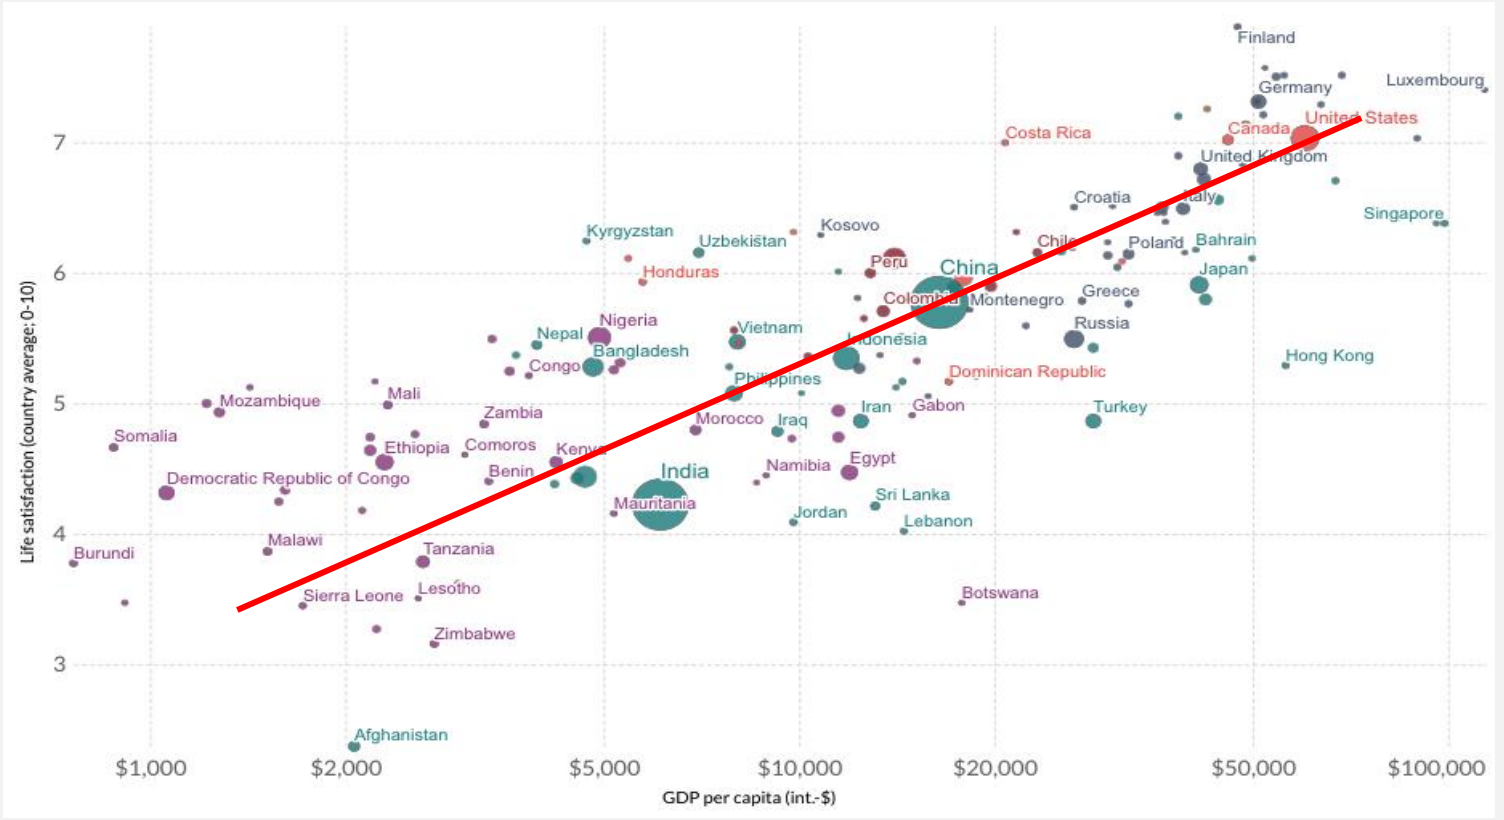
Tratando de estimar los mejores parámetros



$$life\ satifaction = \Theta_0 + \Theta_1 * GDP + \varepsilon$$

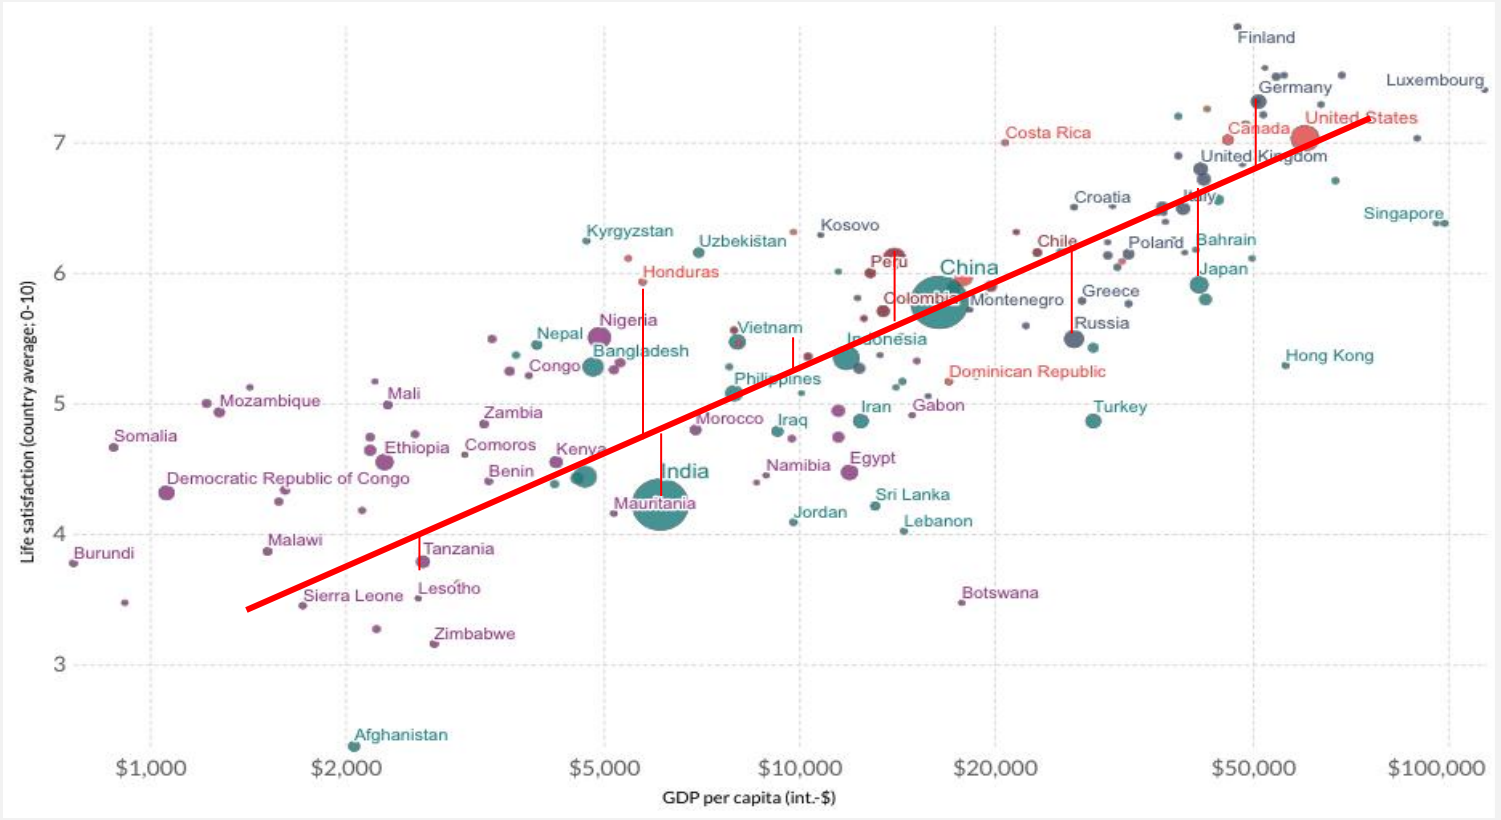
Parámetros o coeficientes del modelo

Tratando de estimar los mejores parámetros



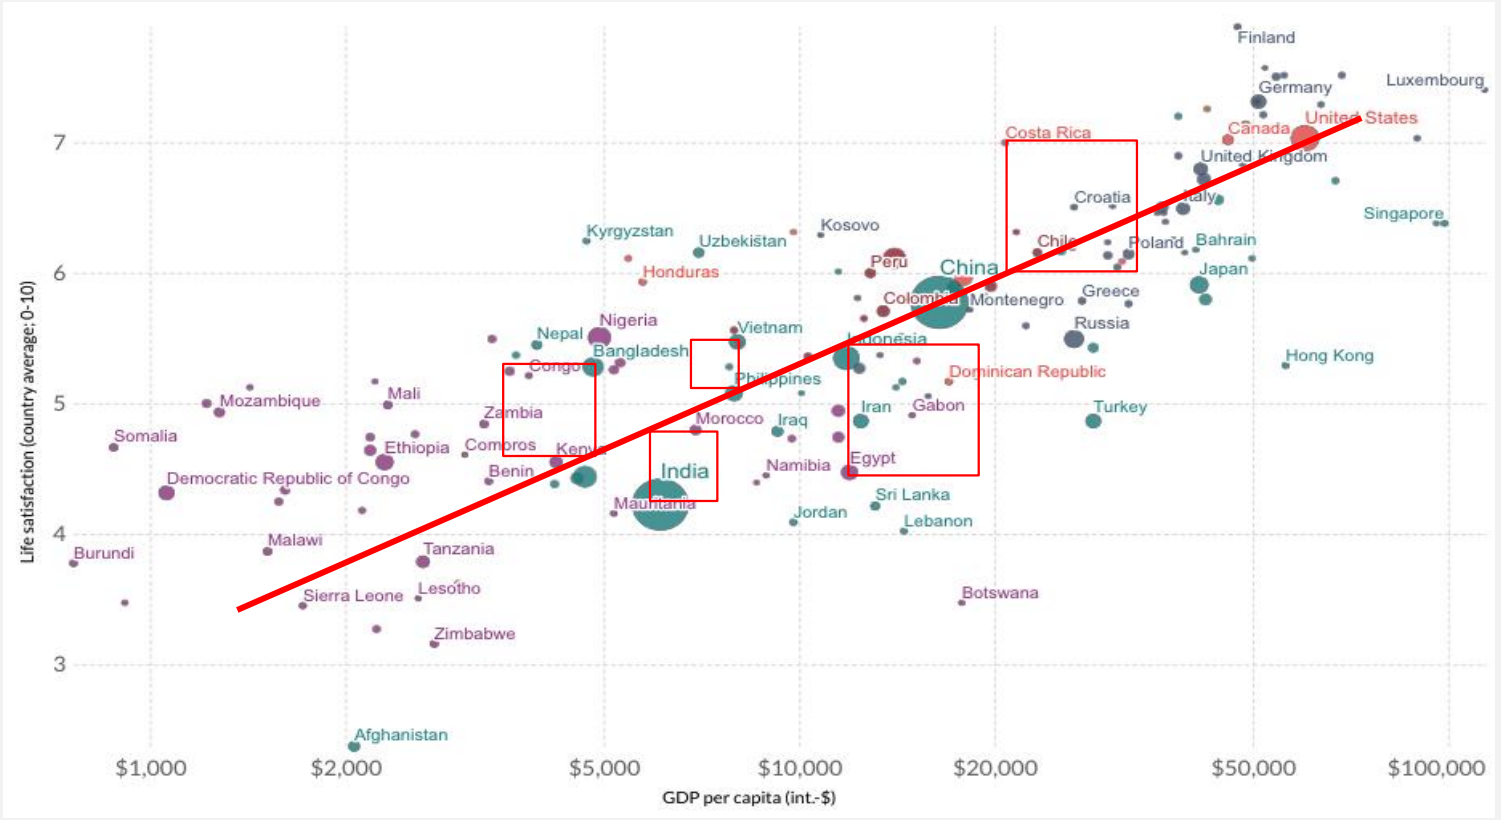
$$life\ satifaction = \Theta_0 + \Theta_1 * GDP + \varepsilon$$

Tratando de estimar los mejores parámetros



$$life\ satifaction = \Theta_0 + \Theta_1 * GDP + \varepsilon$$

Tratando de estimar los mejores parámetros



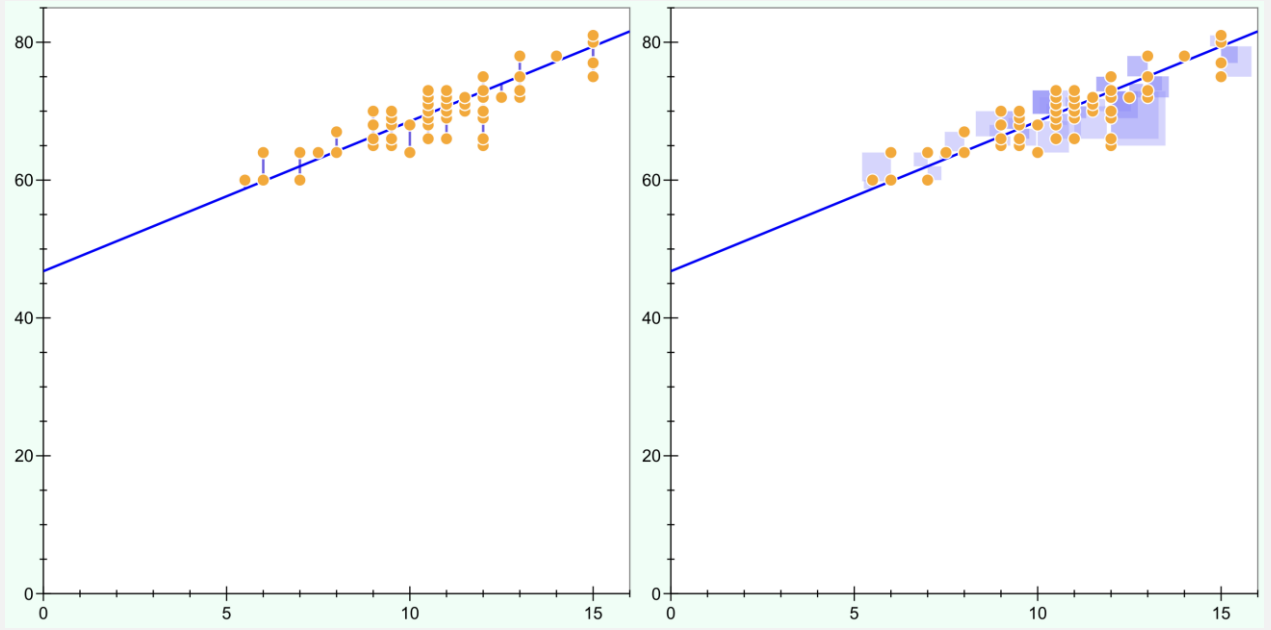
$$life\ satifaction = \Theta_0 + \Theta_1 * GDP + \varepsilon$$

¿Cómo medir el error ε?

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}|$$

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y})^2$$

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y})^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$$



$$life\ satifaction = \Theta_0 + \Theta_1 * GDP + \varepsilon$$

En donde:
$\hat{y}$ es el valor predicho de y
$\bar{y}$ es el valor medio de y

¿Cómo encontrar los mejores parámetros?

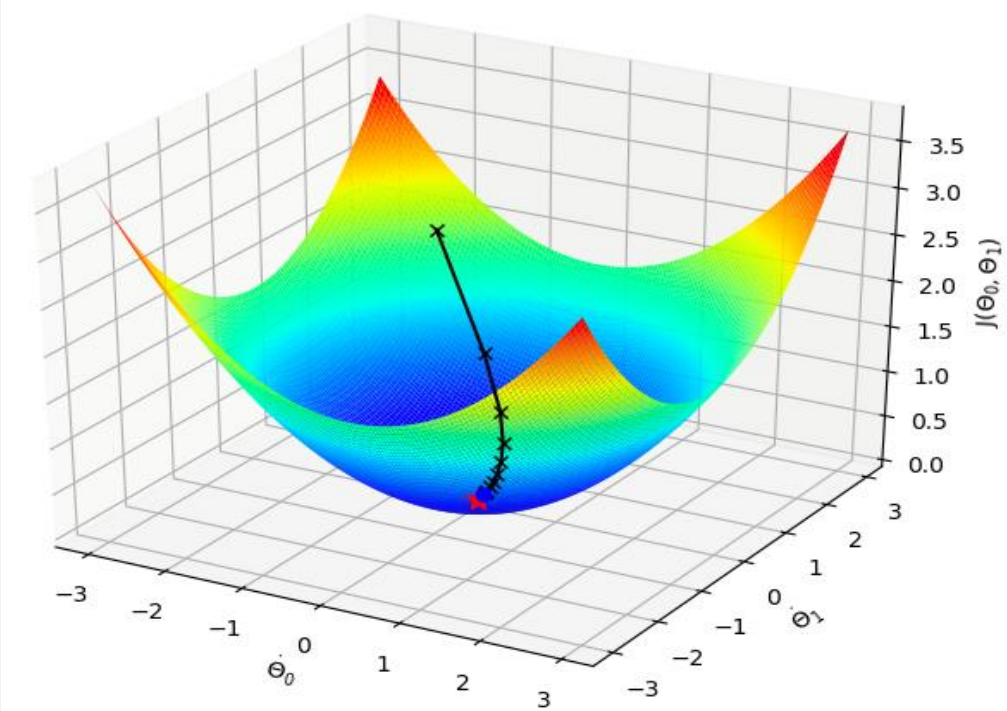
Hipótesis: $h_\theta(x) = \theta_0 + \theta_1 x$

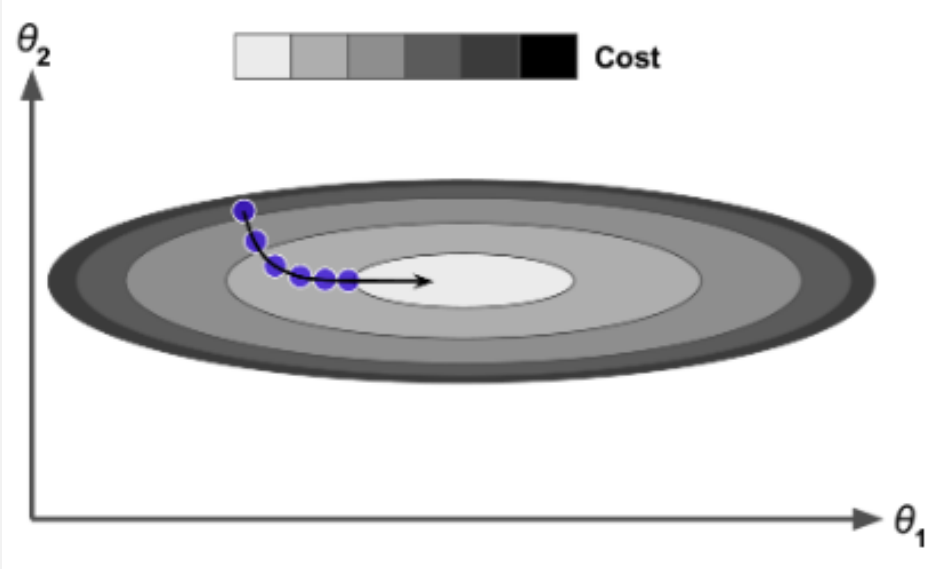
Parámetros: $\theta_0, \theta_1 x$

Función de costo: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta\left(x^{(i)}\right) - y^{(i)} \right)^2$

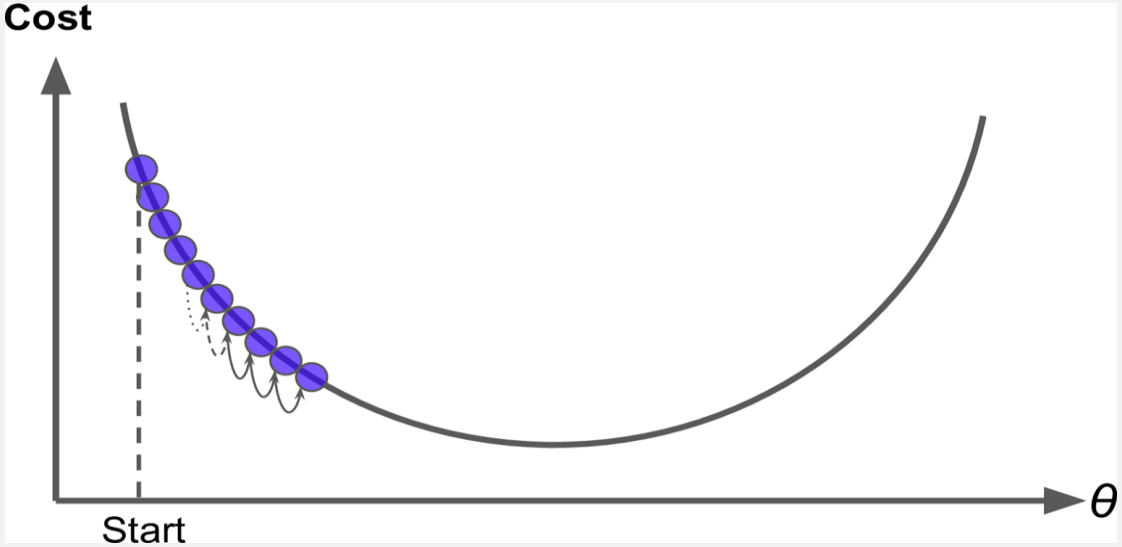
Objetivo: $minimizar \ J(\theta_0, \theta_1)$

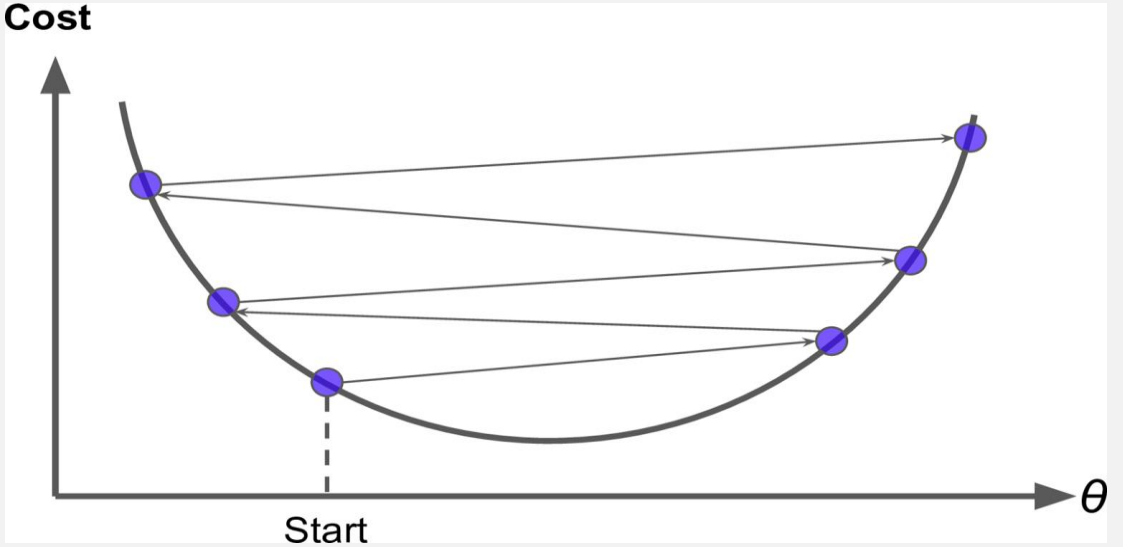
Algoritmo de descenso del gradiente





Tasa de aprendizaje





Regresión lineal con más de dos atributos

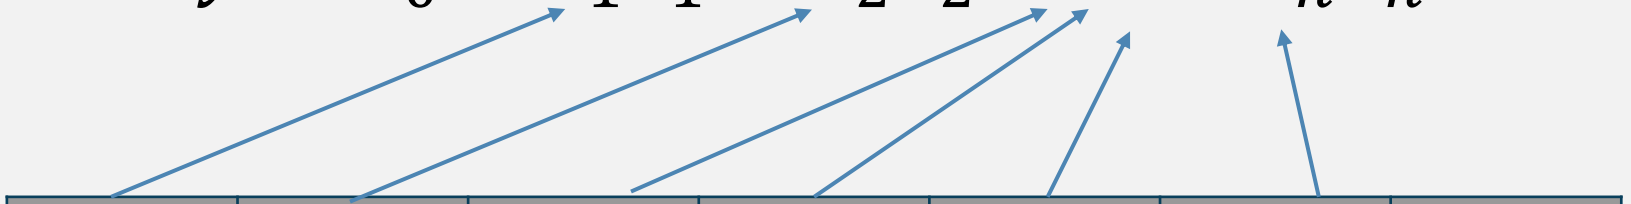
$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

En esta ecuación:

- $\hat{y}$ es el valor predicho
- n es el número de atributos
- x_i es el valor del iesimo atributo
- θ_j es el jesimo parámetro del modelo incluyendo el intersecto θ_0 y los pesos $\theta_1, \theta_2, \ldots, \theta_n$

Regresión lineal con más de dos atributos

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$



País	Satisfacción	GDP per capita	Población	Región	T. de fertilidad	...
Colombia	5.78	$13.449 / year	50.88M	América del Sur	1.79 hijos*	...
...	...	...	...	...	...	...

¿Qué **interpretación** se le puede dar a los parámetros o coeficientes?

¿Qué efecto tiene la **escala de los atributos**?

¿Cómo trabajar con **atributos categóricos**?

Transformación de atributos categóricos a numéricos

SAFETY-LEVEL (TEXT)	SAFETY-LEVEL (NUMERICAL)
None	0
Low	1
Medium	2
High	3
Very-High	4

BRIDGE-TYPE (TEXT)	BRIDGE-TYPE (Arch)	BRIDGE-TYPE (Beam)	BRIDGE-TYPE (Truss)	BRIDGE-TYPE (Cantilever)	BRIDGE-TYPE (Tied Arch)	BRIDGE-TYPE (Suspension)	BRIDGE-TYPE (Cable)
Arch	1	0	0	0	0	0	0
Beam	0	1	0	0	0	0	0
Truss	0	0	1	0	0	0	0
Cantilever	0	0	0	1	0	0	0
Tied Arch	0	0	0	0	1	0	0
Suspension	0	0	0	0	0	1	0
Cable	0	0	0	0	0	0	1

Técnicas de normalización

- **Escalamiento lineal (0-1):**

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- **Clipping:**

$$x' = \begin{cases} Si\ x > \max & max \\ Si\ x < \min & min \end{cases}$$

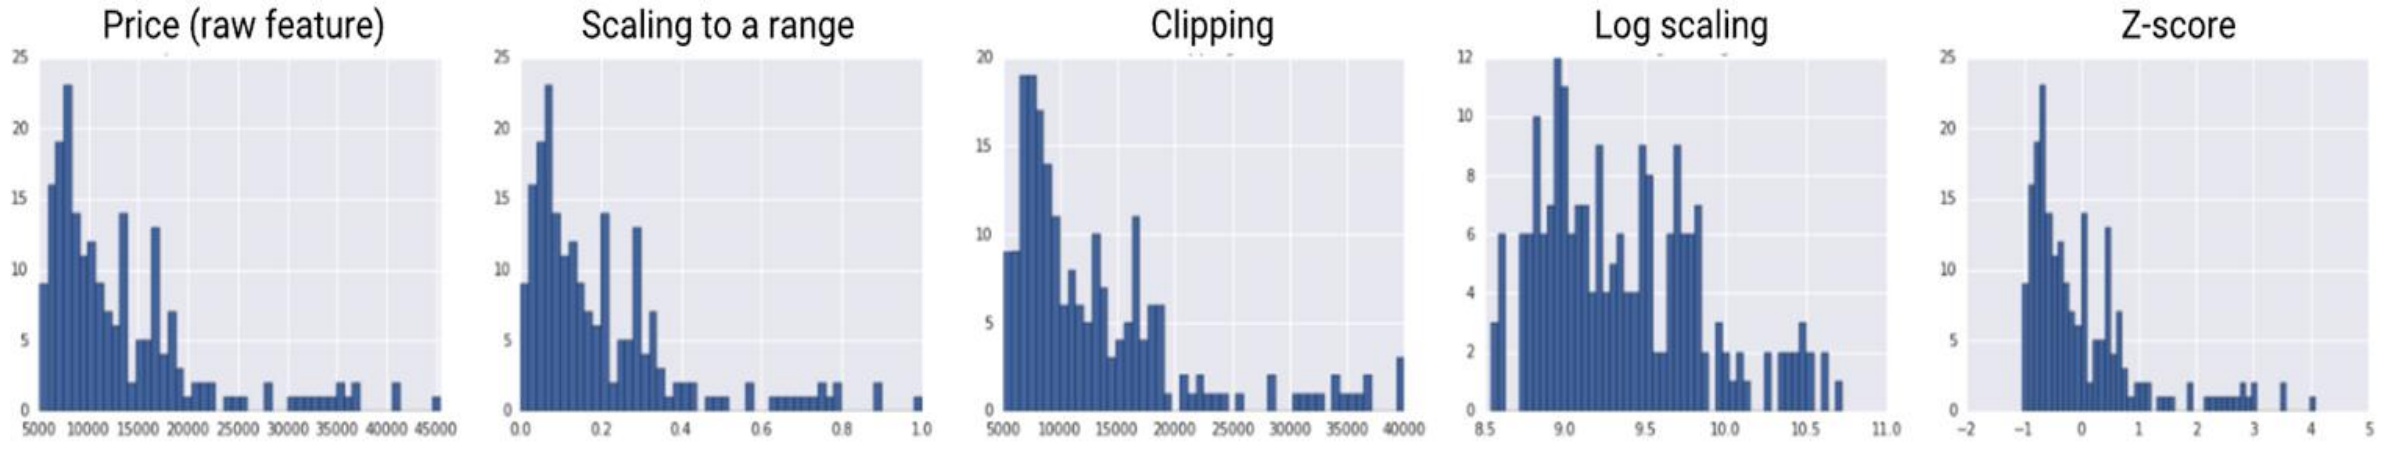
- **Z-score:**

$$x' = \frac{x - \mu}{\sigma}$$

- **Escalamiento logarítmico:**

$$x' = \log(x)$$

Técnicas de normalización

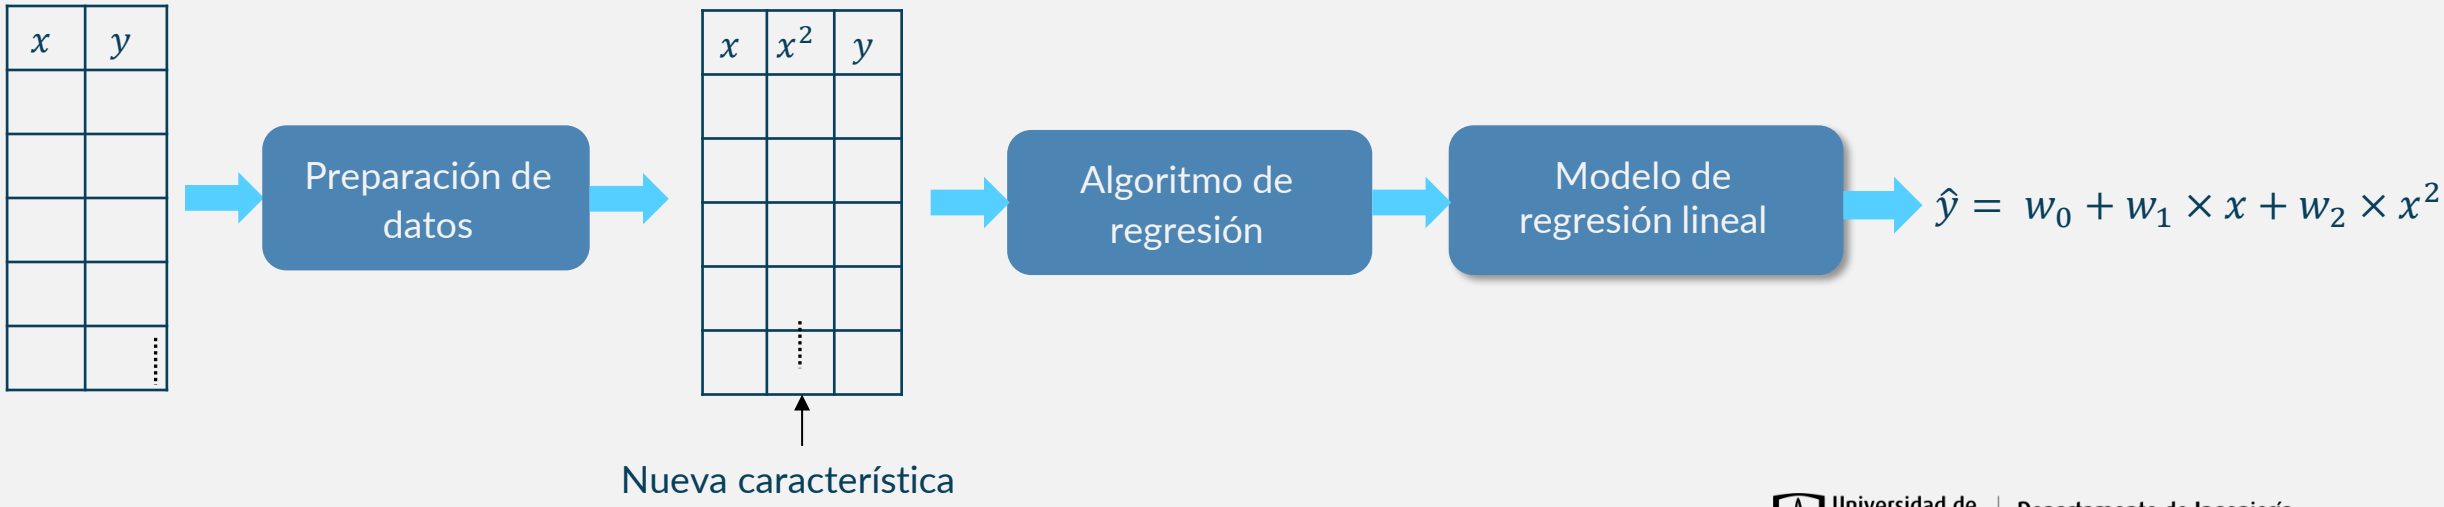


Supuestos de la regresión lineal

- Existe una **relación lineal** entre la variable dependiente y las variables independientes.
- No hay **multicolinealidad** entre las variables independientes.
- Las diferencias entre las predicciones y los valores observados siguen una distribución normal.
- La varianza de los errores es consistente en todas las variables independientes (**Homocedasticidad**).

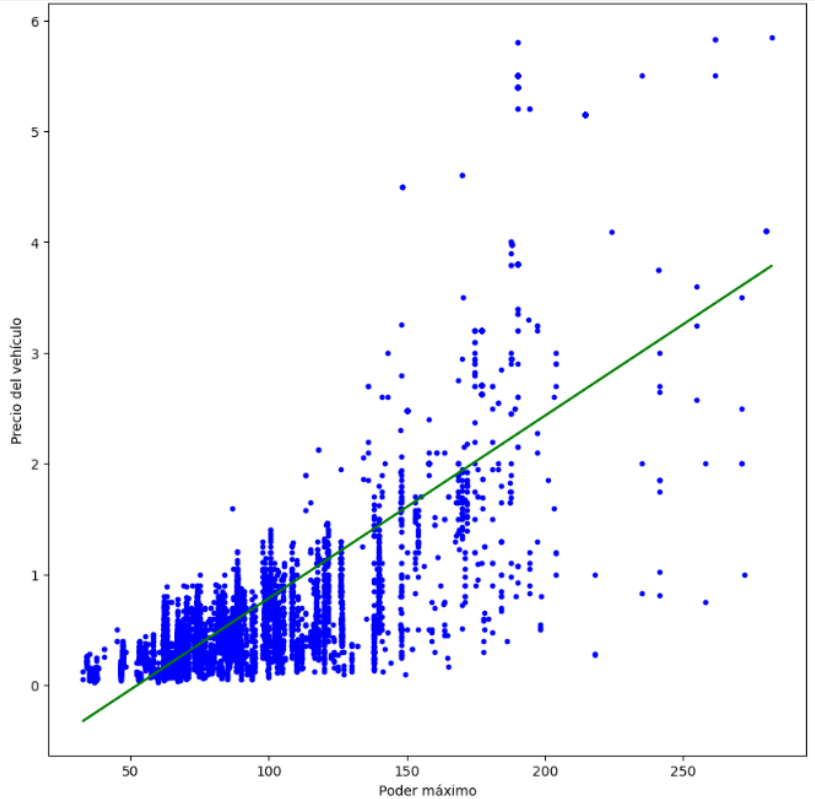
Regresión Polinomial

- Podemos generar modelos basados en usar combinaciones polinomiales de las variables objetivas.
- Representa la relación entre la variable objetivo y las predictoras como un polinomio de orden p.
- El modelo sigue siendo lineal en sus parámetros.
- La construcción de nuevas características ocurre en la fase de preparación de datos.
- Estas nuevas características, construidas a partir de la originales, se generan a través de una **transformación** polinomial.

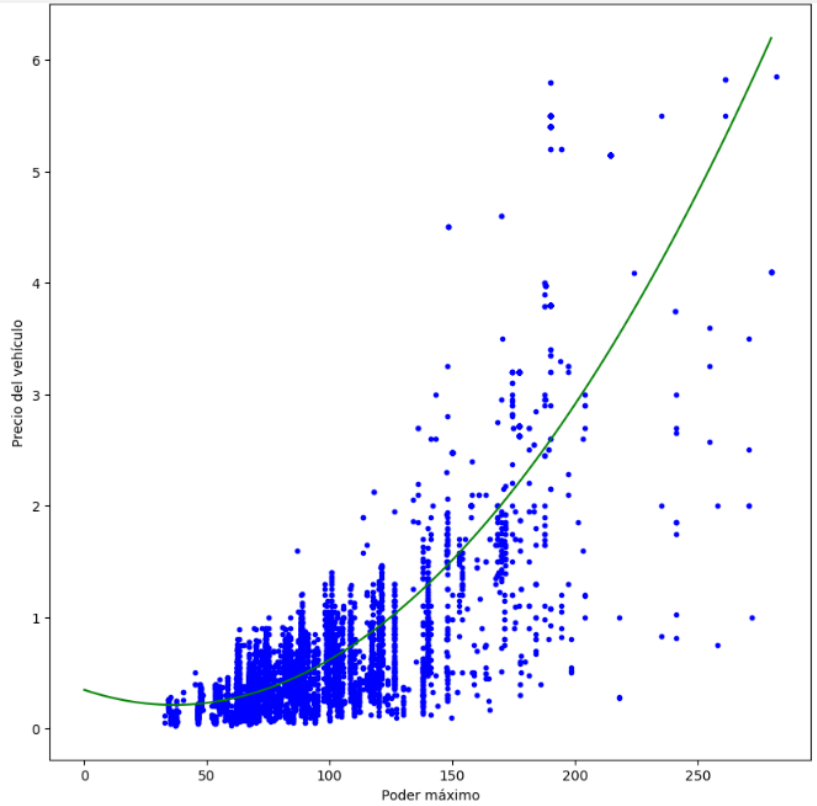


Regresión Polinomial

Regresión lineal



Regresión polinomial



A través de las transformaciones se pueden mejorar las métricas de los algoritmos

Regresión Polinomial - Complejidad

- Una de las consecuencias de estos modelos, es el aumento de la complejidad del modelo:

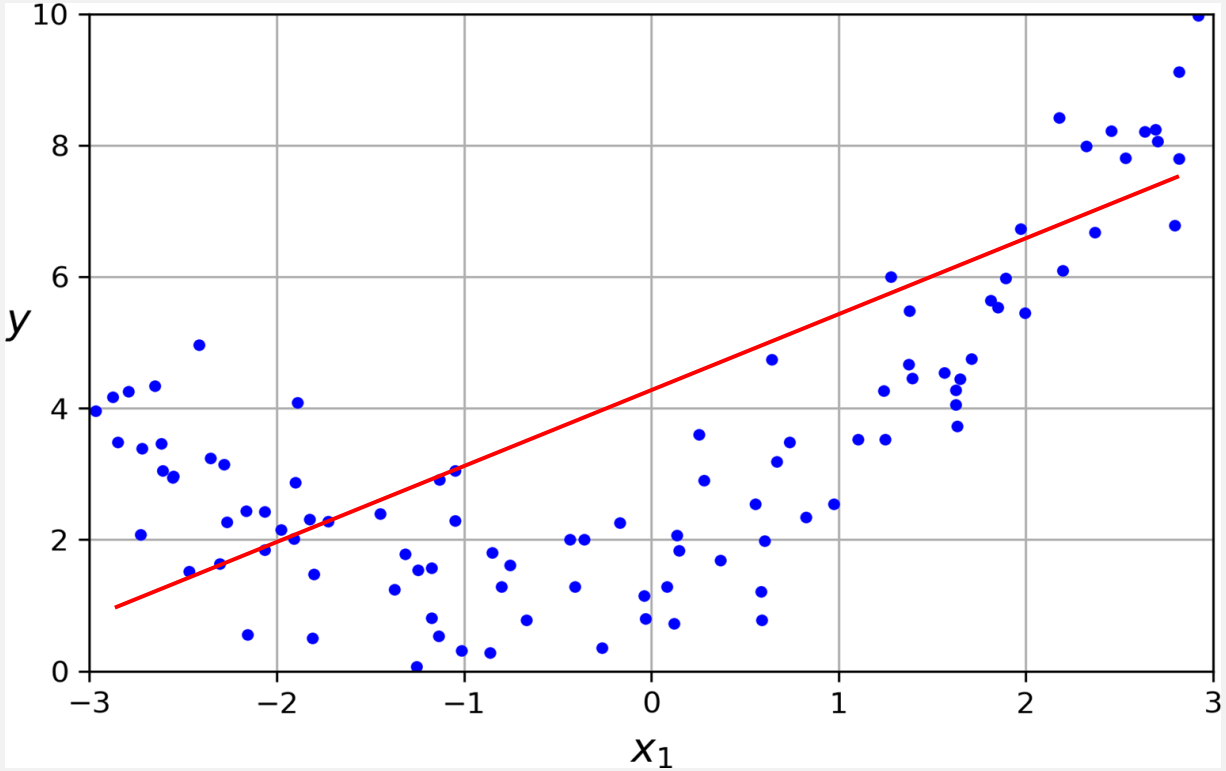
Modelo	Cantidad de variables
Regresión lineal	14
Regresión polinomial grado 2	105
Regresión polinomial grado 3	560
Regresión polinomial grado 4	2380
Regresión polinomial grado 5	8568
Regresión polinomial grado 6	27132

¿Cuántos parámetros tendría el modelo de regresión lineal?

En general, para d variables y grado = q, se generan $\binom{d+q}{q}$ nuevas características.

¿Cómo resolver el subajuste?

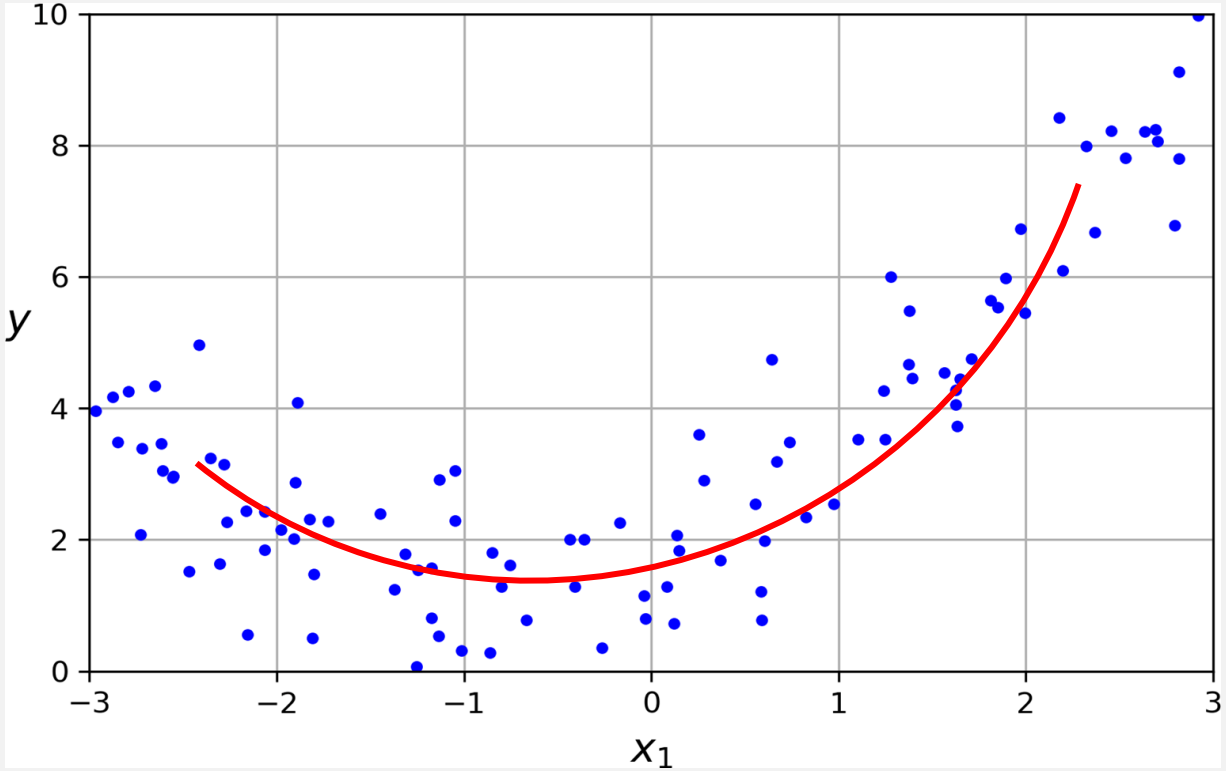
- Aumentar la complejidad del modelo
- Agregar más o mejores atributos (si es posible).
- La Regresión Polinomial sirve para ambos propósitos



$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \cdots + \beta_n x^n + \varepsilon$$

¿Cómo resolver el subajuste?

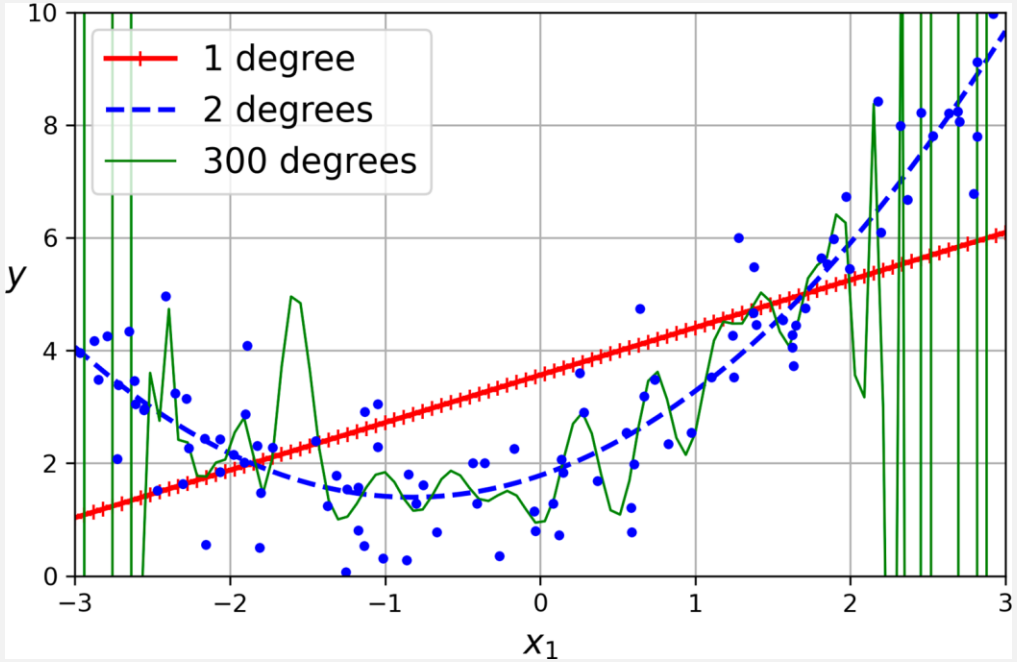
- Aumentar la complejidad del modelo
- Agregar más o mejores atributos (si es posible).
- La Regresión Polinomial sirve para ambos propósitos



$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \cdots + \beta_n x^n + \varepsilon$$

¿Cómo resolver el sobreajuste?

- Entrenar con más datos (si es posible).
- Realizar selección de atributos (*feature selection*).
  - Entrenar solo con los atributos más significativos
- Realizar validación cruzada.
- Regularización.
- Modelos de ensamble.



Supuestos de la regresión lineal

- Existe una **relación lineal** entre la variable dependiente y las variables independientes.
- No hay **multicolinealidad** entre las variables independientes.
- Las diferencias entre las predicciones y los valores observados siguen una distribución normal.
- La varianza de los errores es consistente en todas las variables independientes (**Homocedasticidad**).

Regularización

Intuición: A menos grados de libertad (parámetros), menor es el riesgo de *subajuste*.

Regularización ~ **restringir** el modelo.

Por ejemplo, en el caso de la regresión polinomial, la regularización busca:

- "Eliminar" algunos grados del polinomio "innecesarios"
- Disminuir la peso (magnitud) de sus coeficientes para que no tengan mayor impacto en la variable objetivo

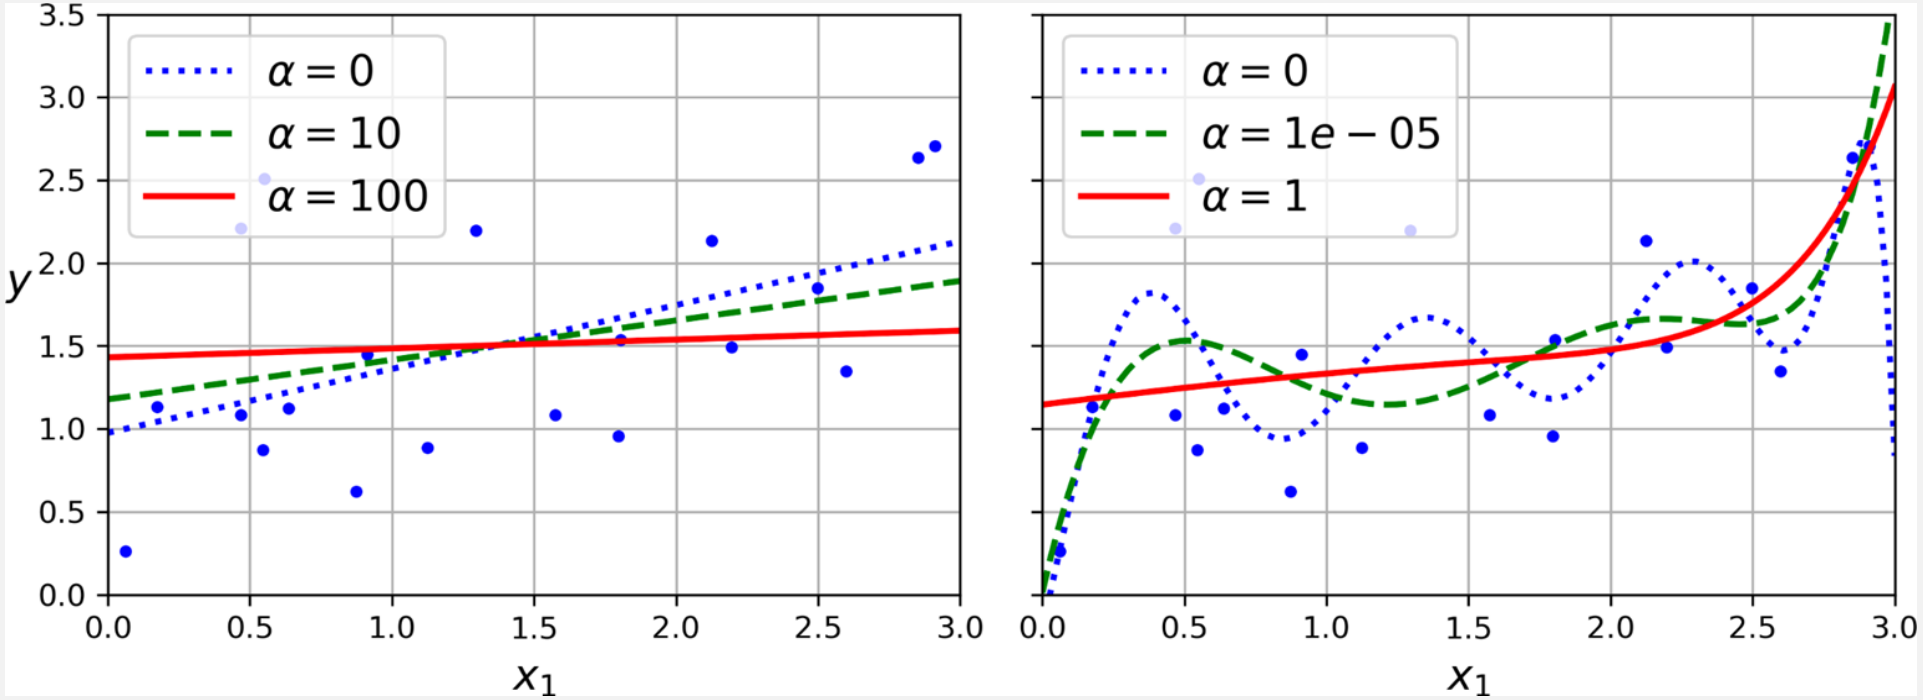
Ride Regression (L2)

Mantiene los pesos de los coeficientes **tan pequeños como sea posible** mientras se ajusta a los datos. Los coeficientes **NUNCA llegan a ser 0**.

El hiper-parámetro α controla la **"fuerza"** de la regularización.

$$J(\theta) = MSE(\theta) + \frac{\alpha}{m}\sum_{i=1}^{n}\theta_i^2$$

Ride Regression (L2)



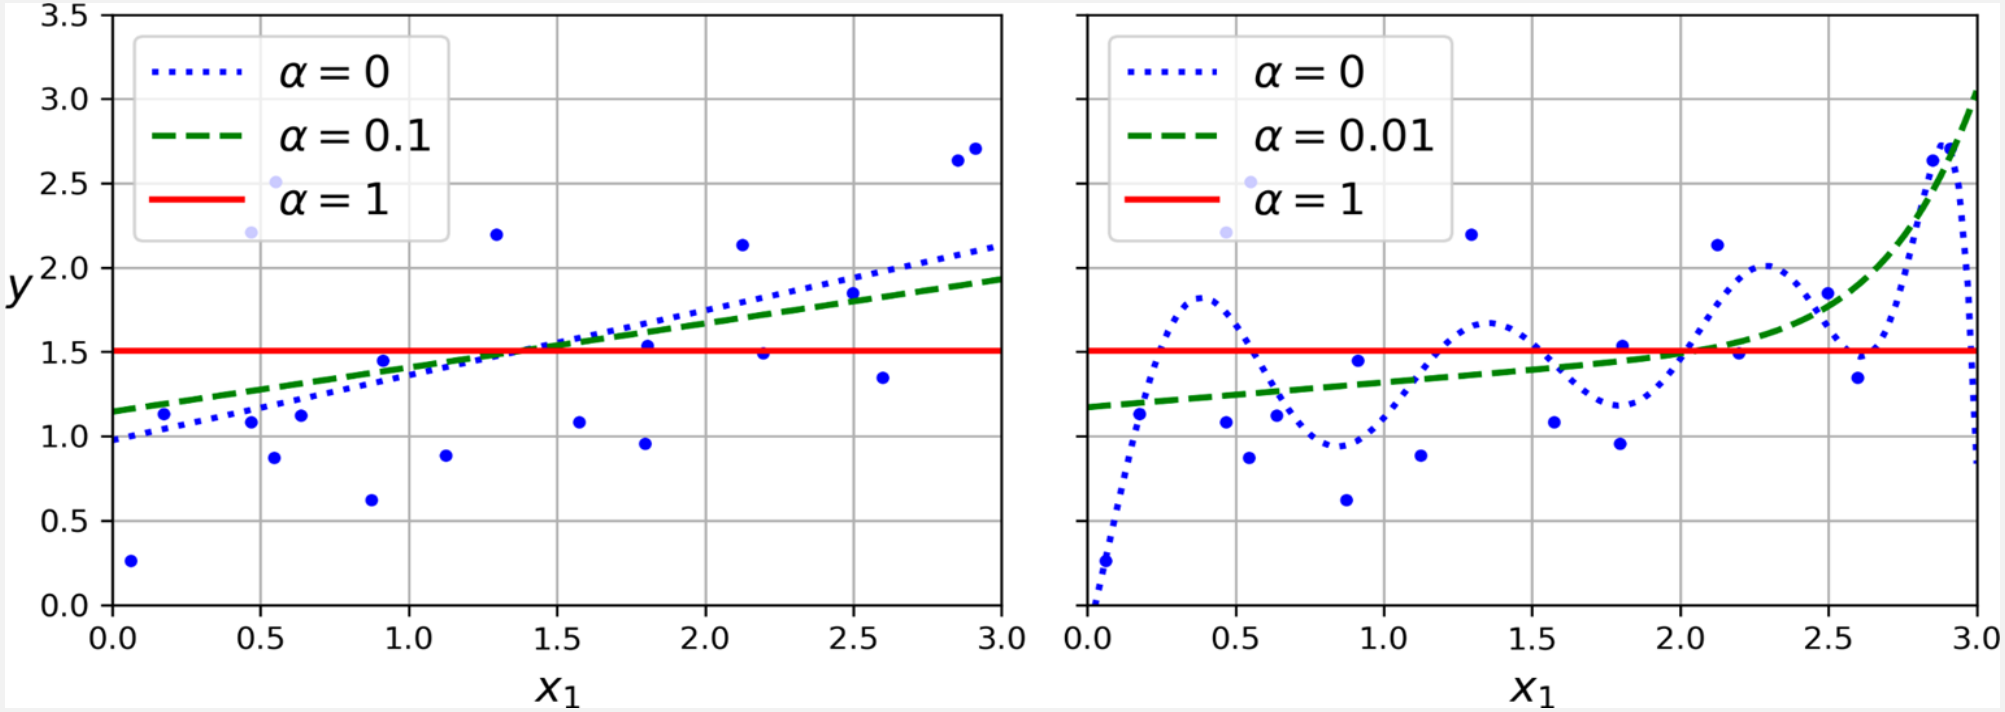
Lasso Regression (L1)

Tiende a eliminar las características menos importantes mientras se ajusta a los datos. Es decir, los coeficientes asociados a estas carácterísticas **pueden llegar a tener un valor de 0**.

Esta técnica es un tipo de **selección de características**.

$$J(\theta) = MSE(\theta) + \frac{\alpha}{m}\sum_{i=1}^{n}\theta_i^2$$

Lasso Regression (L1)



Aspectos de diseño a considerar

1. Es importante que las características se encuentren **normalizadas**.

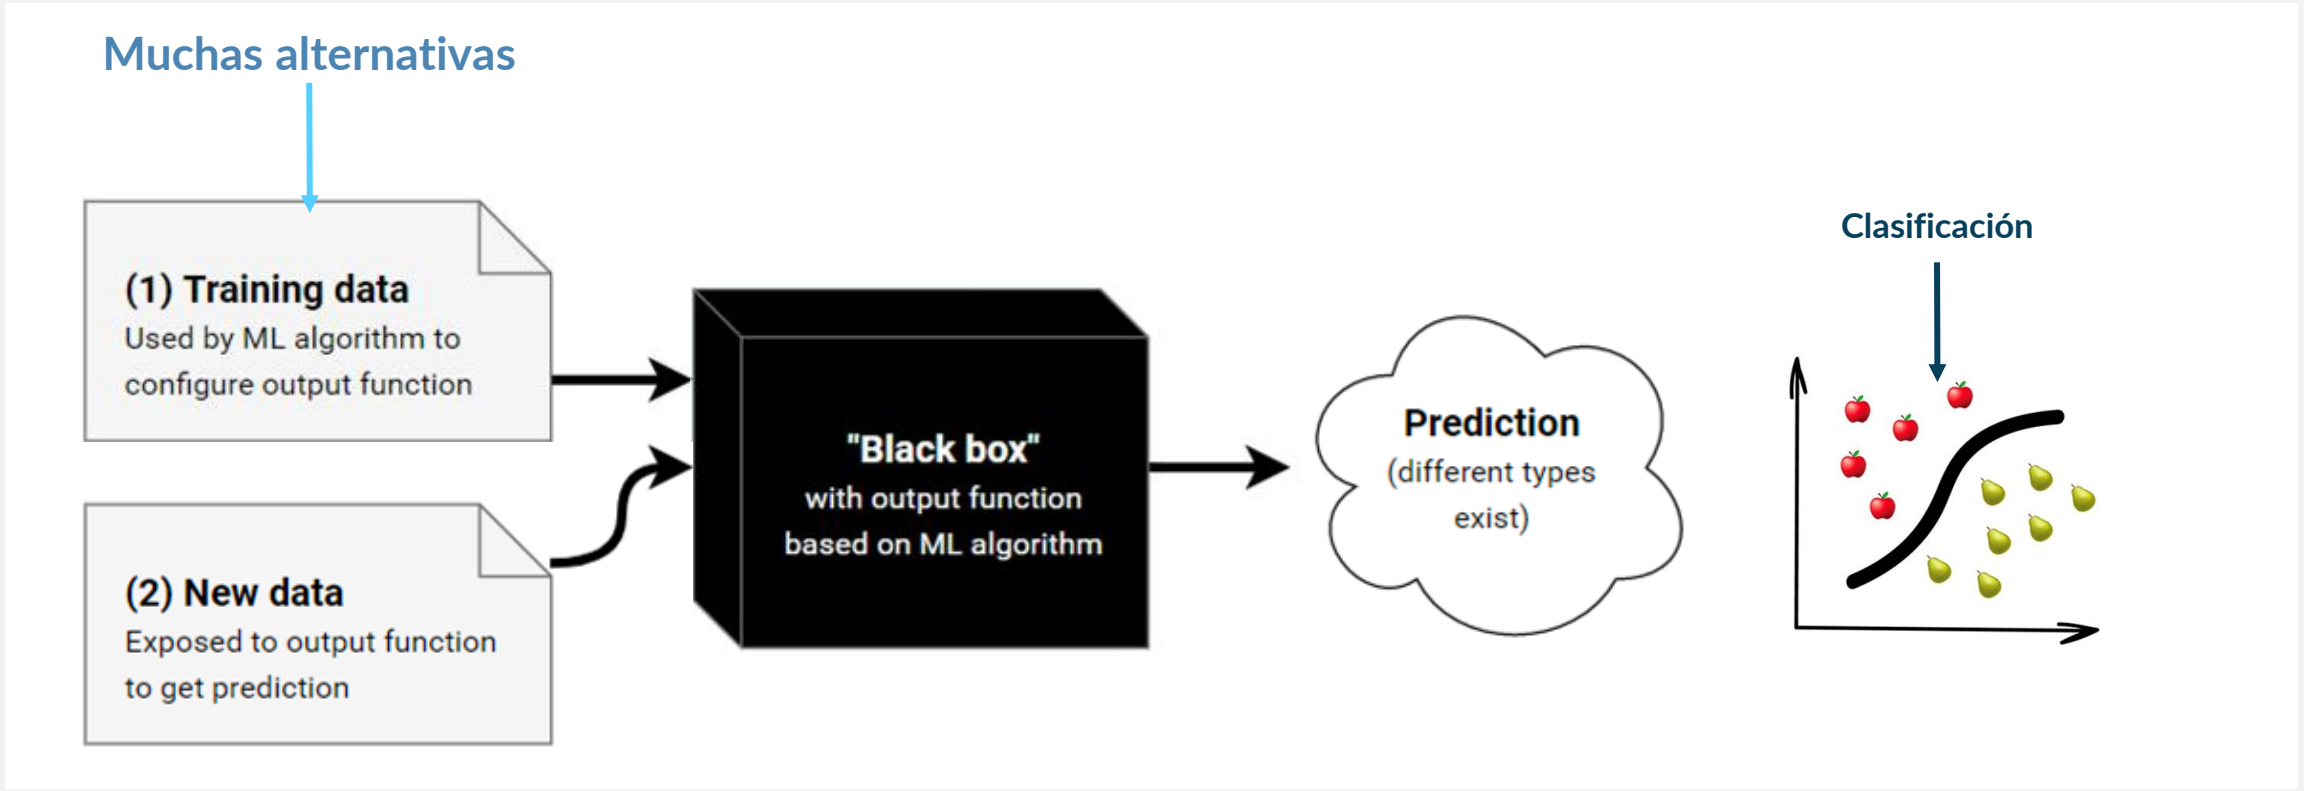
2. El término de regularización se aplica **sólo a la función de costo**, no afecta la evaluación del modelo posterior al entrenamiento.

3. En general, no es buena idea aplicar regularización cuando el objetivo es entrenar un **modelo interpretable**, en lugar de tener la mejor capacidad predictiva.

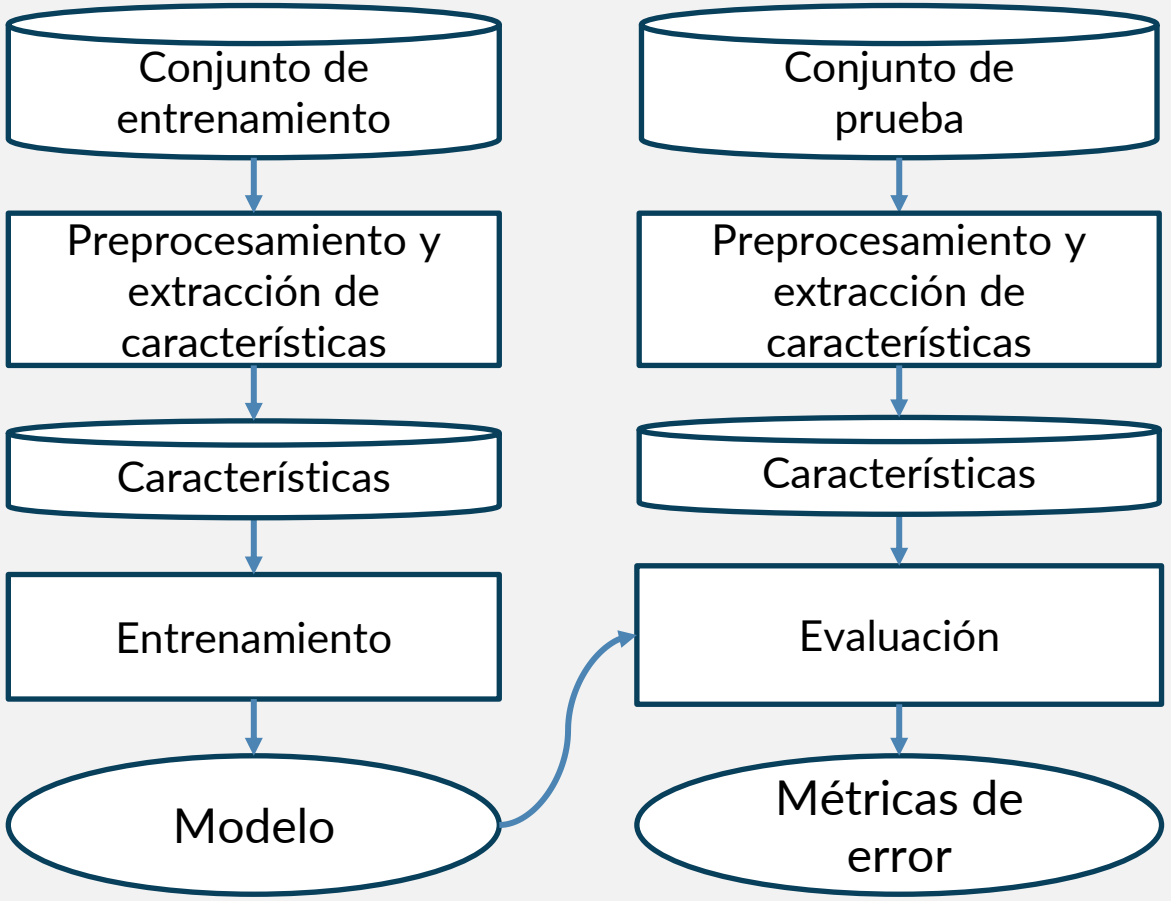
4. Cuando el objetivo es capacidad predictiva, siempre es preferible tener al menos un poco de regularización, *Ridge* es una buena opción por defecto.

Aprendizaje Supervisado: Clasificación

Esquema general de un modelo de Clasificación



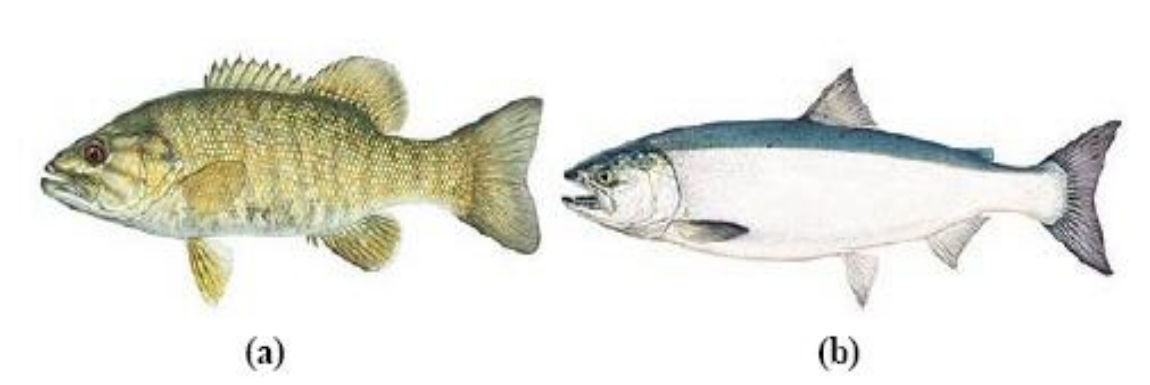
Esquema general de un modelo de clasificación



Caso de estudio

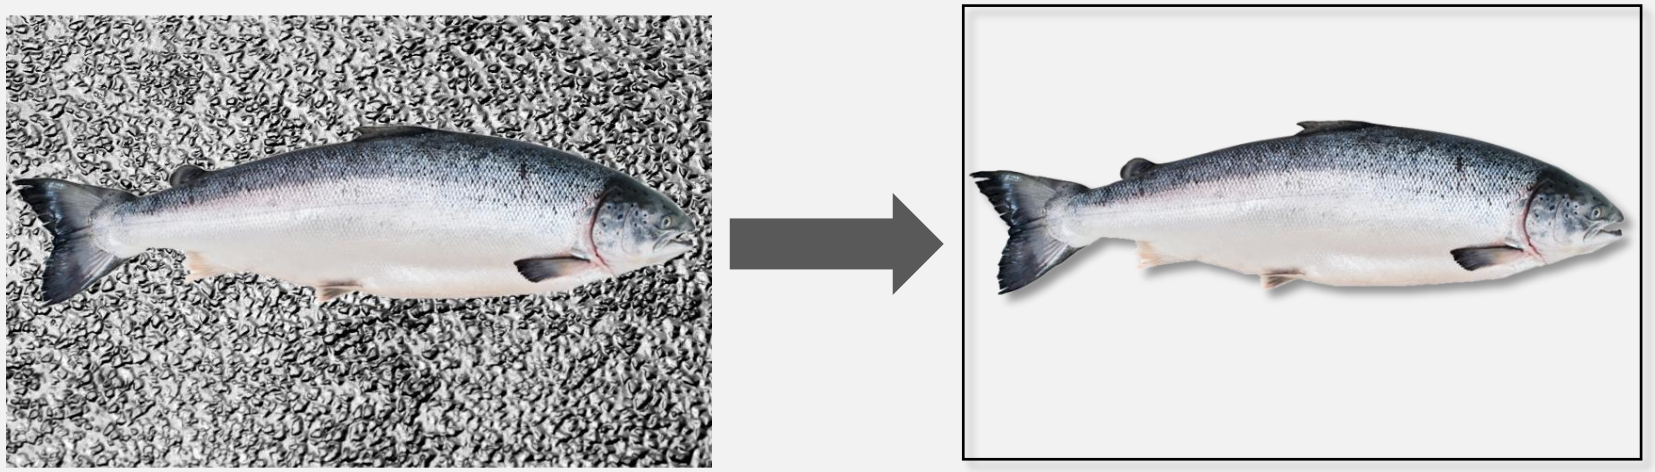
Una planta empacadora de pescados quiere automatizar el proceso de clasificar (o separar) los peces que llegan de acuerdo a la especie.

Como proyecto piloto, se decide utilizar la **lubina** y el **salmón**.



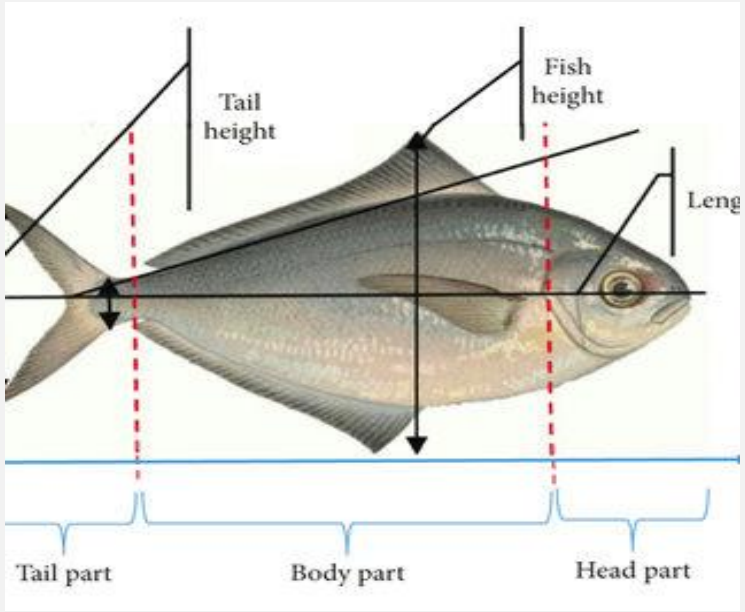
Paso 1: Preprocesamiento

Las imágenes de los distintos peces son aisladas del fondo.



Paso 2: Extracción de características

La imágen de cada pez es enviada a un extractor de características, este sistema mide las características o atributos de cada pez.



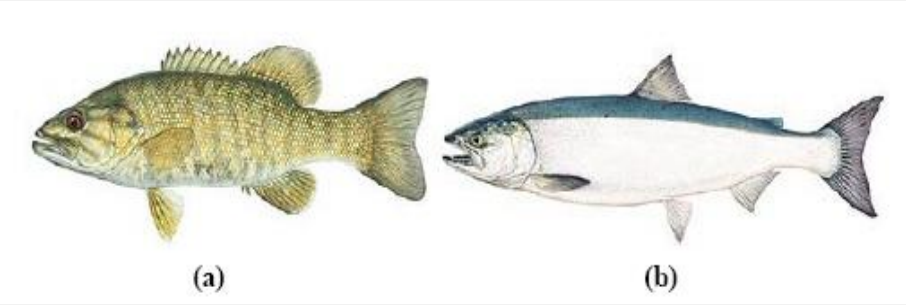
Paso 2: Extracción de características

¿Qué características usamos?

Hacemos uso de nuestro conocimiento del dominio: Una lubina generalmente es más grande que un salmón.

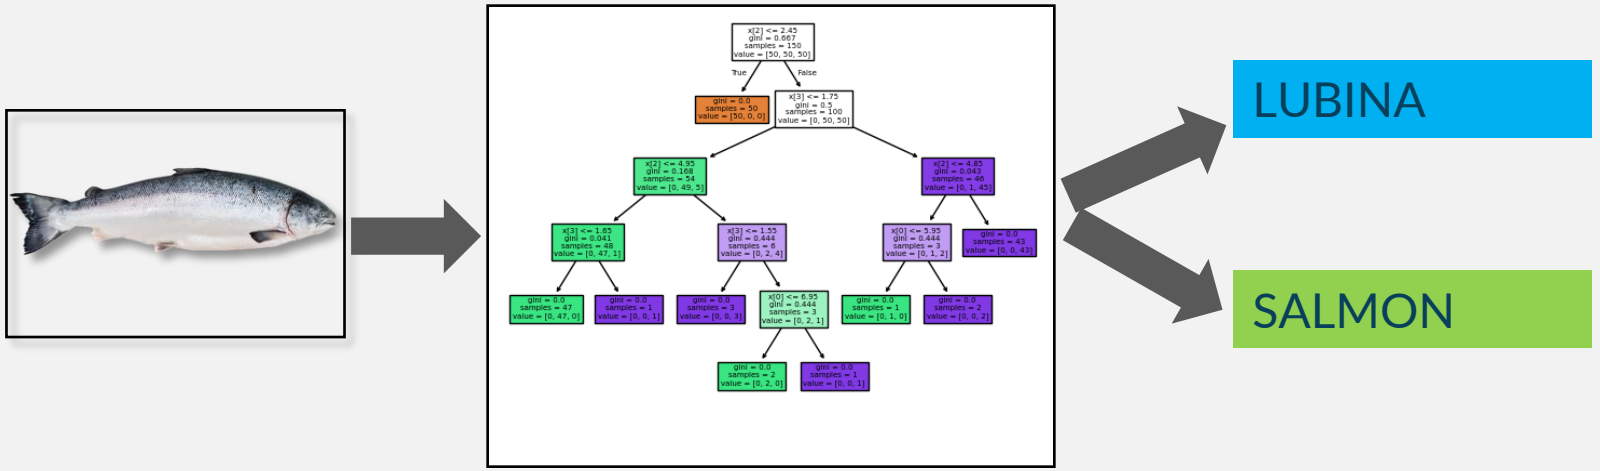
¿A qué característica estamos haciendo referencia?

Longitud



Paso 3: Entrenamiento

Estas características son analizadas por un **algoritmo** que construye un **modelo** para discriminar entre las dos especies de peces.



Paso 3: Entrenamiento

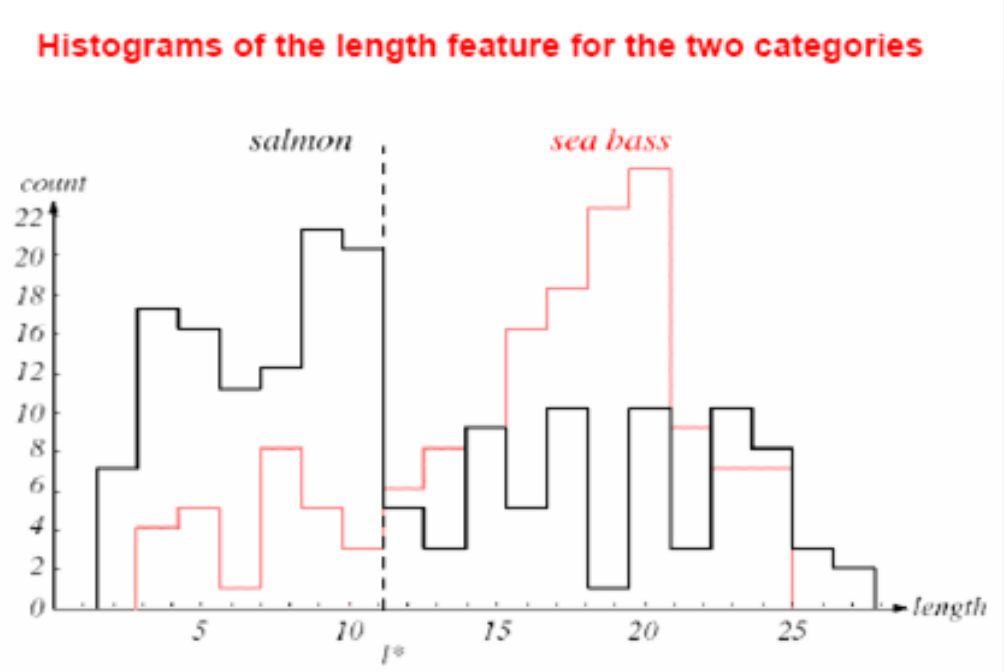
Un ejemplo de modelo, para este simple escenario podría ser:

```
IF longitud_pez >= l*
THEN lubina
ELSE salmón.
```

El valor de ***l****es determinado por el algoritmo utilizando los datos de entrenamiento.

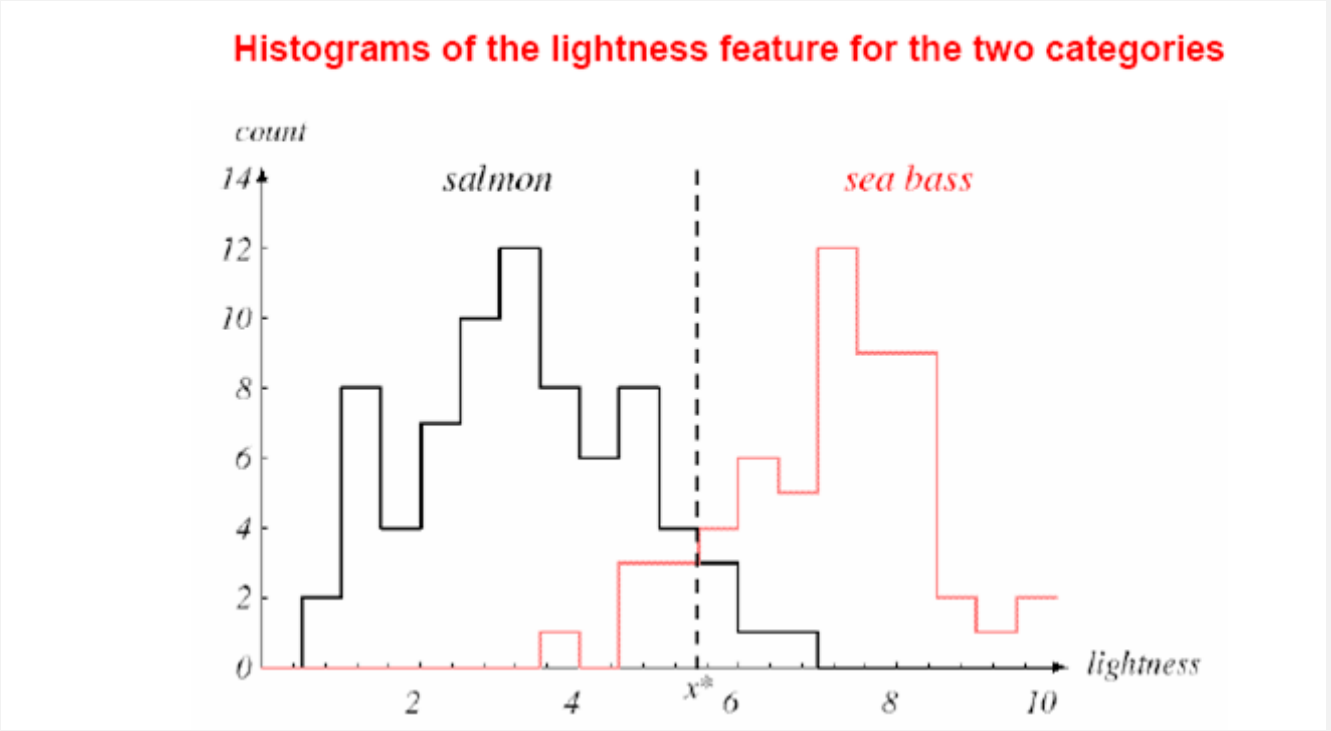
Paso 4: Evaluación

Se realiza una **medición** de la cantidad de veces que el modelo **falló** (o tuvo **éxito**) al clasificar un pez.

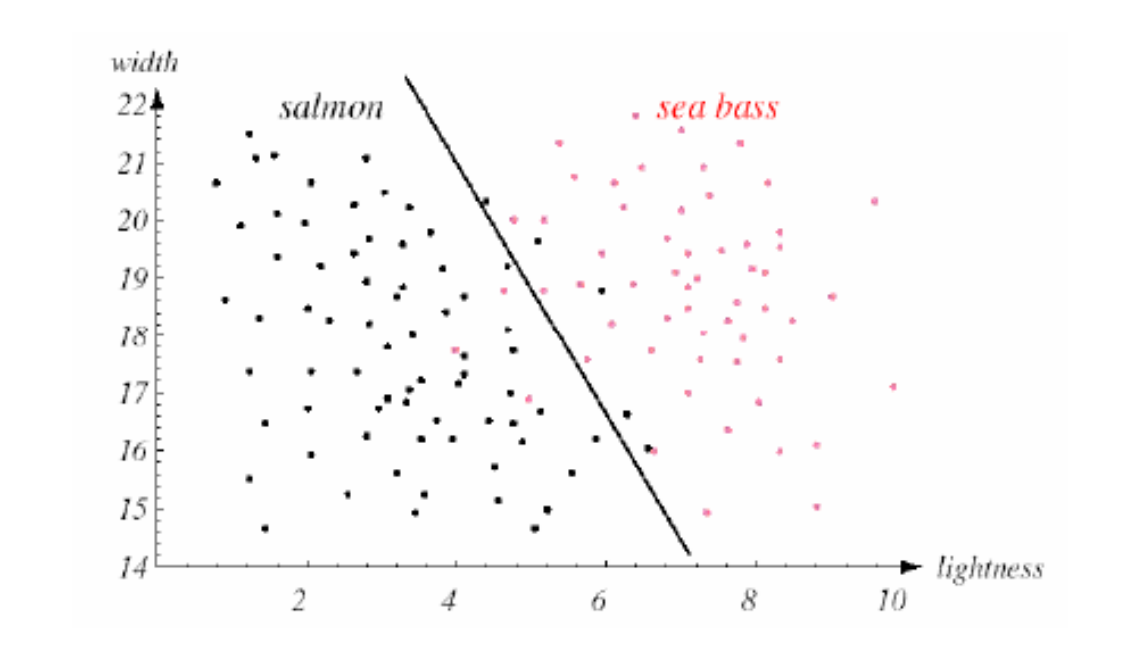


Paso 5: Iteración del modelo

Probamos con diferentes hiperparámetros, pre-procesamiento o incluso diferentes modelos.



Paso 5: Iteración del modelo

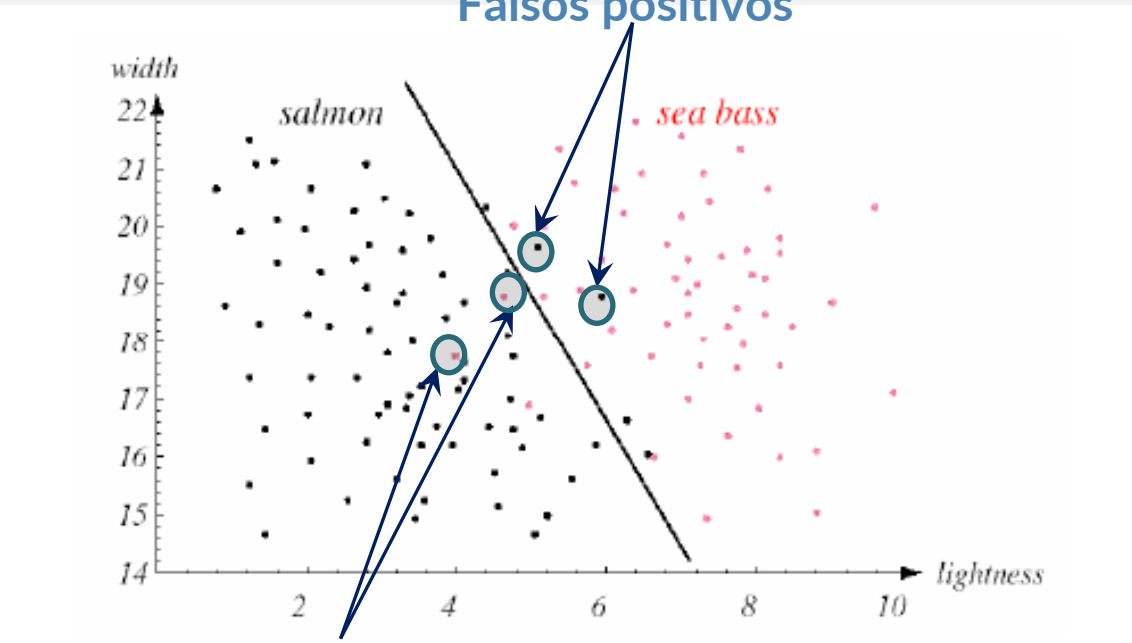


Clase positiva*
Lubina

Clase negativa
Salmón

* Por lo general, la clase positiva es la clase minoritaria

Paso 5: Iteración del modelo

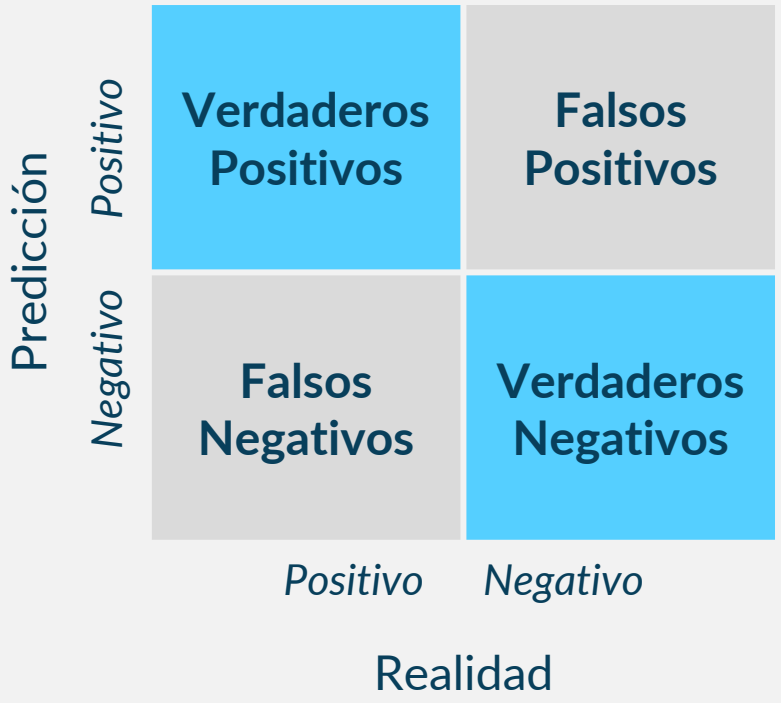


Clase positiva*
Lubina

Clase negativa
Salmón

* Por lo general, la clase positiva es la clase minoritaria

Matriz de confusión



$$Exactitud = \frac{VP + VN}{VP + VN + FP + FN}$$

$$Error = \frac{FP + FN}{VP + VN + FP + FN}$$

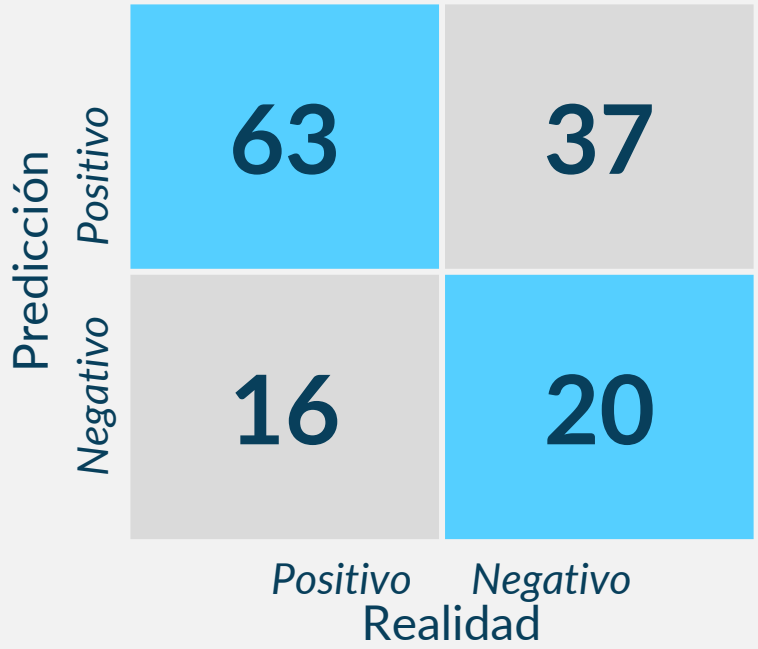
$$Precision = \frac{VP}{VP + FP}$$

$$Recall = \frac{VP}{VP + FN}$$

$$Especificidad = \frac{VN}{FP + VN}$$

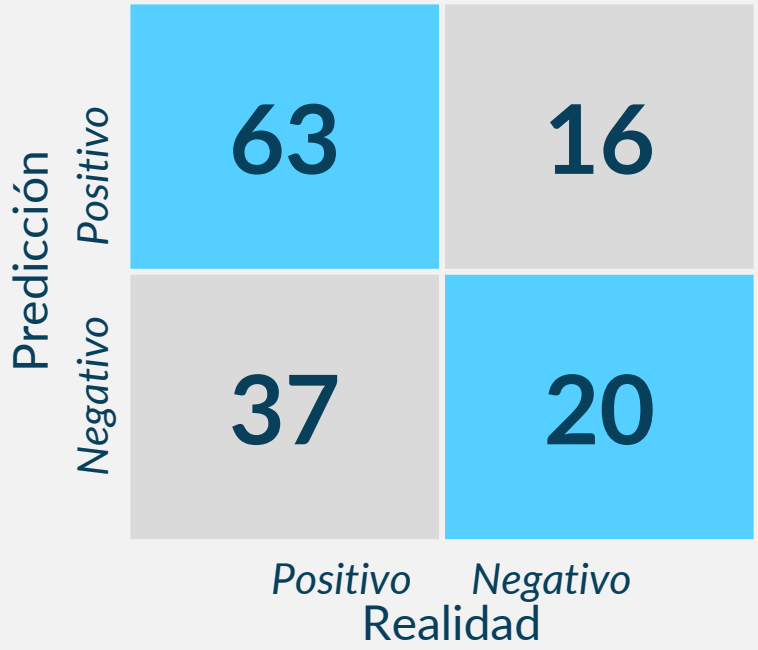
$$FScore = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Matriz de confusión - Ejemplos



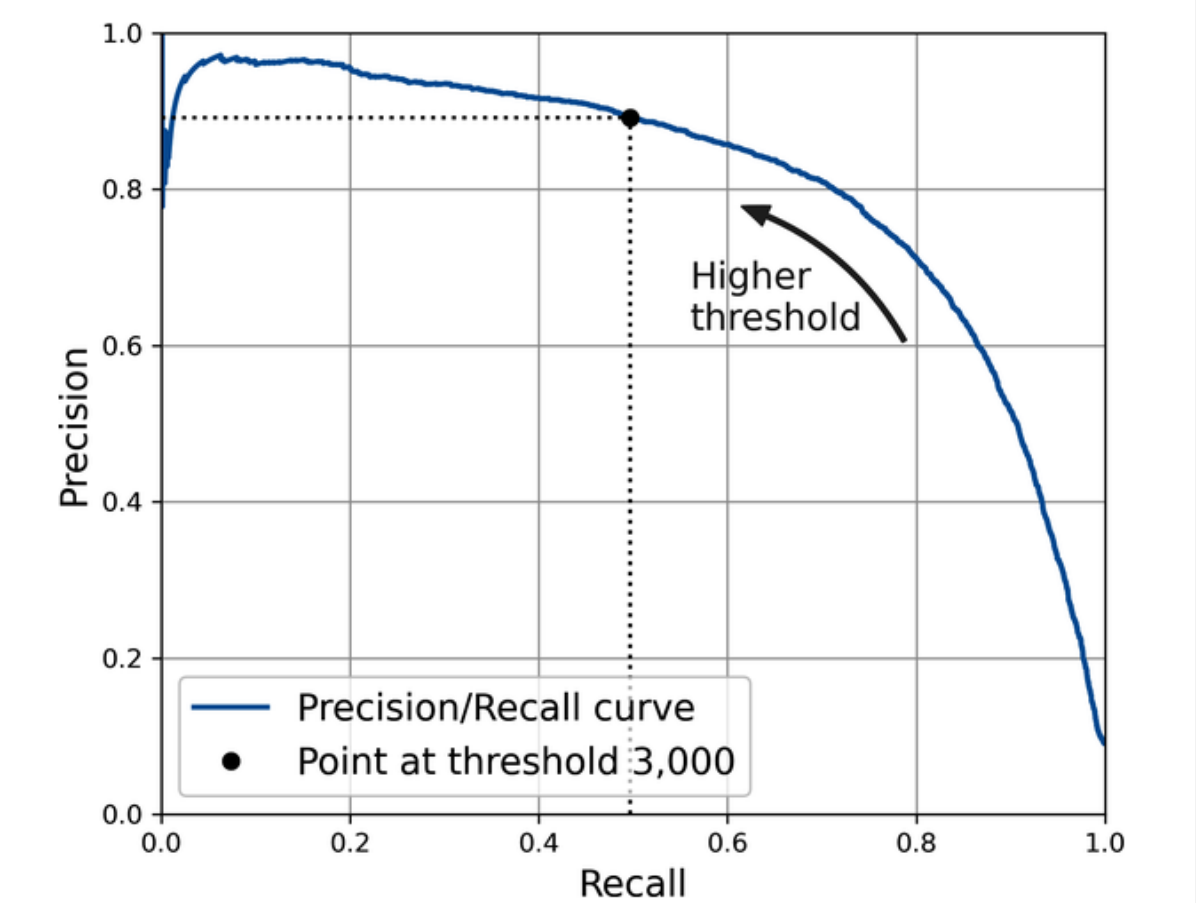
- **Accuracy:** 0.61
- **Precision:** 0.63
- **Recall:** 0.80
- **F-Score:** **0.70**

Matriz de confusión - Ejemplos

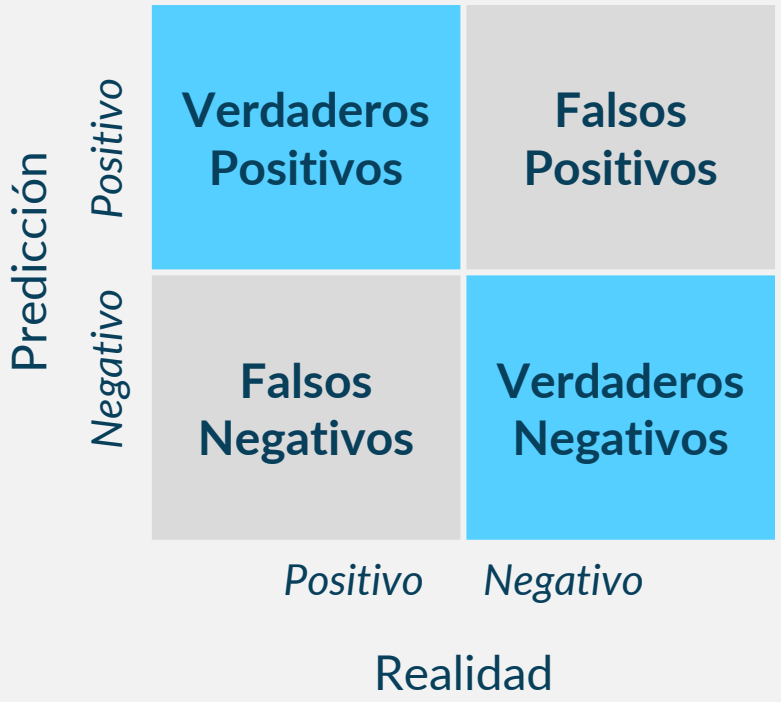


- **Accuracy:** 0.61
- **Precision:** 0.80
- **Recall:** 0.63
- **F-Score:** **0.70**

Curva de Precision vs Recall



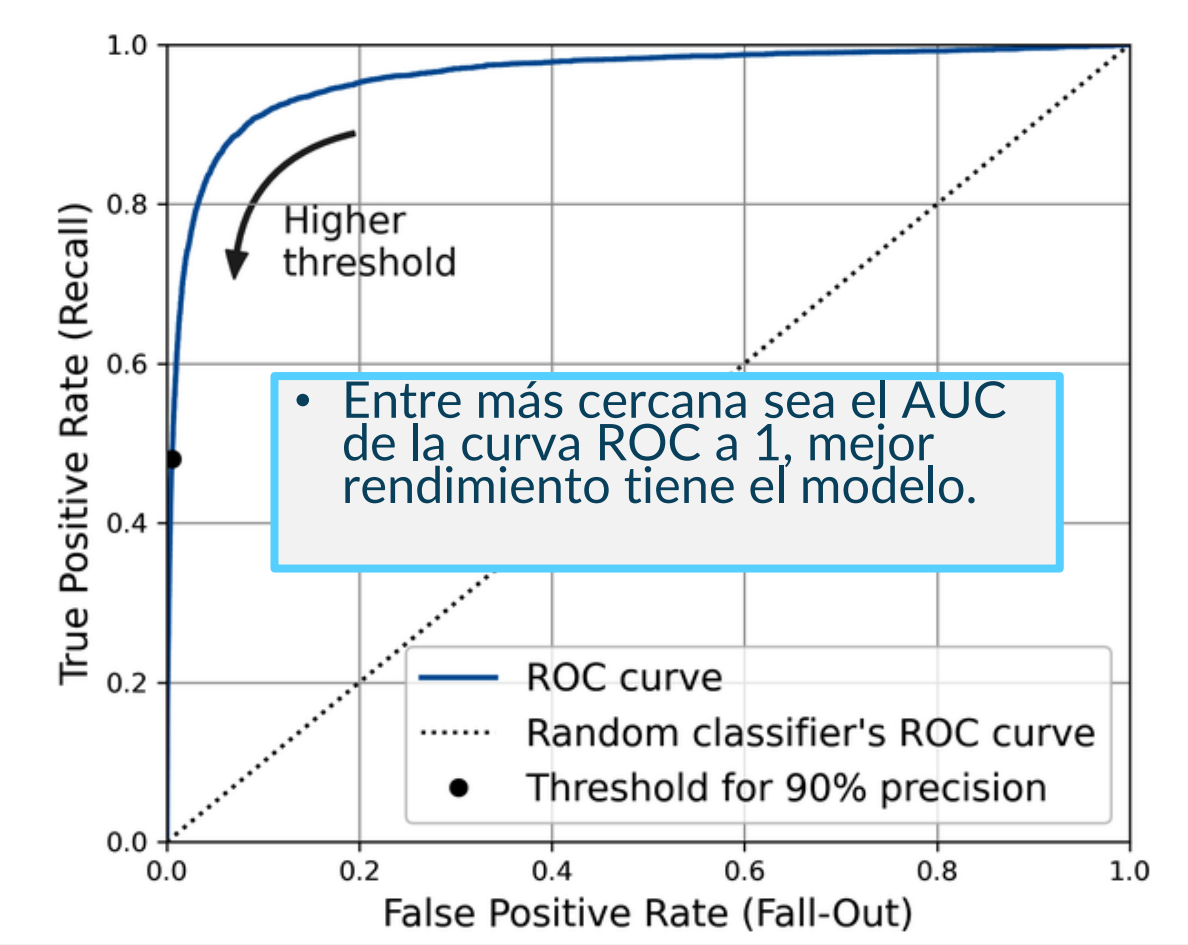
Curva ROC



$$Recall = \frac{VP}{VP + FN}$$

$$Fall\ Out = \frac{FP}{FP + VN}$$

Curva ROC



- Entre más cercana sea el AUC de la curva ROC a 1, mejor rendimiento tiene el modelo.

$$Recall = \frac{VP}{VP + FN}$$

$$Fall\ Out = \frac{FP}{FP + VN}$$

Métricas multiclase

- Podemos calcular las métricas como en el caso binario (Exactitud, Precision, Recall, AUC-ROC) por clase (**One vs All**).
- Es possible entender las métricas globales del modelo usando un macro-promedio (**macro-average**).
- Cuando existe desbalanceo, es possible usar un promedio ponderado (**weighted average**) basado en el número de instancias de cada clase.
- Es posible calcular también un micro-promedio (**micro-average**) asociado a la proporción entre detecciones correctas e incorrectas.

Métricas multiclase

¿Como leer los resultados en sklearn?

	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Métricas multiclase

¿Como leer los resultados en sklearn?

	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Métricas para la clase No Renuncia

Métricas multiclase

¿Como leer los resultados en sklearn?

	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Métricas para la clase Renuncia

Métricas multiclase

¿Como leer los resultados en sklearn?

	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Micro-promedio

Métricas multiclase

¿Como leer los resultados en sklearn?

	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Macro-promedios

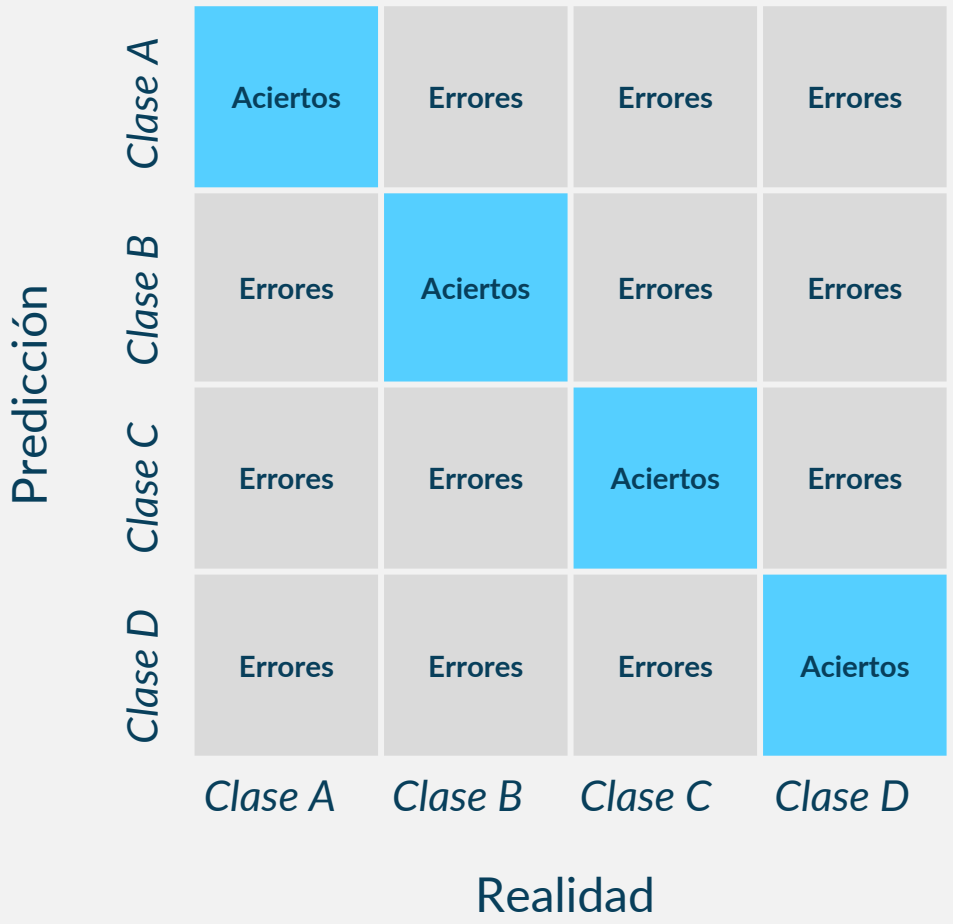
Métricas multiclase

¿Como leer los resultados en sklearn?

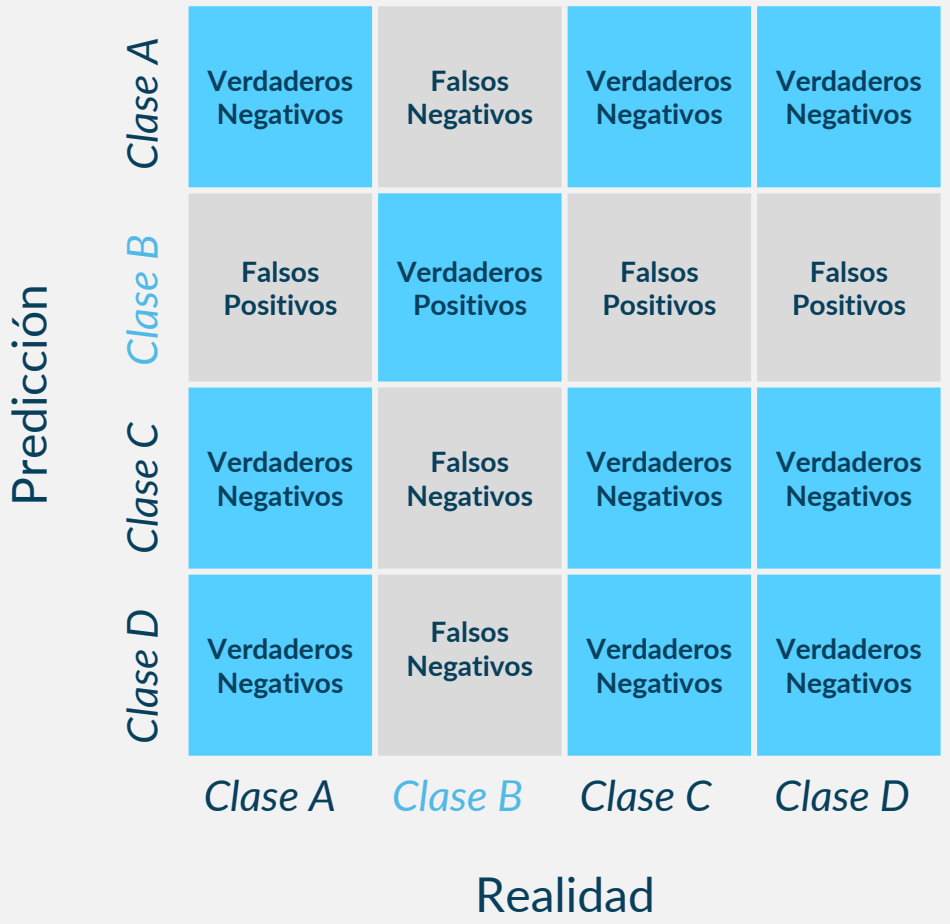
	precision	recall	f1-score	support
No Renuncia	0.86	0.97	0.91	177
Renuncia	0.60	0.24	0.35	37
accuracy			0.84	214
macro avg	0.73	0.60	0.63	214
weighted avg	0.81	0.84	0.81	214

Promedios ponderados

Matriz de confusión multiclase



Matriz de confusión multiclase



Algoritmos de clasificación

- K-Nearest Neighbor
- Logistic Regression
- Decision Trees
- Support Vector Machines
- Neural Networks
- Random Forest
- Gradient Boosting

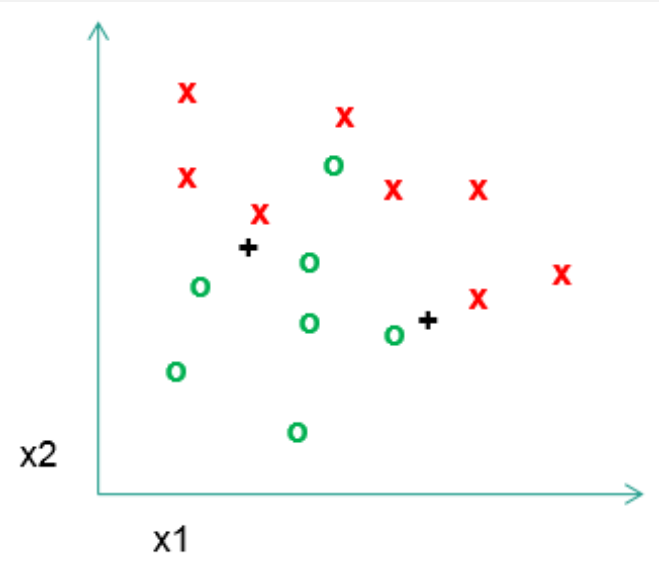
¿Cómo escoger el **mejor**?

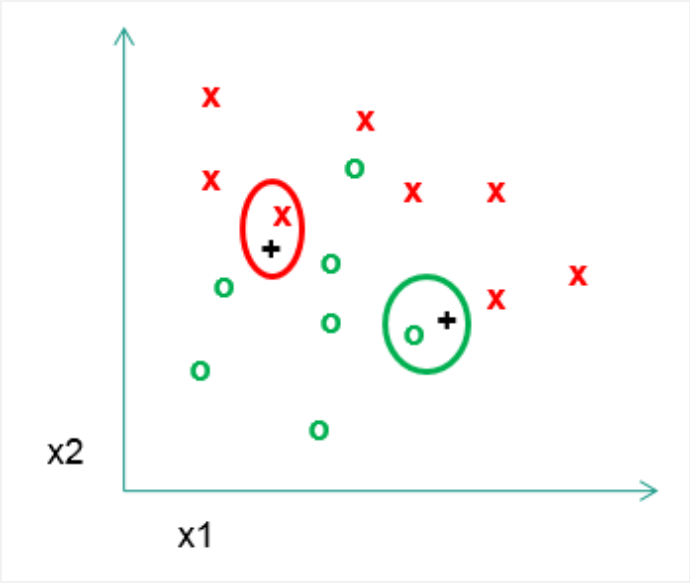
No free lunch theorem

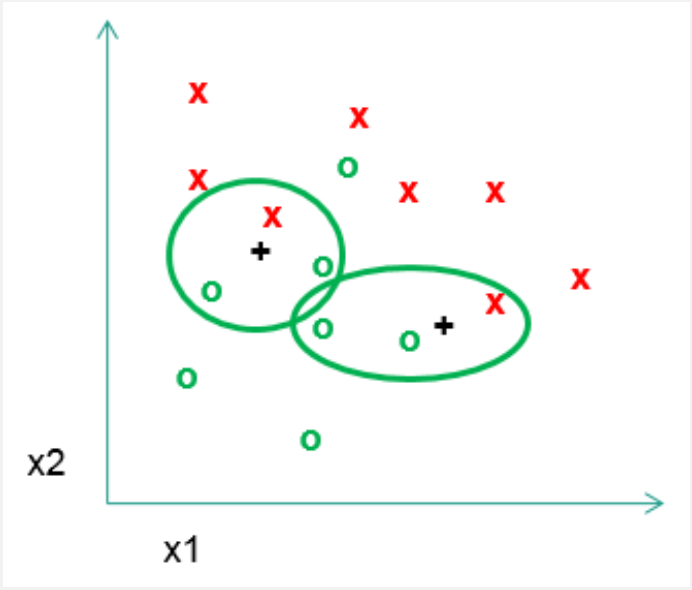


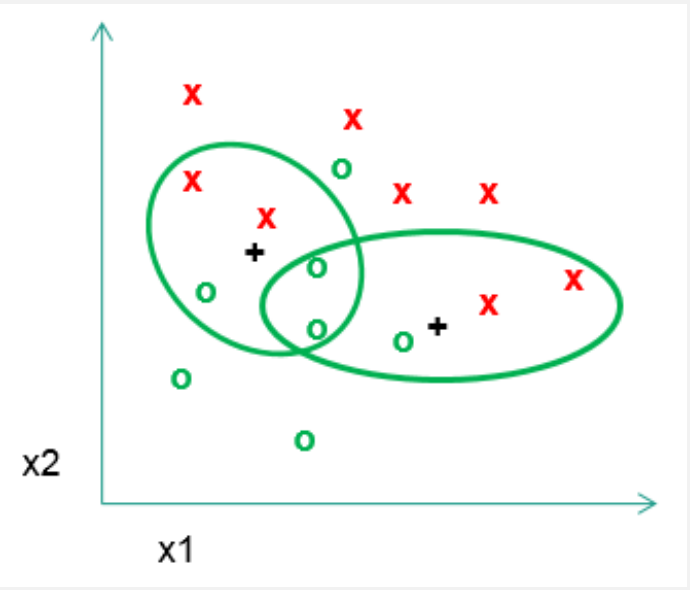
K-Vecinos más cercanos

Asigna la clase observando los datos de ‘entrenamiento’ **más cercanos**.







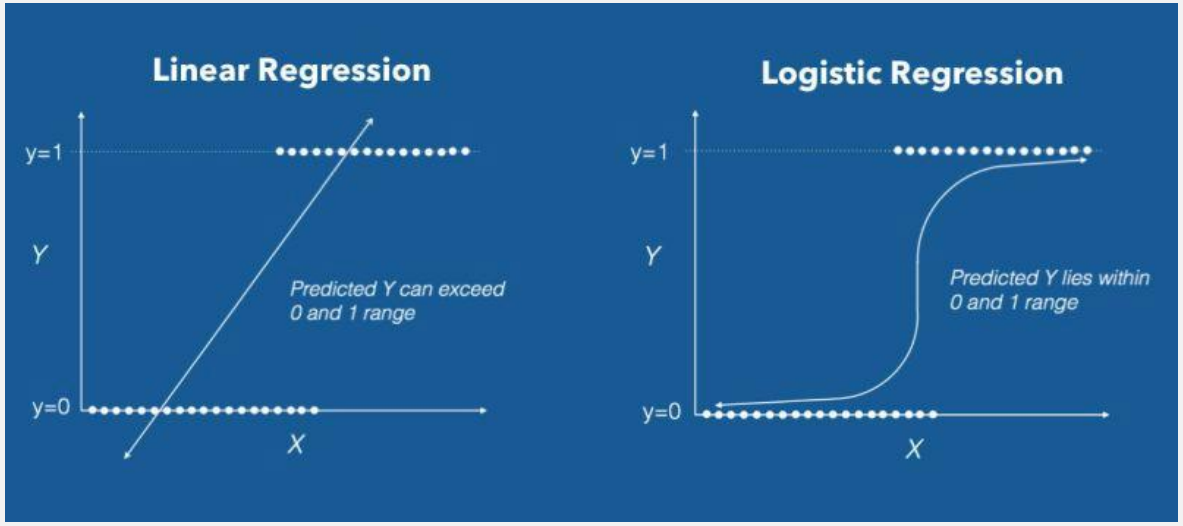


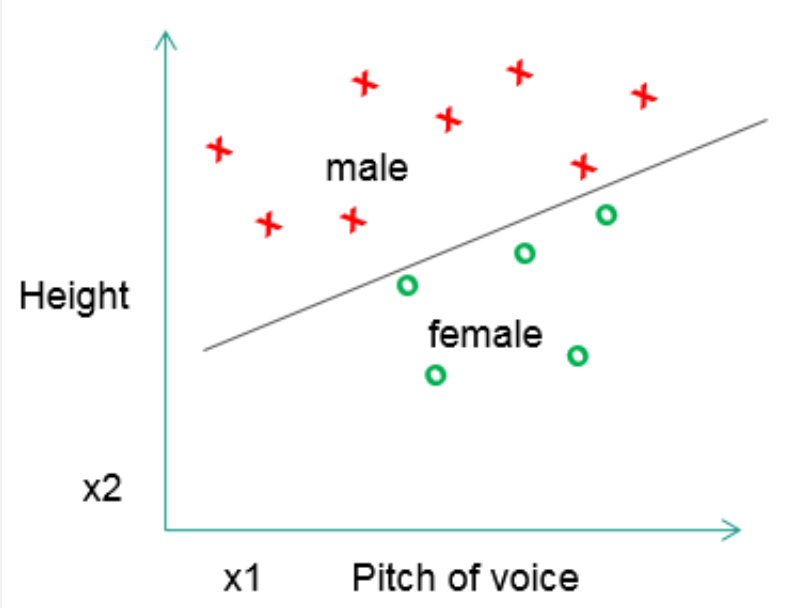
Regresión logística

Separa el espacio con un **límite lineal** buscando minimizar el **error de clasificación**.

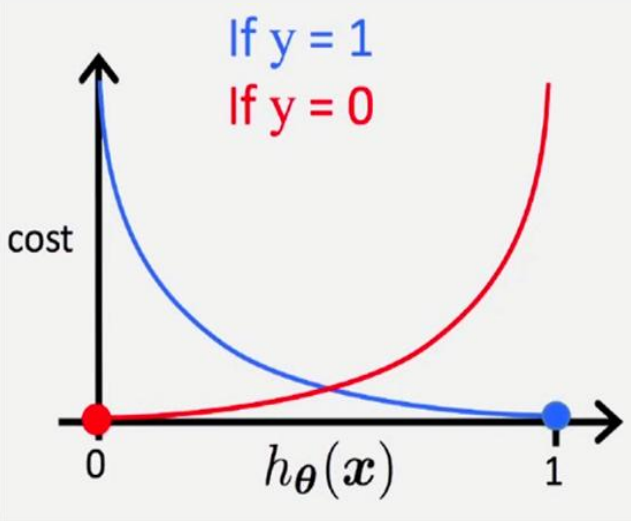
$$h\theta(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

Retorna una etiqueta con un nivel de confianza **probabilístico**.





Regresión logística



$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m} Cost(\, h_\theta(x^{(i)}), y^{(i)})$$

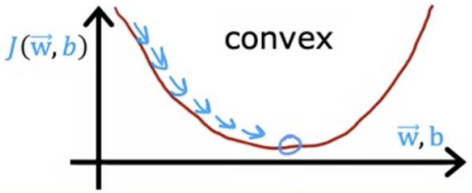
$$Cost(h_\theta(x)), y) = -\log\,(h_\theta(x)) \qquad if\ y = 1$$
$$Cost(h_\theta(x)), y) = -\log\,(1 - h_\theta(x)) \qquad if\ y = 0$$

$$J(\vec{w}, b) = \frac{1}{m}\sum_{i=1}^{m}\frac{1}{2}(f_{\vec{w},b}(\vec{x}^{(i)}) - y^{(i)})^2$$

loss $L\left(f_{\vec{w},b}(\vec{x}^{(i)}), y^{(i)}\right)$

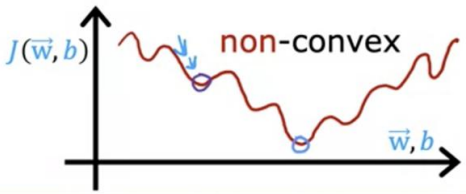
linear regression

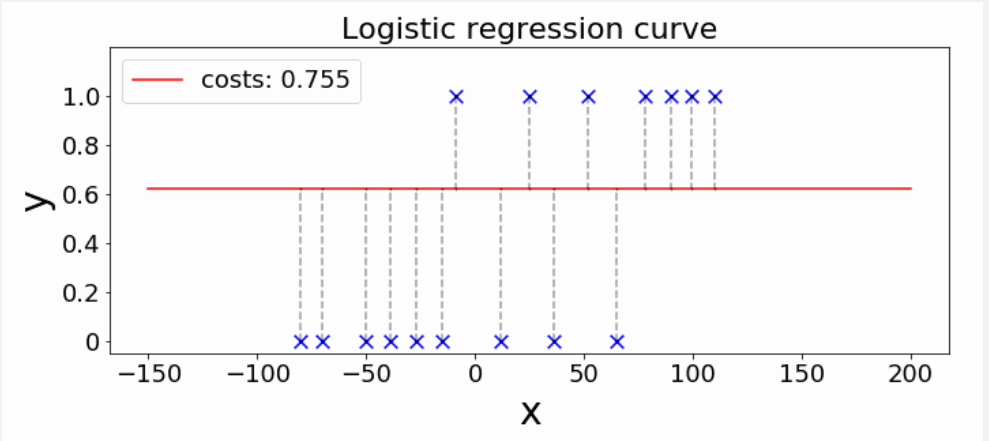
$$f_{\vec{w},b}(\vec{x}) = \vec{w}\cdot\vec{x} + b$$



logistic regression

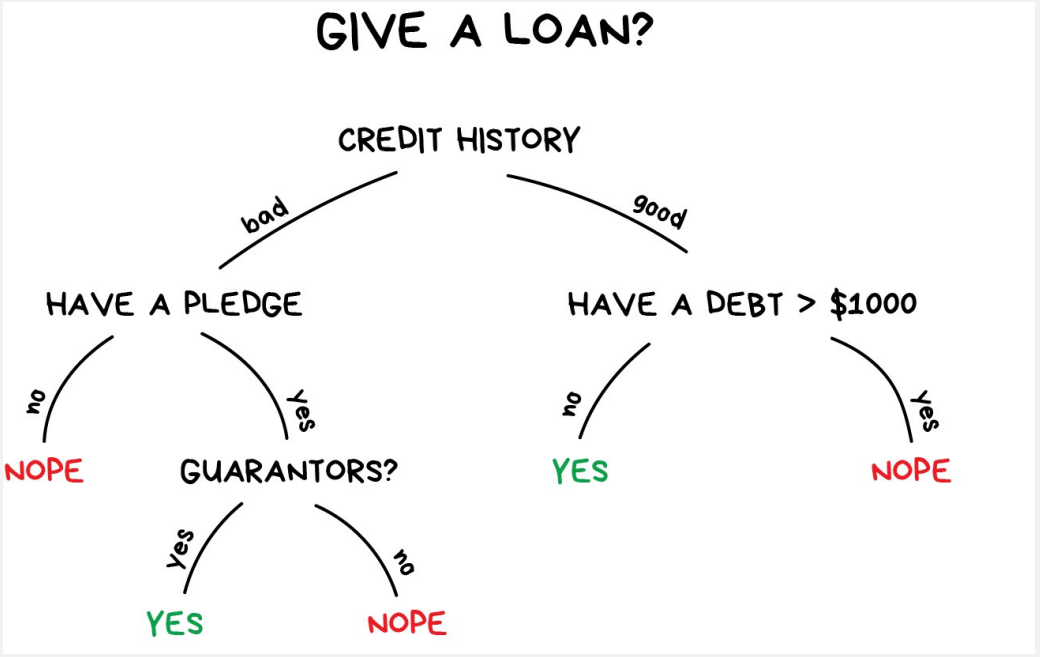
$$f_{\vec{w},b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w}\cdot\vec{x}+b)}}$$

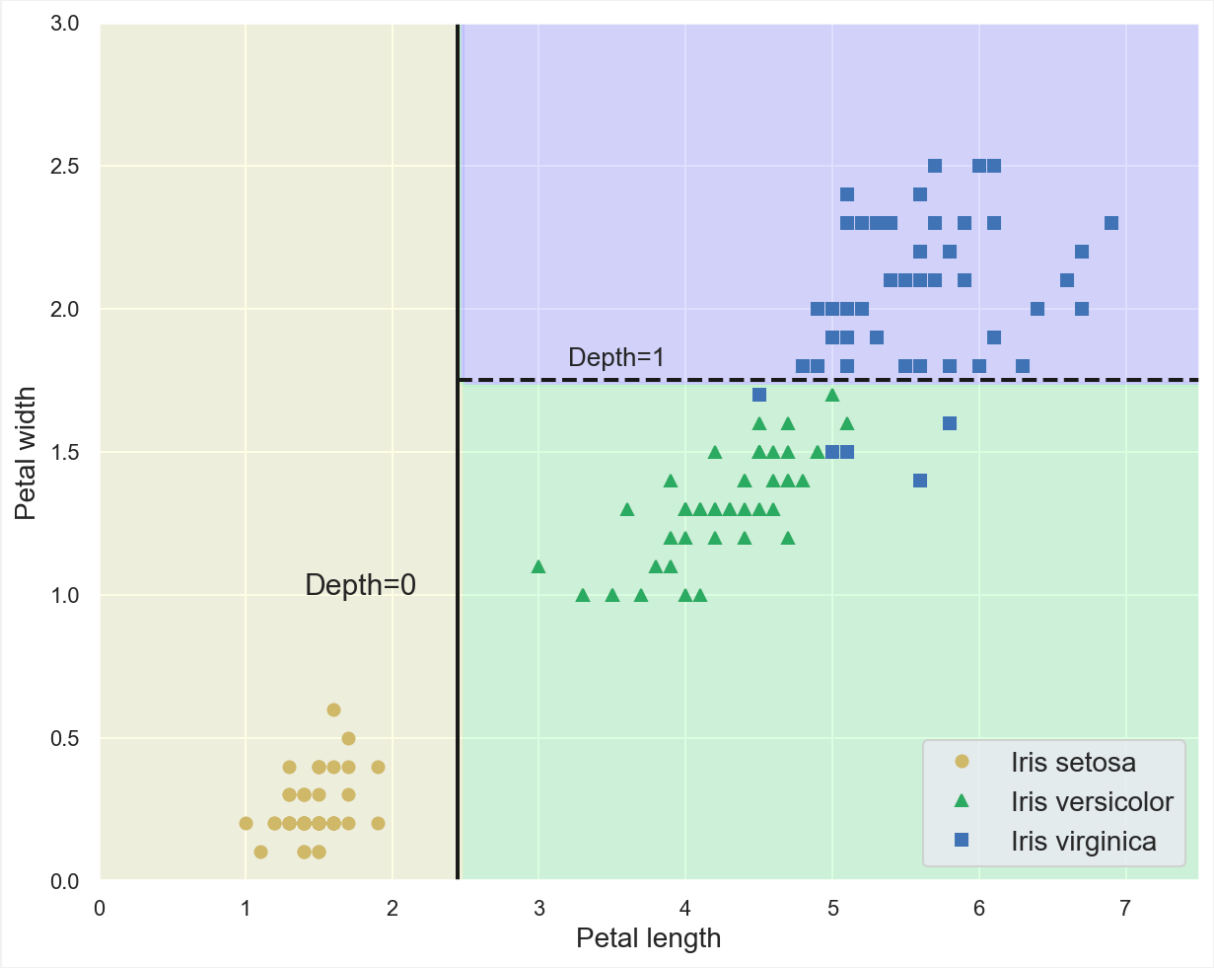




Árboles de decisión

Basado en **reglas de decisión** consecutivas para la asignación de la clase.



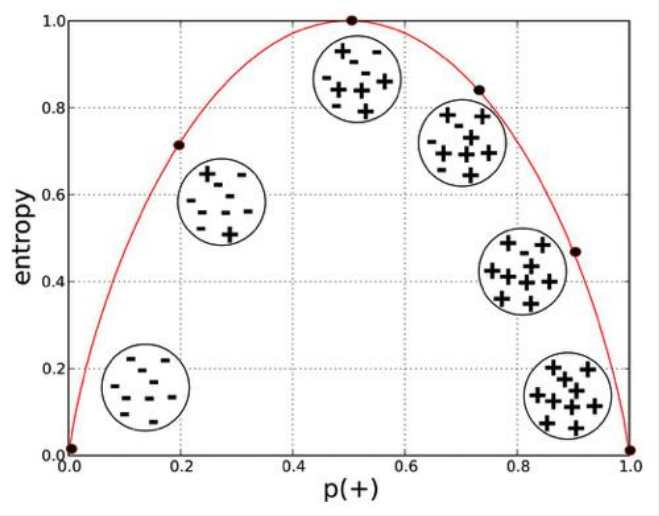


Árboles de decisión

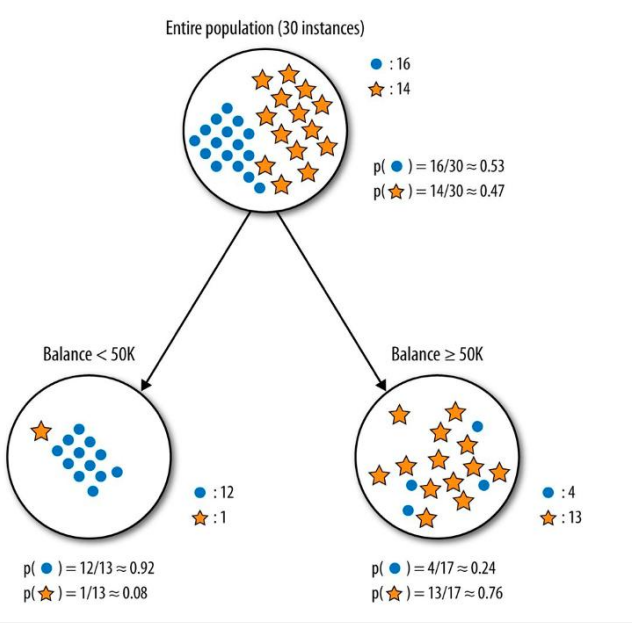
$$E = \sum_{i=1}^{C} -p(i)\log_2 p(i)$$

$$G = \sum_{i=1}^{C} p(i) * (1 - p(i))$$

Alta **entropia**, baja **pureza**

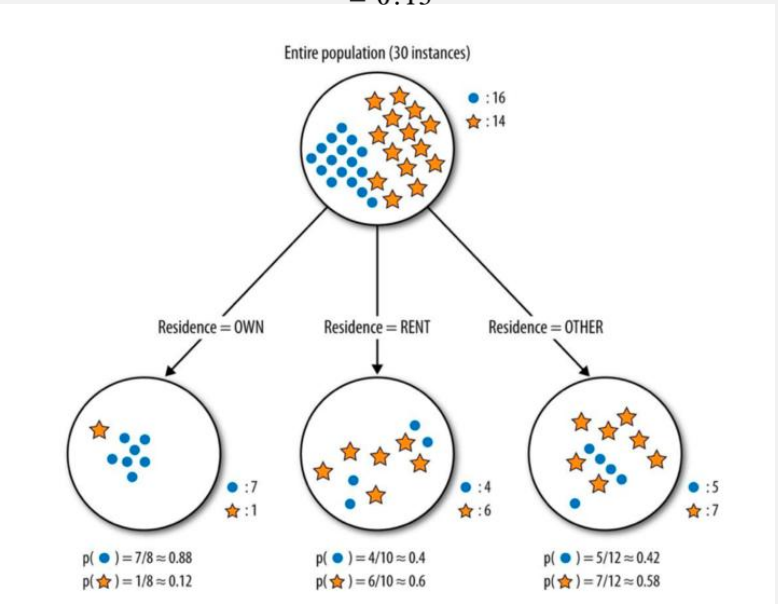


$$IG(Y, X) = E(Y) - E(Y|X)$$



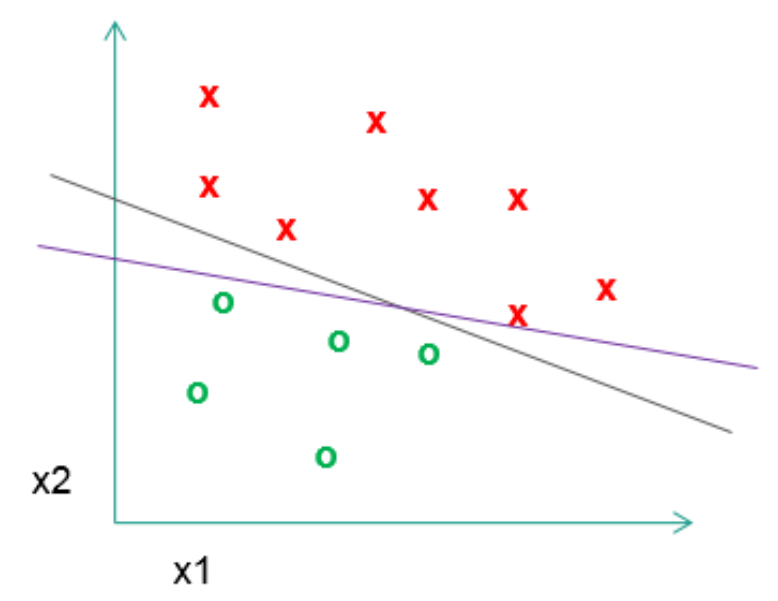
$$IG(Parent, Balance) = E(Parent) - E(Balance)$$
$$= 0.99 - 0.62$$
$$= 0.37$$

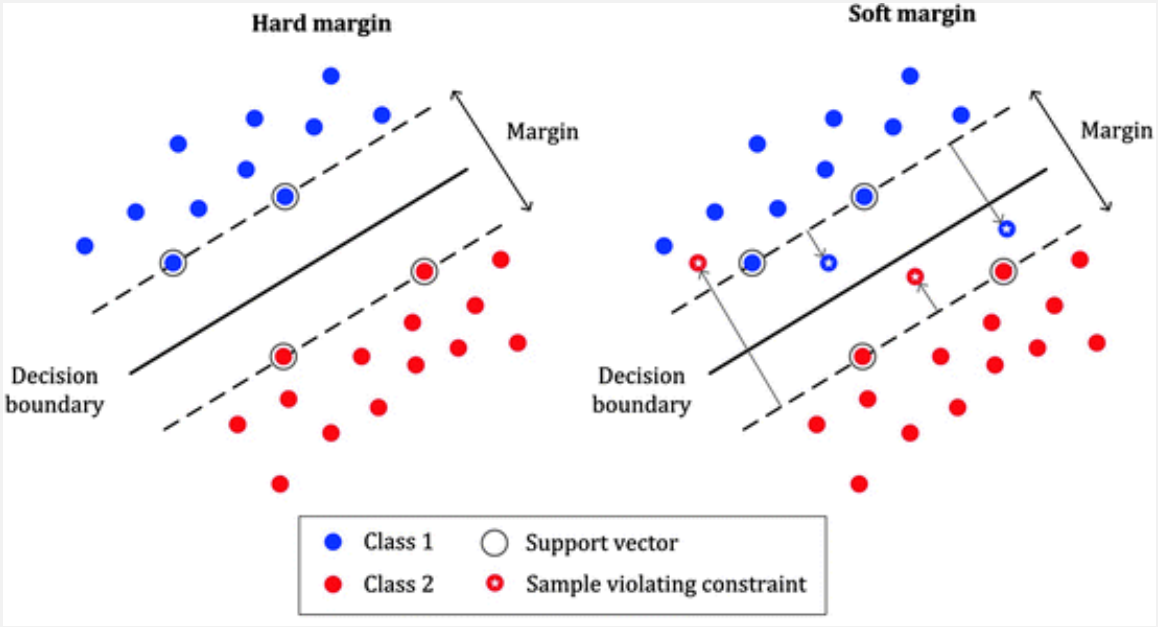
$$IG(Parent, Residence) = E(Parent) - E(Residence)$$
$$= 0.99 - 0.86$$
$$= 0.13$$



Support Vector Machines

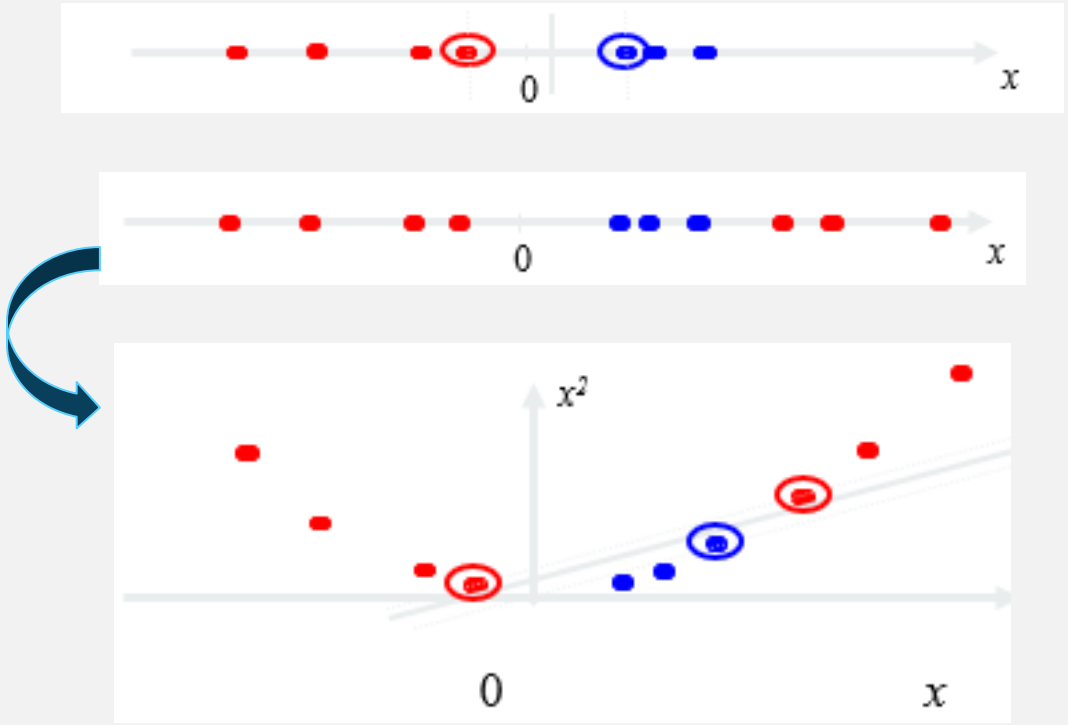
Encuentra una función lineal para separar las clases buscando lograr **máxima separabilidad**.

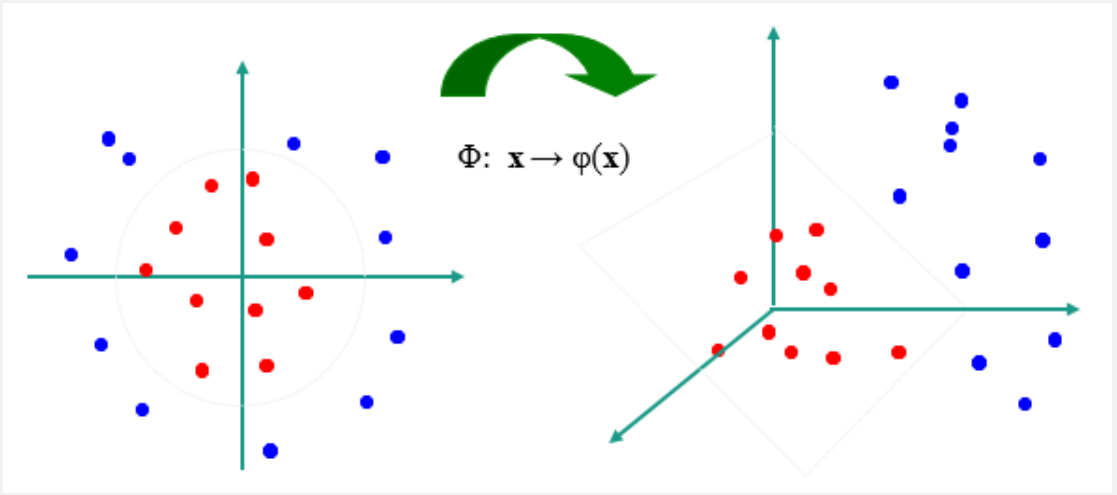




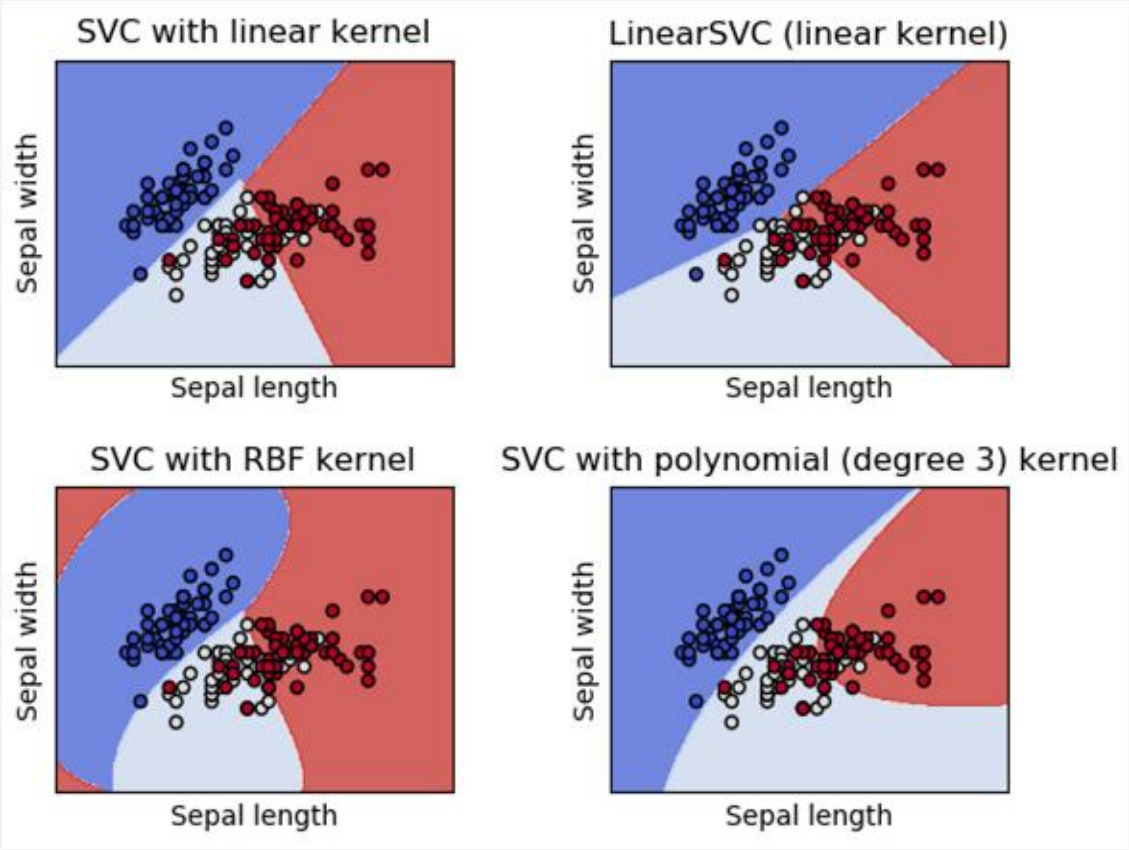
Support Vector Machines

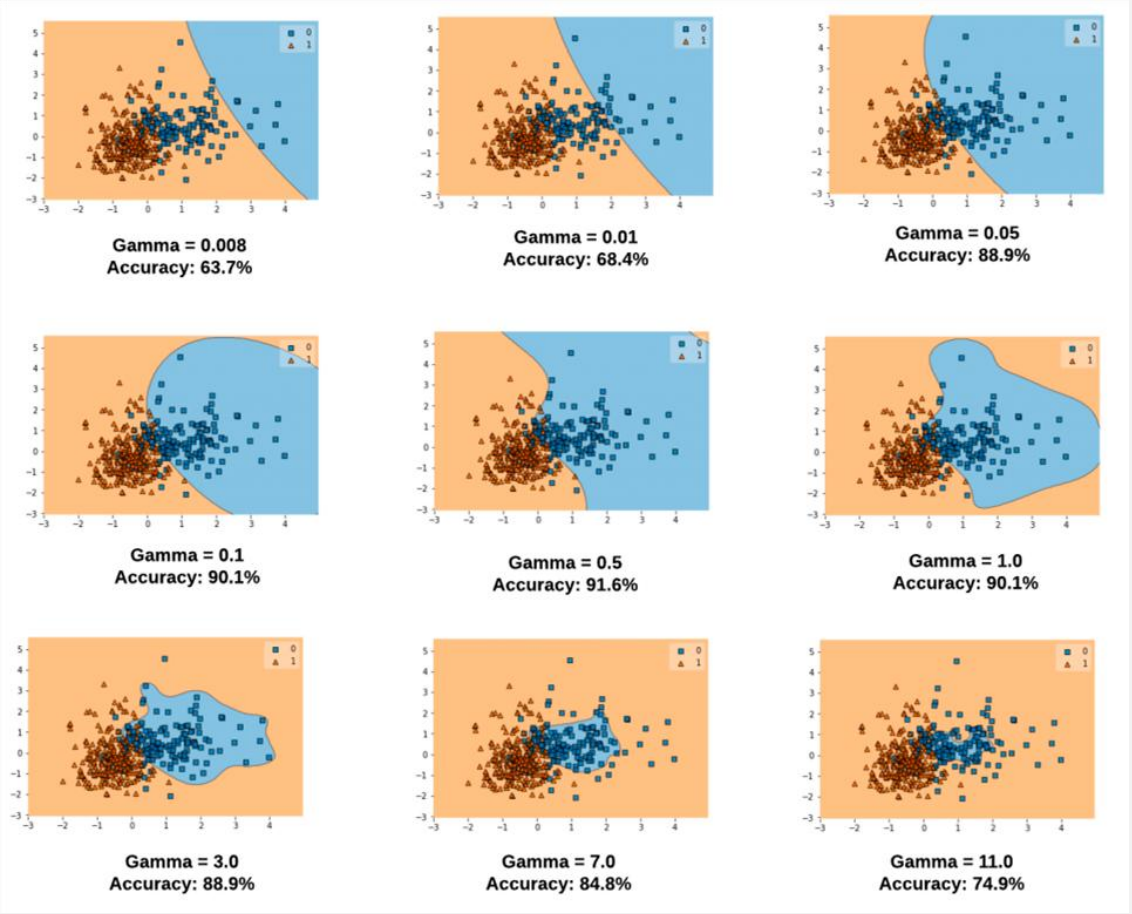
El espacio de entrada siempre se puede **mapear a uno de mayor dimensión** que permita la separabilidad lineal





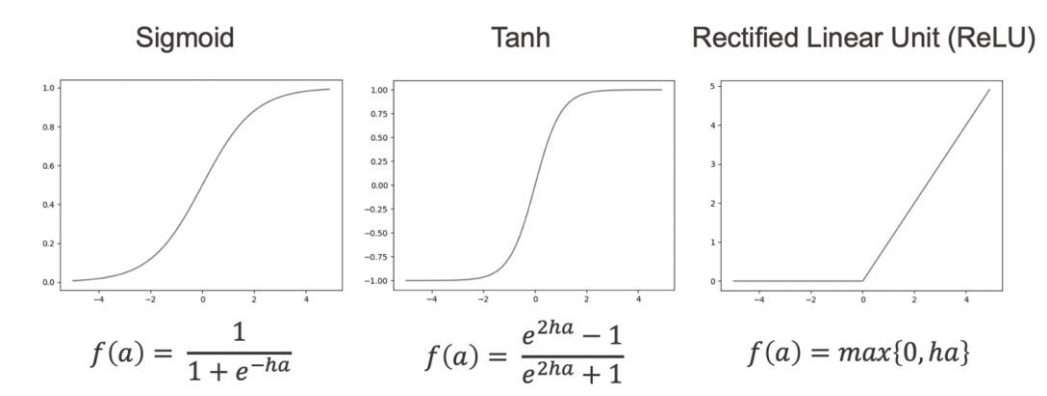
Support Vector Machines

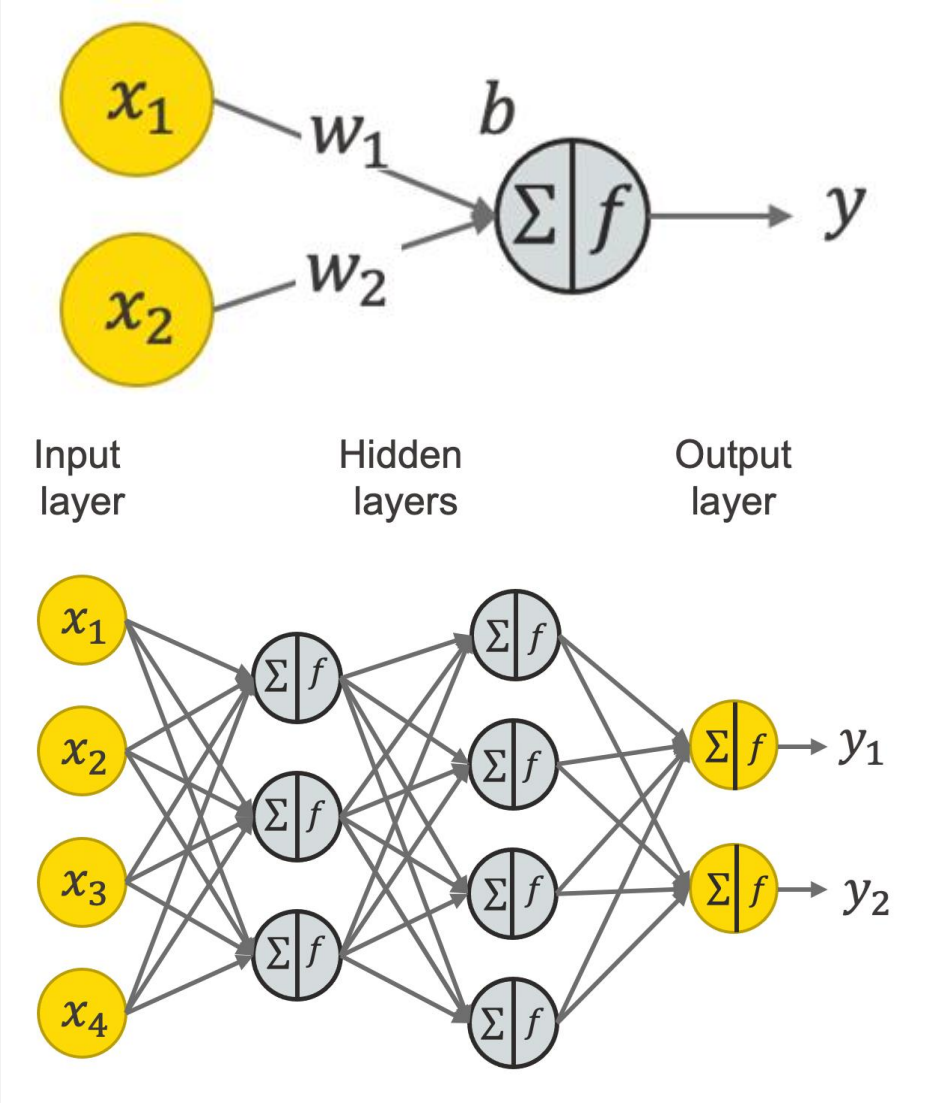




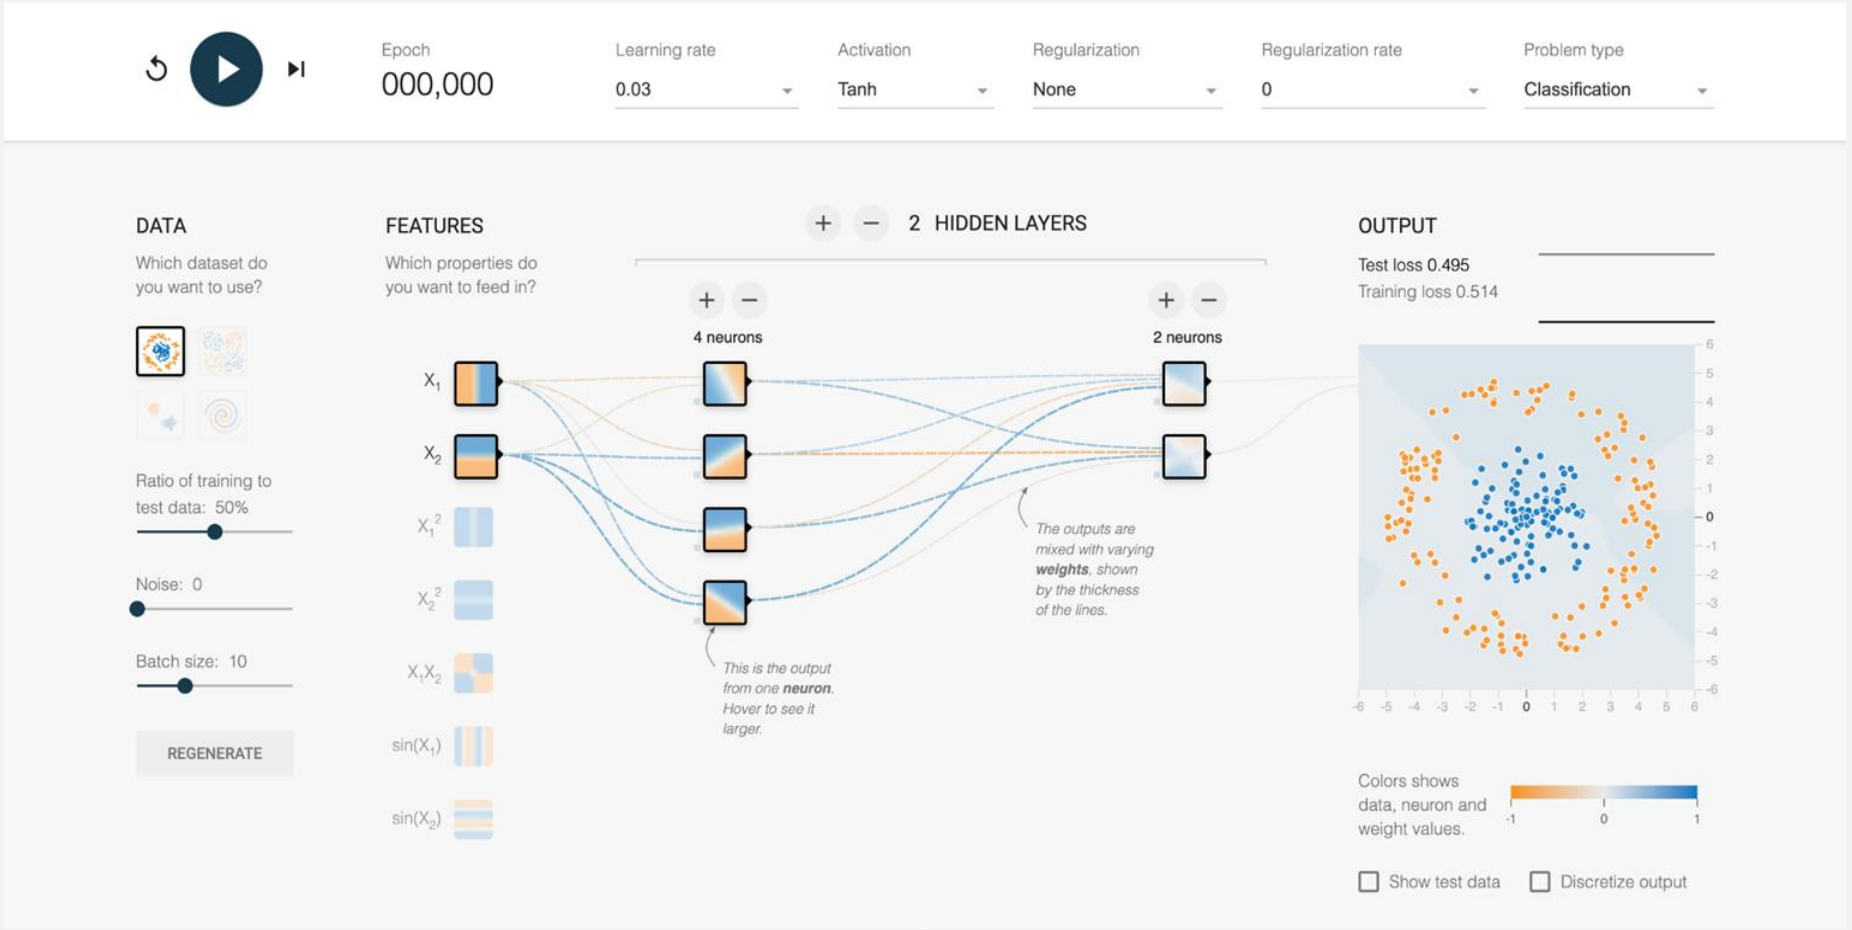
Redes Neuronales

Recordemos la regresión logística …





Redes Neuronales



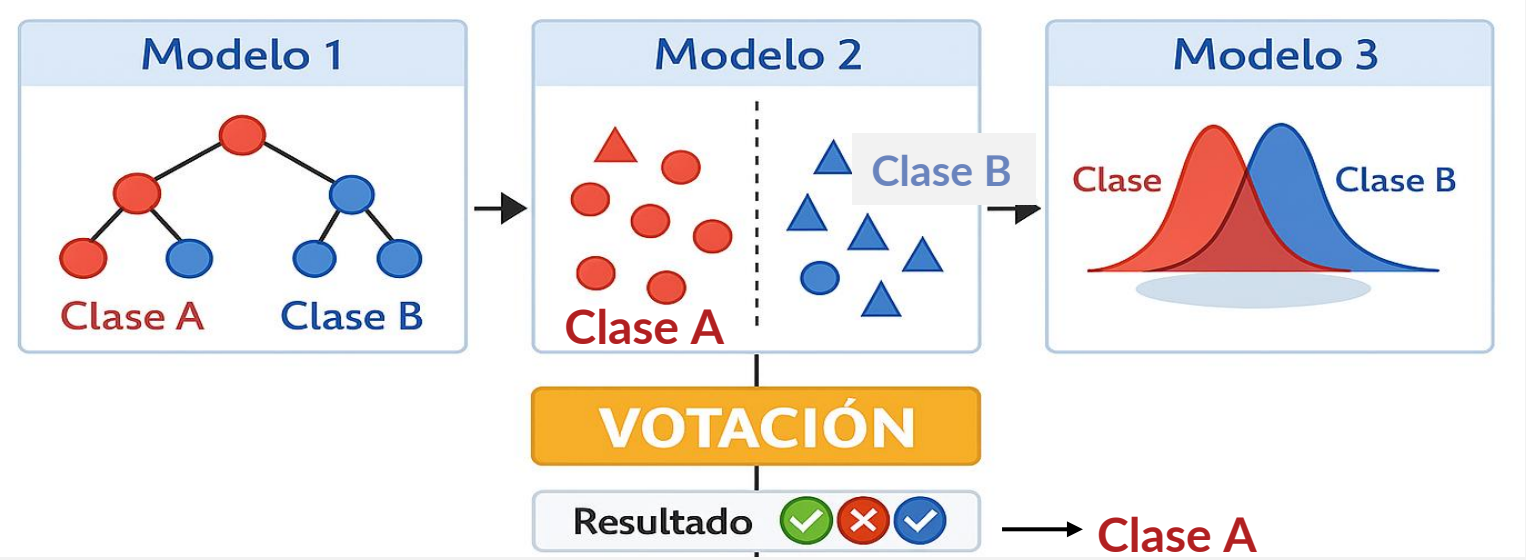
Métodos de ensamble: Random Forest

Objetivo: Utilizar **múltiples clasificadores débiles** (árboles de decisión) en conjunto para **aumentar la capacidad de predicción** de la variable objetivo.

Procedimiento:

1. Realizar muestreo con reemplazo (***bootstrapping***) con probabilidad ***1/m*** del dataset de entrenamiento original para obtener diferentes datasets de entrenamiento.
2. Para el entrenamiento de un modelo para cada dataset muestreado, utilizar diferentes subconjuntos de las *features* disponibles.
3. Para la predicción de una nueva instancia, realizar el cálculo de la variable objetivo sobre cada árbol y someter a votación para obtener la etiqueta resultante.

Métodos de ensamble: Random Forest



Modelos de votación: El resultado corresponde a:

* Votación dura – mayoría de votos
* Votación suave
  - Promedio de las probabilidades de pertenencia a una clase
  - Aplica a modelos que dan como resultado una probabilidad de pertenecer a una clase

Métodos de ensamble: Gradient Boosting

Objetivo: Utilizar **múltiples clasificadores débiles** (árboles de decisión) en conjunto para **aumentar la capacidad de predicción** de la variable objetivo.

Procedimiento:

1. Realizar muestreo con reemplazo (*bootstrapping*) con probabilidad *1/m* del dataset de entrenamiento original para obtener diferentes datasets de entrenamiento.
   - **Aquellas instancias de datos para las que los modelos previamente entrenados se equivocan más, tendrán una mayor probabilidad de ser elegidos para conformar el nuevo dataset.**
2. Para el entrenamiento de un modelo para cada dataset muestreado, utilizar diferentes subconjuntos de las *features* disponibles.
3. Para la predicción de una nueva instancia, realizar el cálculo de la variable objetivo sobre cada árbol y someter a votación para obtener la etiqueta resultante.

Métodos de ensamble: Gradient Boosting

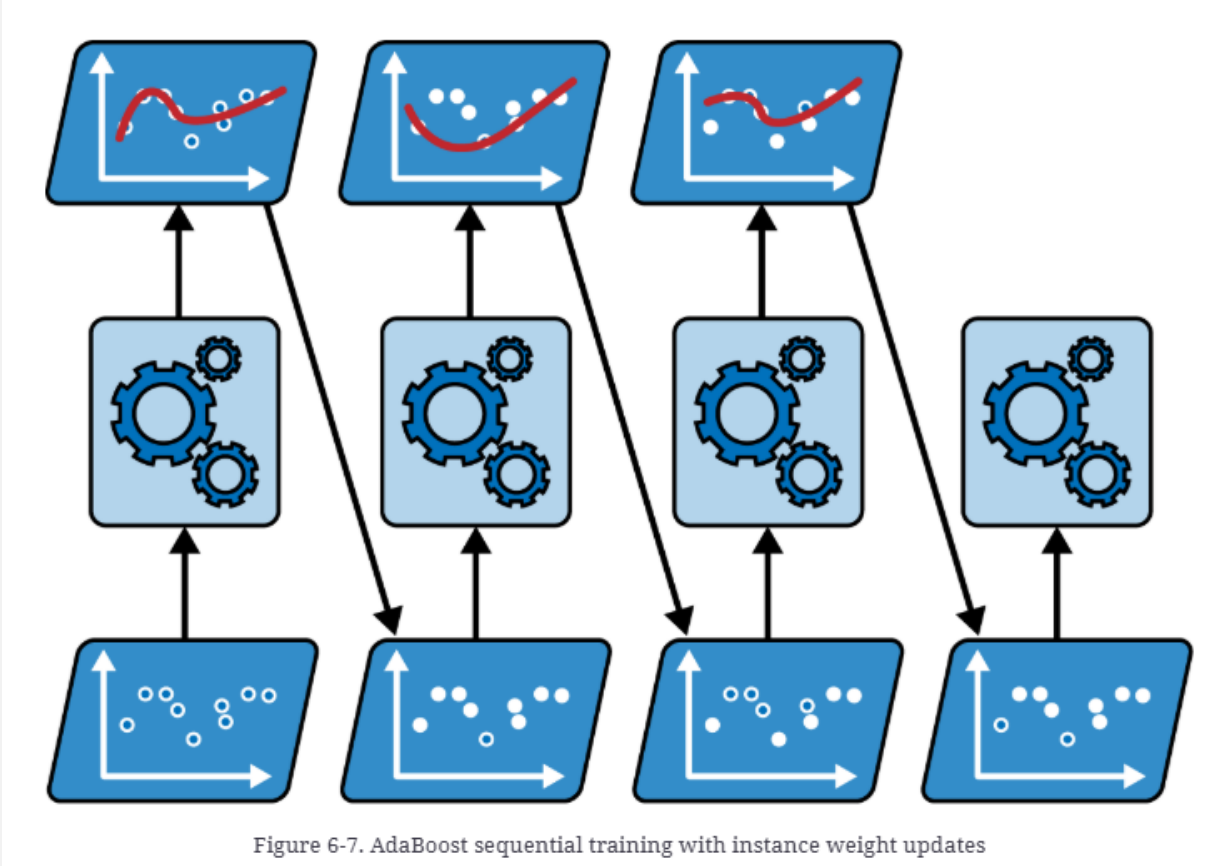
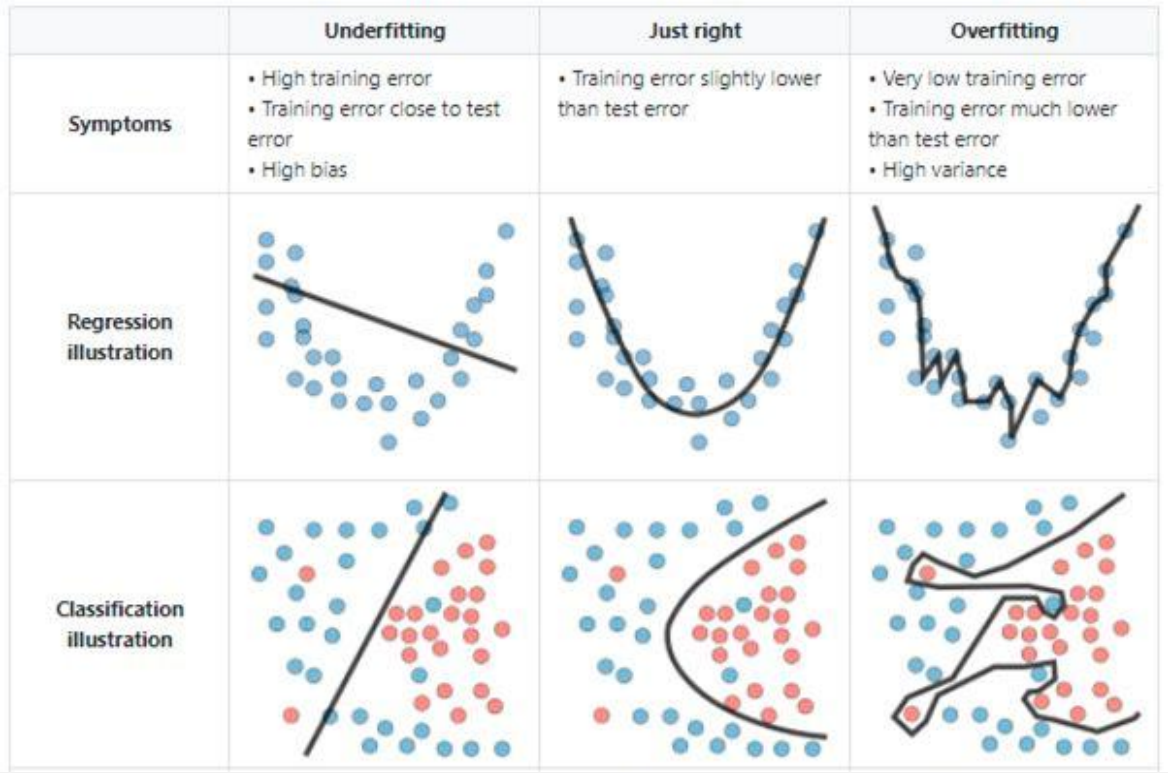


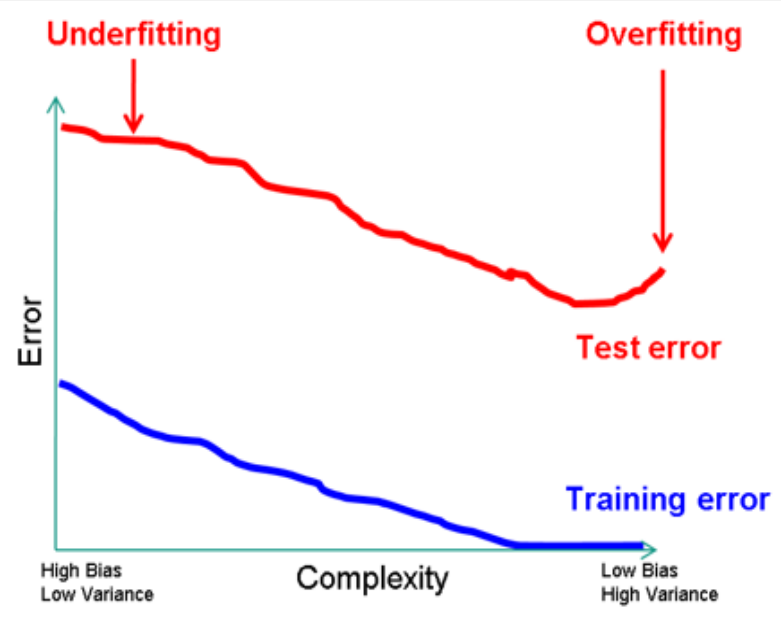
Figure 6-7. AdaBoost sequential training with instance weight updates

¿Existen los modelos perfectos?

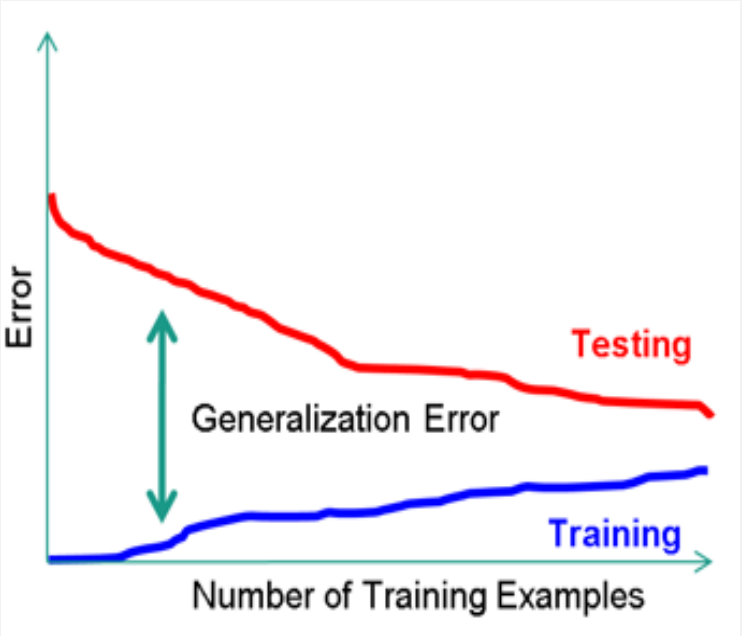
- Datos de entrenamiento insuficientes.
- Muy pocos atributos relevantes para la discriminación.
- Muchos atributos, pero irrelevantes.
- Complejidad del modelo insuficiente o innecesaria.



Balance entre sesgo y varianza







Para tener en cuenta…

- *No free lunch theorem*.
- Utilizar clasificadores sencillos al principio.
- Es mejor tener un buen conjunto de características y clasificadores simples que características malas y buenos clasificadores.
- Emplear clasificadores potentes con muchos datos de entrenamiento.

¿Preguntas?