MINE4101-Ciencia de Datos Aplicada

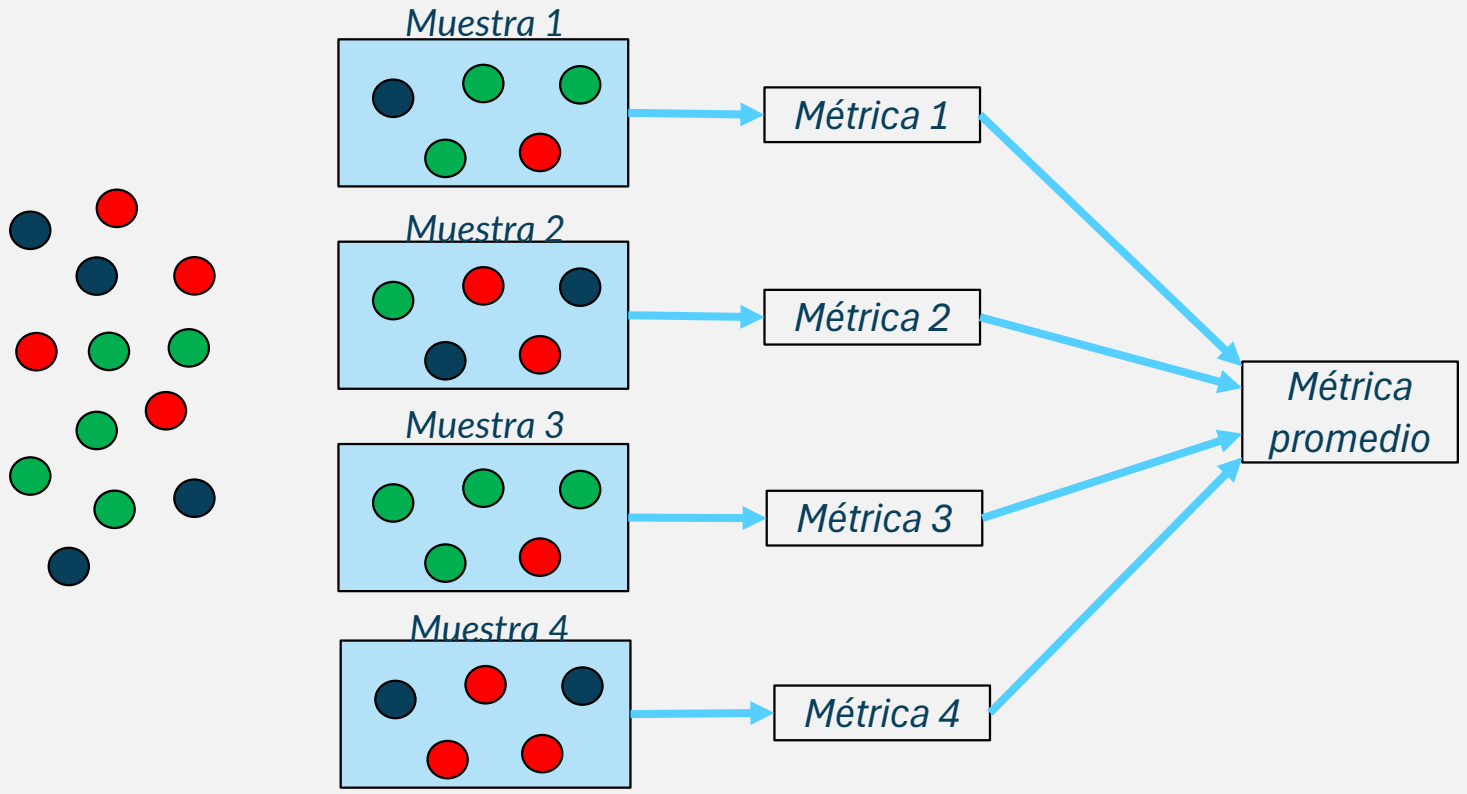
Universidad de los Andes Colombia | Departamento de Ingeniería de Sistemas y Computación

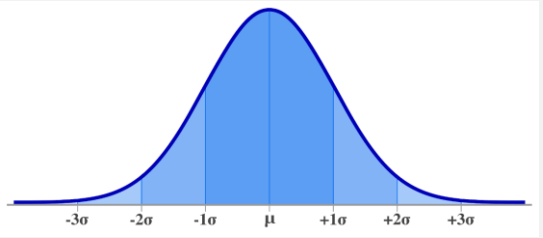
Evaluación avanzada de modelos, rigor estadístico y medición de impacto

Reconocimiento como Universidad: Decreto 1297 del 30 de mayo de 1964.
Reconocimiento personería jurídica: Resolución 28 del 23 de febrero de 1949 Minjusticia

Bootstrapping

El proceso de bootstrap consiste en seleccionar varias muestras con reemplazo para calcular las métricas de un modelo dado





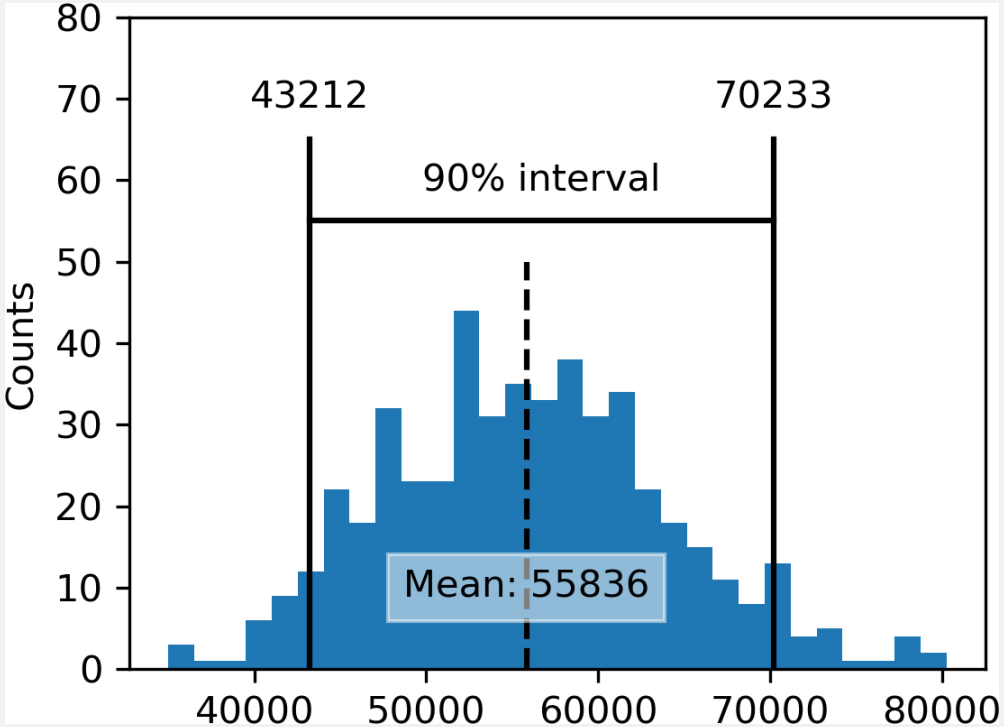
Bootstrapping

El algoritmo se puede entender como:

1. Seleccionar una muestra, registrarla y reemplazarla.
2. Repetir n veces.
3. Registrar la media de los n valores muestreados.
4. Repetir los pasos 1 a 3 durante R iteraciones.
5. Usar los R resultados para:
    - Calcular la desviación estándar
    - Producir un histograma
    - Encontrar intervalos de confianza.

Bootstrapping – Intervalos de confianza

Permite entender el potencial errar de una muestra, codificando un nivel de confianza. Se expresa con un nivel de cobertura (x%) indicando el porcentaje de muestras que en promedio deberían estar en un rango determinado.



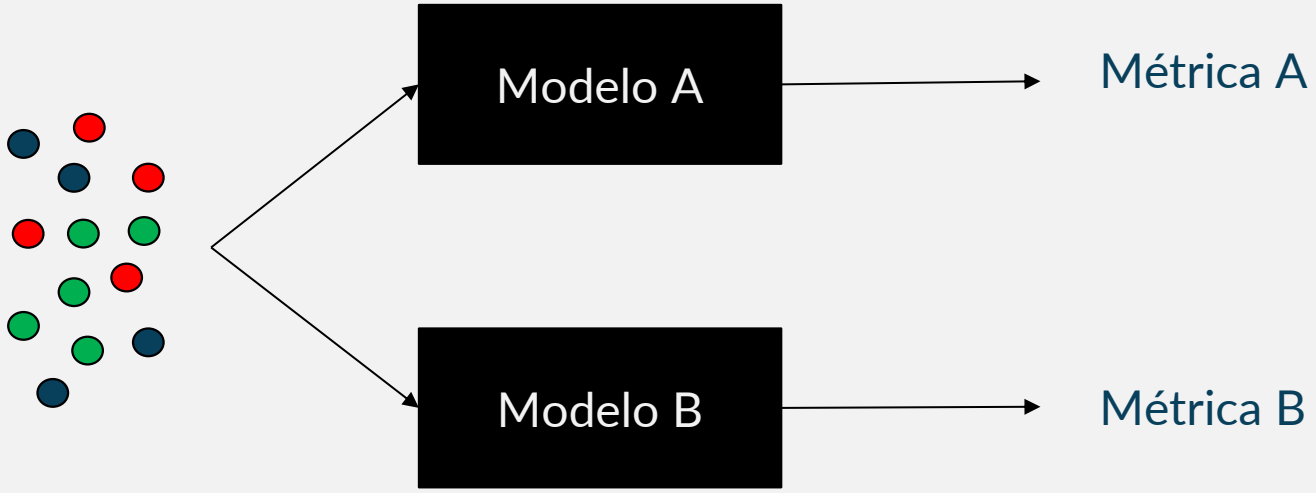
Comparación de modelos

Dados dos modelos diferentes, ¿cuál es mejor? ¿significa una mejora que un modelo es superior al otro sin importar su magnitud?

Otro factor importante corresponde al momento de comparación. ¿Estamos en la etapa de ingeniería del modelo? ¿O en el monitoreo post-despliegue?

Pruebas A/B

Una prueba A/B es un experimento con dos grupos para determinar cuál es superior. En el contexto de Ciencia de Datos, se puede usar para determinar qué modelo tiene efectivamente mejor rendimiento que otro sobre un conjunto de datos dado. Las pruebas A/B se construyen como pruebas de hipótesis, con la hipótesis examinada siendo que el modelo A es mejor que el modelo B.



Pruebas A/B con bootstrapping

Cuando se tienen **pruebas pareadas** (el modelo se aplica sobre el mismo conjunto de datos).

1. Se predicen las etiquetas para los datos por modelo A y modelo B.
2. Se determinan los aciertos obtenidos por cada modelo.
3. Se realiza bootstrapping con varias iteraciones, remuestreando el conjunto en el tamaño de y, registrando las diferencias de las medias.
4. Se calculan los intervalos de confianza asociados a las medias.
5. Si el interval de confianza excluye a cero y además la diferencia de las medias es mayor que el umbral relevante, se considera que los modelos son diferentes.

Pruebas A/B con bootstrapping

Cuando se tienen **grupos independientes** (el modelo se aplica sobre conjuntos diferentes de datos).

1. Se predicen las etiquetas para los datos por modelo A y modelo B.
2. Se determinan los aciertos obtenidos por cada modelo.
3. Se realiza el bootstrapping independientemente por cada grupo, se calcula la media de aciertos por cada población y se registran las diferencias.
4. Se calculan los intervalos de confianza asociados a la diferencia.
5. Si el interval de confianza excluye a cero y además la diferencia de las medias es mayor que el umbral relevante, se considera que los modelos son diferentes.

Pruebas A/B – t-test

En **grupos independientes** podemos aplicar t-test. Esta prueba permite determiner si la diferencia entre los dos resultados es más grande de la propia del muestreo.

$$t = \frac{\bar{x}_B - \bar{x}_A}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

De donde podemos obtener el valor-p con la siguiente formula:

$$p = 2P\left(T_{df} \geq |t|\right) = 2(1 - F_{t,df}(|t|)$$

H_o: no existen diferencias significativas entre las distribuciones.

Pruebas A/B – t-test

En **pruebas pareadas** podemos aplicar t-test. Esta prueba permite determiner si la diferencia entre los dos resultados es más grande de la propia del muestreo.

$$t = \frac{\bar{d}}{S_d/\sqrt{n}}$$

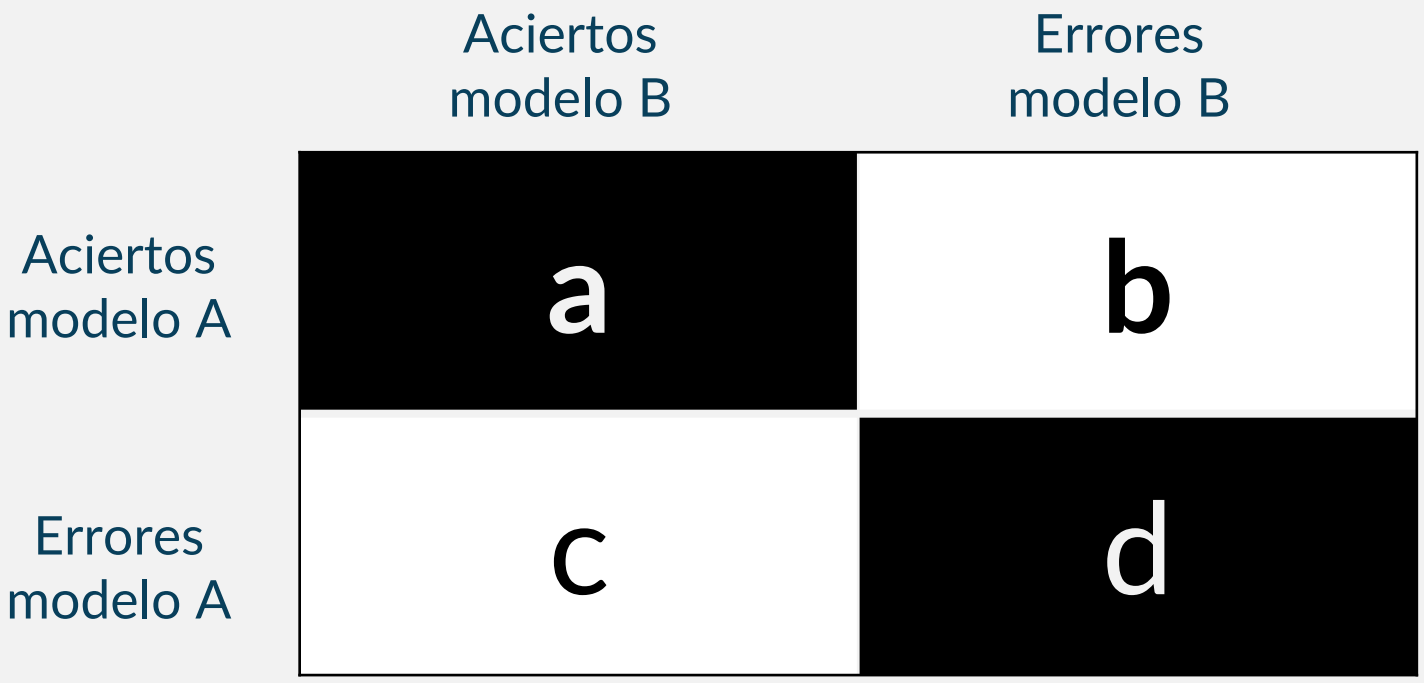
De donde podemos obtener el valor-p con la siguiente formula:

$$p = 2P\left(T_{df} \geq |t|\right) = 2(1 - F_{t,df}(|t|)$$

H_o: no existen diferencias significativas entre las distribuciones.

Pruebas A/B – test de McNemar

Es un tipo de **prueba pareada** en datos nominales aplicada sobre tablas de contingencia para determiner si las frecuencias marginales de filas y columnas son iguales (homogeneidad marginal).

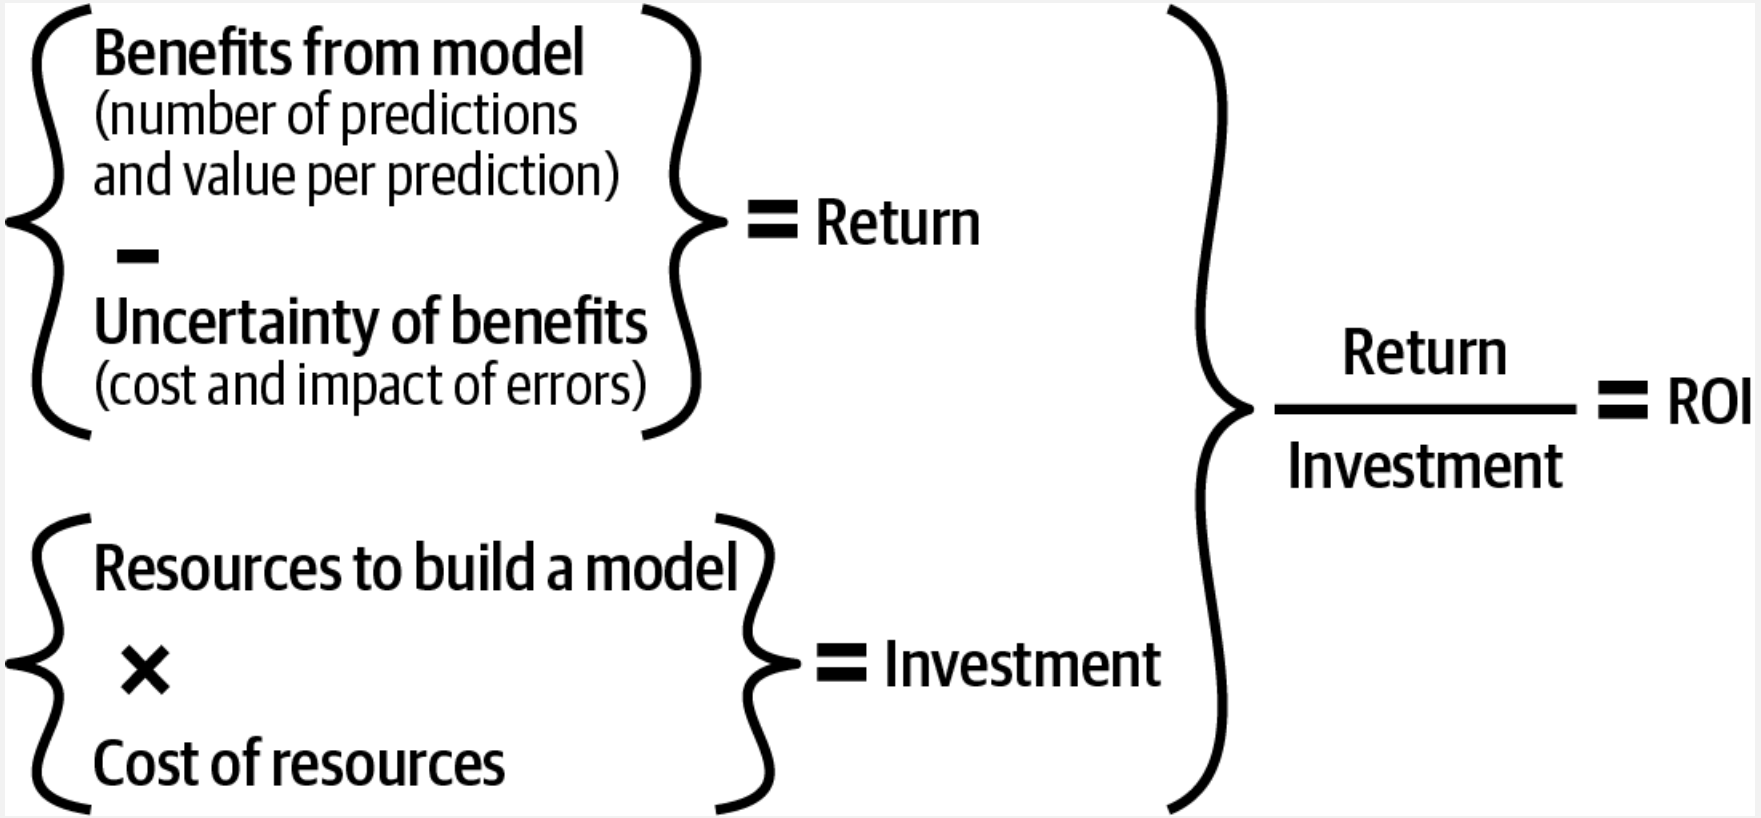


$$\chi^2 = \frac{(b-c)^2}{b+c}$$

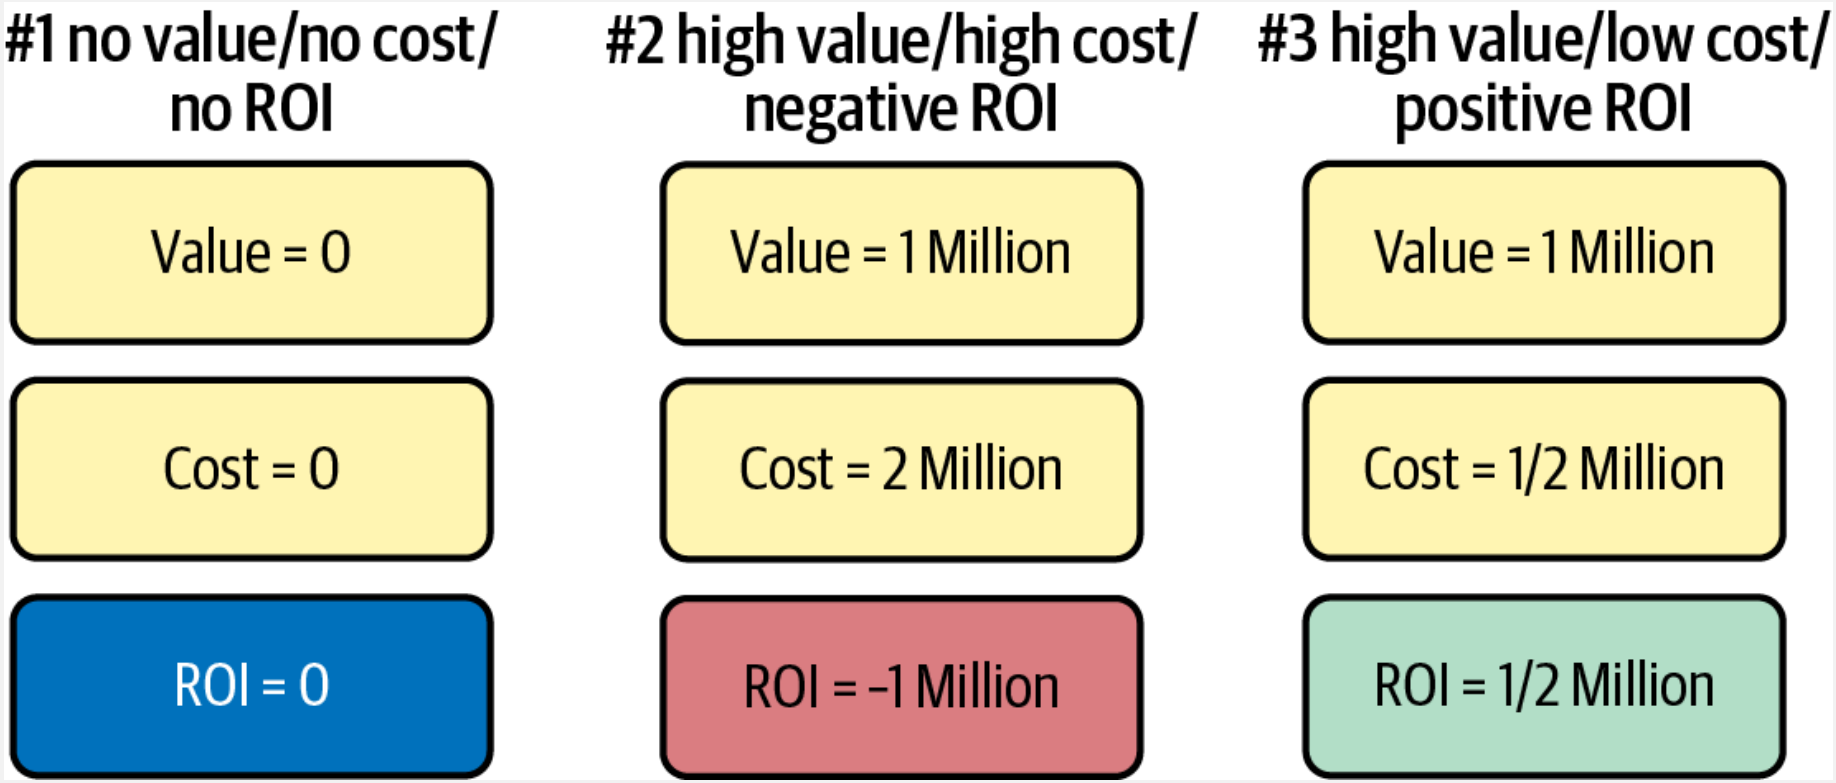
Si el resultado de χ^2 es significativo, se prove suficiente evidencia para rechazar la hipótesis nula.

Medición de impacto

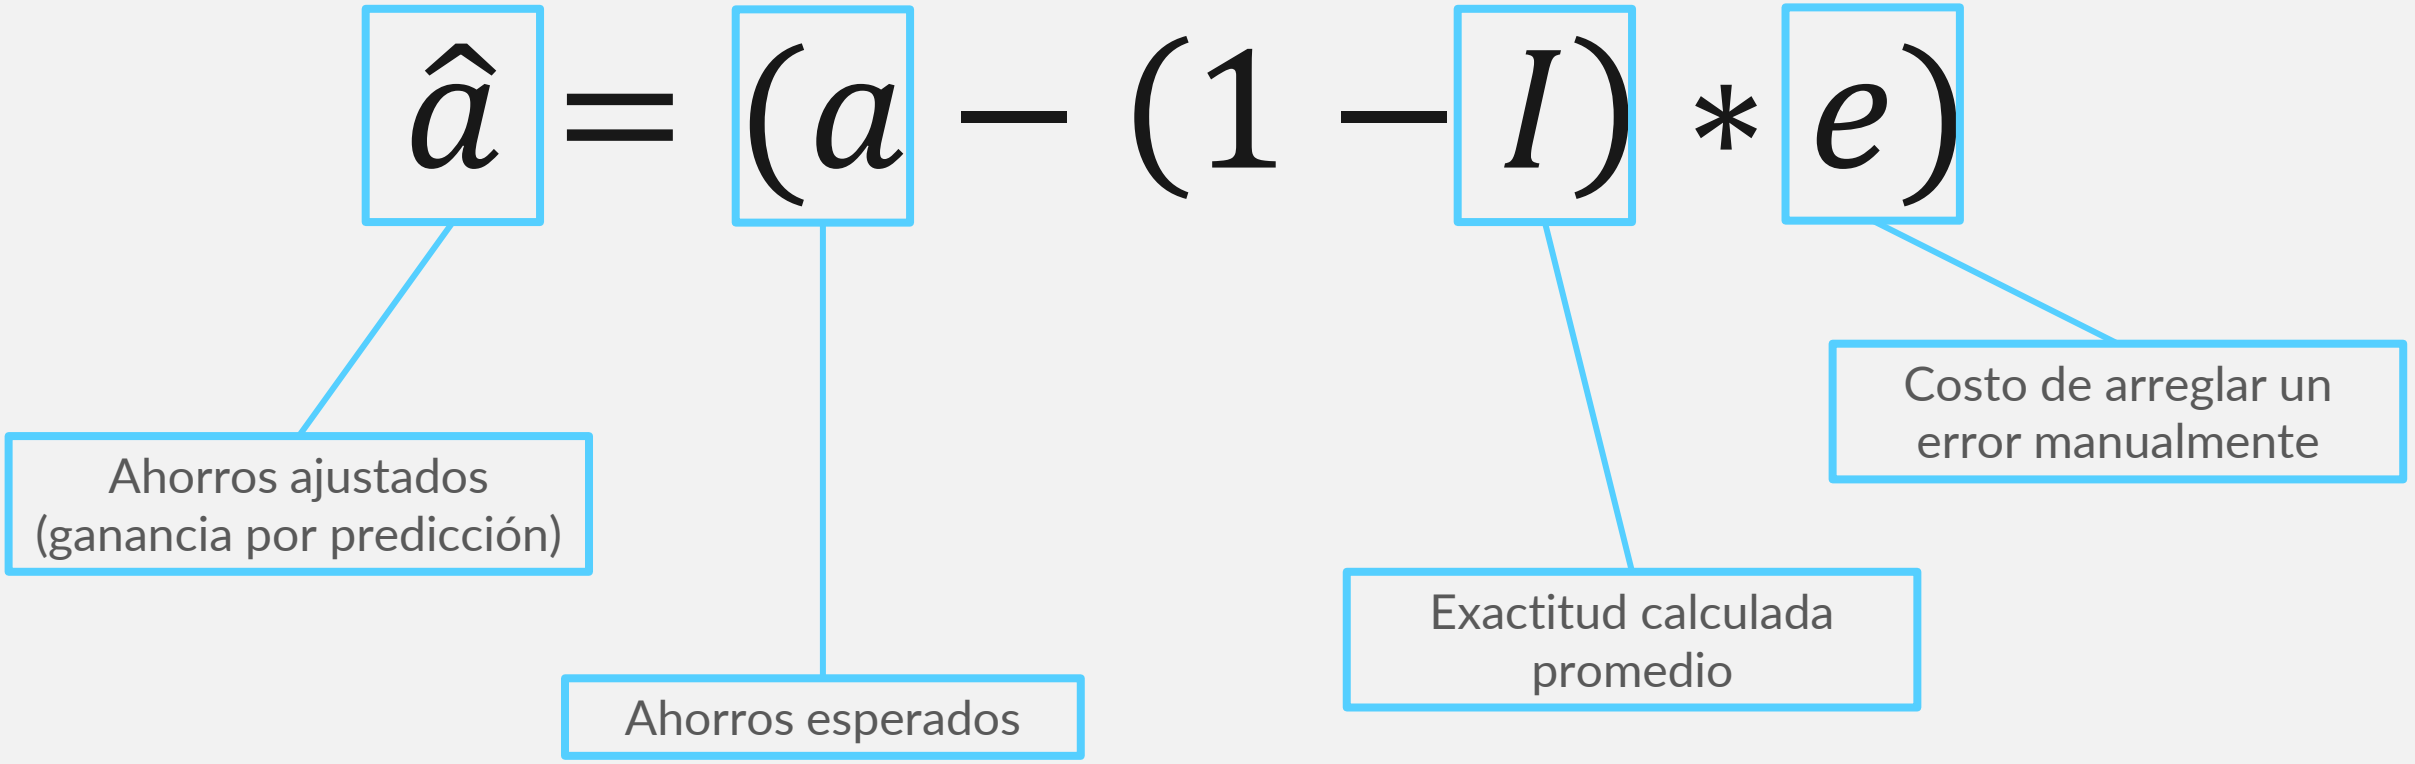
Retorno de Inversión (ROI)



Retorno de Inversión (ROI)



Ganancias por predicción ajustada



Ganancias por predicción ajustada

$$P_e = 1 - \frac{a}{e}$$

Exactitud de equilibrio (break-even)

La exactitud de equilibrio es la exactitud a partir de la cual el modelo es rentable para producir beneficios.

Ejemplo – readmisión de pacientes

El costo de readmisión* de pacientes en un hospital de gran tamaño tiene una proporción grande de los costos asociados a servicios de pacientes. La Diabetes es una de las causas principales de muerte a nivel mundial, y los pacientes hospitalizados con diabetes tienen un alto riesgo de readmisión, por lo que reducir esta tasa tiene un potencial enorme para reducir costos significativos. Suponiendo que el proceso de readmisión a nivel administrativo toma en promedio 35 minutos por paciente, pero que a través de un sistema de predicción de readmisión permita tener una lista de prioridad que reduzca en promedio 5 minutos el proceso. Suponga también que readmitir un paciente injustificadamente requiere una revisión administrativa igual a la de una admisión (35 minutos aprox).

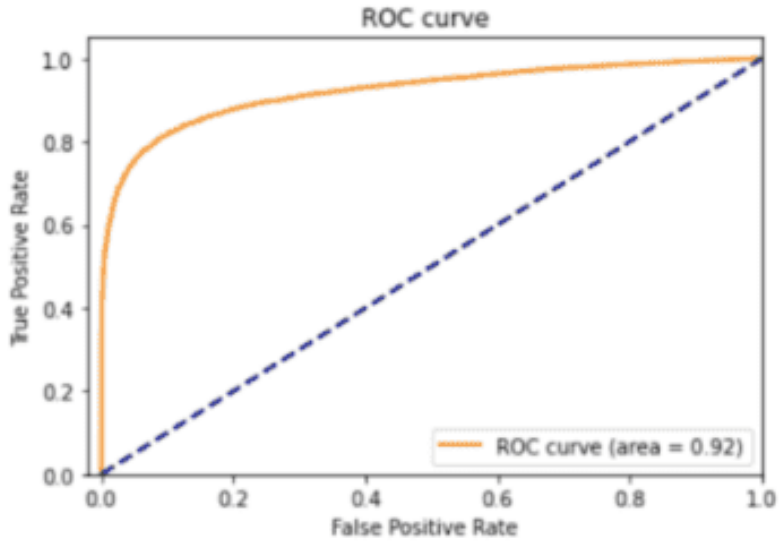
Si usted desarrolla un algoritmo de ML de clasificación para predecir los pacientes con diabetes que serán readmitidos, calcule el ROI en términos de horas de servicio de pacientes ahorrados. Suponga que en un periodo de 30 días hay alrededor de 300 readmisiones de pacientes con diabetes (15% del total).

*Readmisión: La admisión no programada de un paciente a un centro de atención luego de un egreso tras un periodo de tiempo.

Ejemplo – readmisión de pacientes

```
Accuracy: 0.8586

AUC Score (Train): 0.921817
```




```
Classification Report
              precision    recall  f1-score   support

           0       0.84      0.89      0.86      9159
           1       0.88      0.83      0.85      8923

    accuracy                           0.86     18082
   macro avg       0.86      0.86      0.86     18082
weighted avg       0.86      0.86      0.86     18082


 Confusion Matrix
[[8162  997]
 [1560 7363]]
```

Ejemplo – readmisión de pacientes

$$\hat{a} = (5 - (1 - 0.86) * 35)$$

Por paciente, la ganancia es de **0.1** minutos, o aproximadamente **30 minutos** en **300** pacientes al mes.

En promedio una enfermera gana **$13.087** por hora en Colombia. Esto significa que este modelo está ahorrando **$6.543** al mes.

¿A partir de qué momento se obtendrá un ROI de 0 para la compañía?

Ejemplo – readmisión de pacientes

$$\hat{a} = (5 - (1 - 0.86) * 35)$$

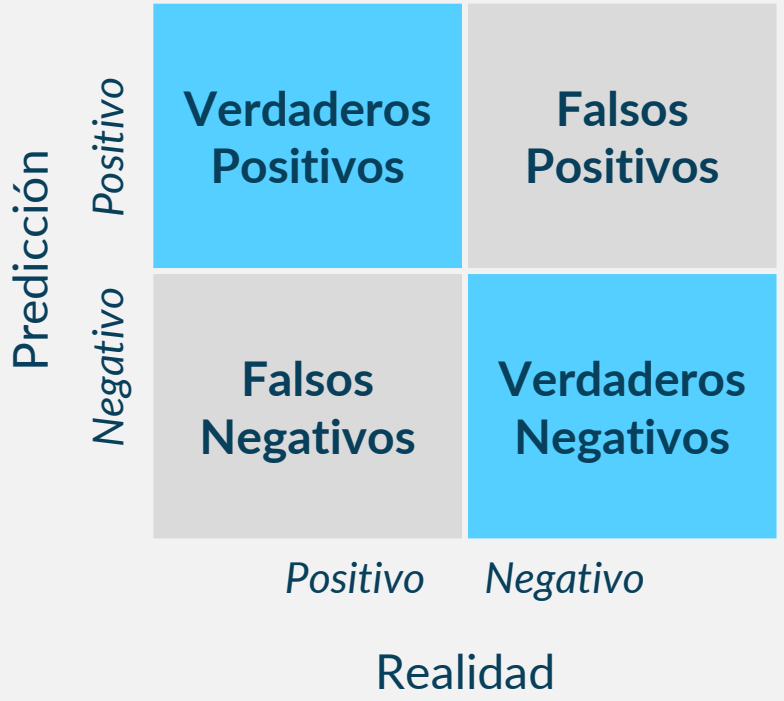
Por paciente, la ganancia es de **0.1** minutos, o aproximadamente **30 minutos** en **300** pacientes al mes.

En promedio una enfermera gana **$13.087** por hora en Colombia. Esto significa que este modelo está ahorrando **$6.543** al mes.

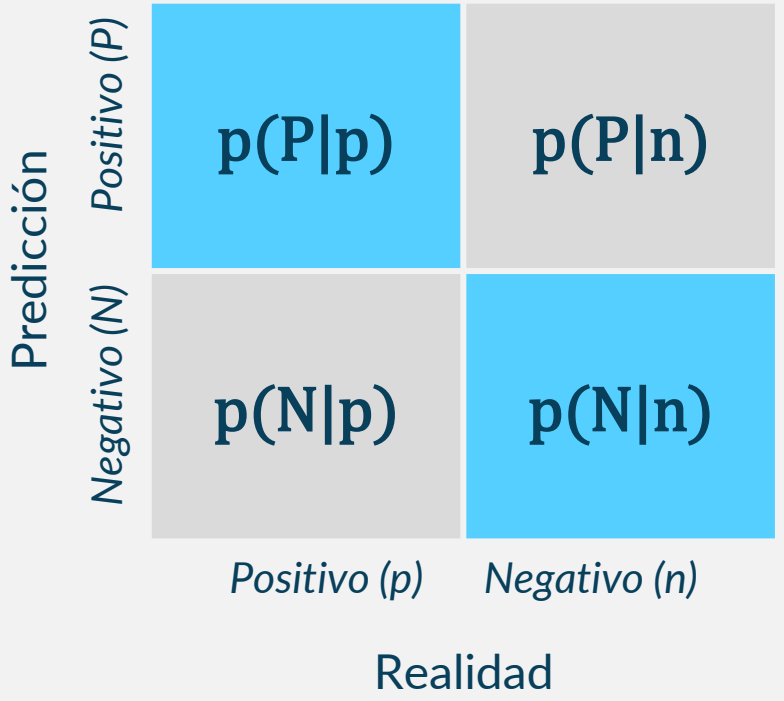
El salario por hora de un Científico de Datos es de **$28.700** por hora. Si el modelo tomó dos semanas laborales de trabajo, el costo es de **$2.296.000**. Este modelo tendrá un ROI de 0 luego de aproximadamente **351 meses**.

Valor esperado (Fórmula de Provost)

Matriz de confusión

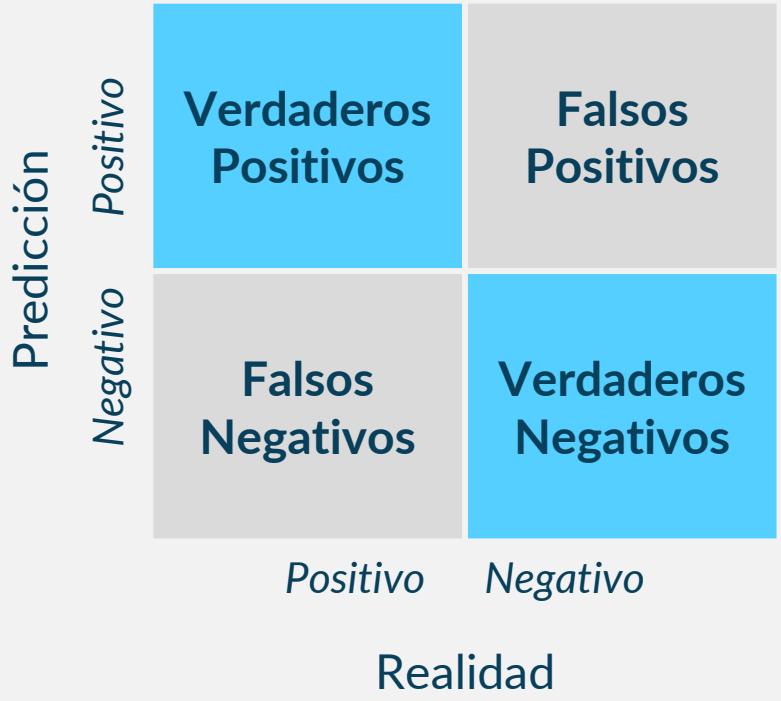


Matriz de probabilidades

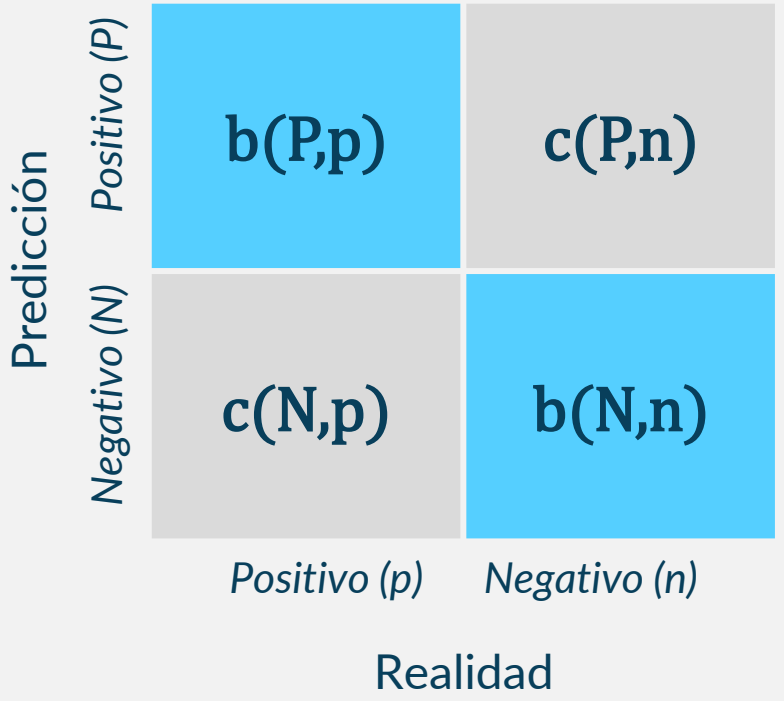


Valor esperado (Fórmula de Provost)

Matriz de confusión



Matriz de costo/beneficio



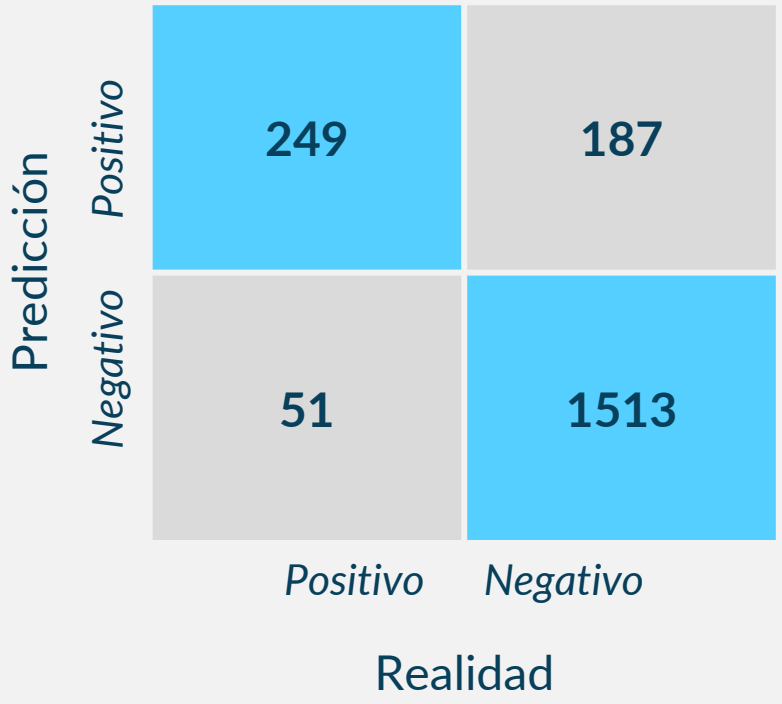
Valor esperado (Fórmula de Provost)

$$\hat{a} = p(p)[p(P|p) \cdot b(P,p) + p(N|p) \cdot c(N,p)] + p(n)[p(N|n) \cdot b(N,n) + p(P|n) \cdot c(P,n)]$$

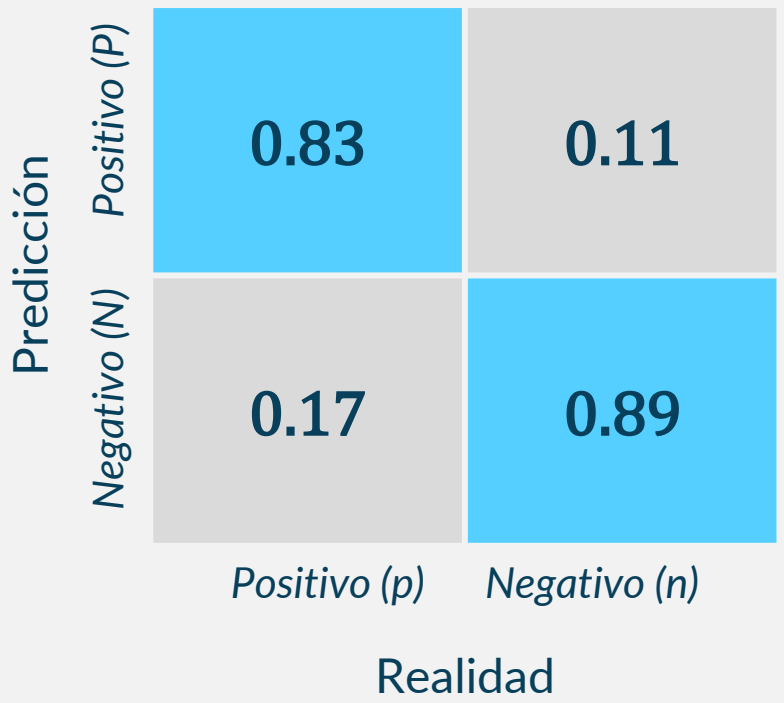
Distribuciones previas

Valor esperado (Fórmula de Provost)

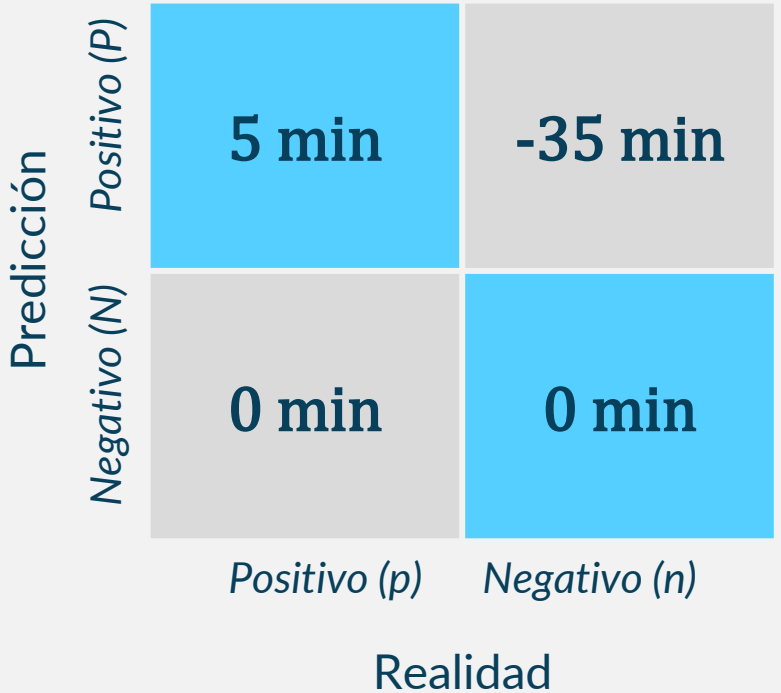
Matriz de confusión



Matriz de probabilidades



Matriz de costo/beneficio



Valor esperado (Fórmula de Provost)

$$\hat{a} = 0.15[0.83 \cdot 5 + 0.17 \cdot 0] + 0.85[0.89 \cdot 0 + 0.11 \cdot (-35)]$$

$$\hat{a} = 0.15[4.15] + 0.85[-3.85]$$

$$\hat{a} = 0.62 - 3.27$$

$$\hat{a} = -2.65$$

Dado que la ganancia es negativa, este modelo nunca recuperará la inversión y ofrece pérdidas.

¿A partir de qué métrica se encuentra el equilibrio (ganancia = 0)?

Valor esperado (Fórmula de Provost)

$$\hat{a} = 0.15[0.83 \cdot 5 + 0.17 \cdot 0] + 0.85[0.89 \cdot 0 + 0.11 \cdot (-35)]$$

$$\hat{a} = 0.15[4.15] + 0.85[-3.85]$$

$$\hat{a} = 0.62 - 3.27$$

$$\hat{a} = -2.65$$

Dado que la ganancia es negativa, este modelo nunca recuperará la inversión y ofrece pérdidas.

¿A partir de qué métrica se encuentra el equilibrio (ganancia = 0)?

R/. Necesitaríamos aumentar el Recall de la clase positiva o reducir el Fall-out de la clase negativa (Falsos positivos). El Fall-out debería ser de 0.02, máximo.

Valor esperado (Fórmula de Provost)

Recomendaciones:

- Asignar los valores a la matriz tomando como línea base el no usar el modelo.
- Evitar contar dos veces las ganancias y las pérdidas. Sólo deben aparecer una vez en el modelo.
- Los signos de costo/beneficio deben ser consistentes para el modelo.

Ejercicio

Utilice el problema de churn para el dataset de clientes. Asuma que la empresa cuenta con 5.000 diferentes clientes actualmente y que la tasa de churn conocida está alrededor del **20%**.

Asuma que el objetivo de la empresa es mantener al menos el mismo nivel de clientes. El costo de adquisición de nuevos clientes de **$150**. El costo de retener un cliente en condiciones normales es de **$25** anuales. La empresa pretende duplicar ese valor en programas de fidelización para clientes que planean dejar la compañía. Asuma que todo cliente que iba a abandonar la empresa y recibe un incentivo se queda, mientras que todo cliente que iba a abandonar la empresa y no recibe incentivo se va, y que la empresa busca siempre mantener su número de clientes. Adicionalmente el valor generado para la compañía por un cliente en promedio es de **$1500**.

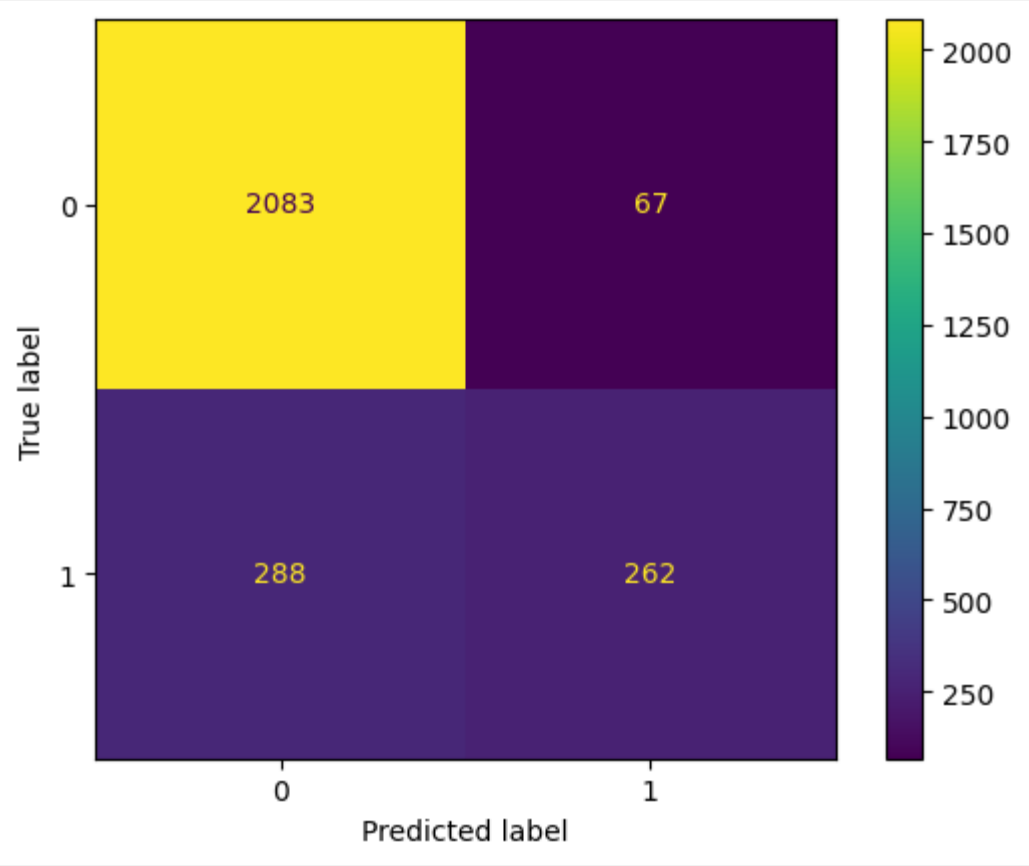
Asumiendo que su modelo tiene una exactitud de **0.87**. El costo de implementación del modelo en esta etapa, incluyendo equipo, licencia e infraestructura es de **$20.000**

Calcule el valor generado por cliente para su modelo usando la fórmula simplificada y la fórmula de Provost, y el punto de equilibrio (break-even).

¿Cómo cambian los valores si se analizan los resultados de ambas fórmulas para un conjunto remuestreado para que las clases churn y no-churn estén balanceadas?

Ejercicio

Matriz de confusión



¿Preguntas?

Referencias

- Ikan, C. (2001). The Foundations of Cost-Sensitive Learning. IJCAI 2001.
- Provost, F., & Fawcett, T. (2013). Data Science for Business. O'Reilly Media. (Capítulo 7)
- Linna, E (2020). Return on Investment for Machine Learning. Medium. (https://medium.com/data-science/return-on-investment-for-machine-learning-1a0c431509e)